KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

XỬ LÝ DỮ LIỆU VỚI R

(GÓI TIDYR)

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

MỘT SỐ VẤN ĐỀ KHI PHÂN TÍCH DỮ LIỆU

- Tiêu đề cột là giá trị, không phải tên biến
- Nhiều biến nằm trong một cột

XỬ LÝ DỮ LIỆU VỚI GÓI TIDYR

- Ưu điểm: thông dụng, đơn giản, dễ hiểu
- Tác dụng: hoàn thiện dữ liệu theo đúng quy cách

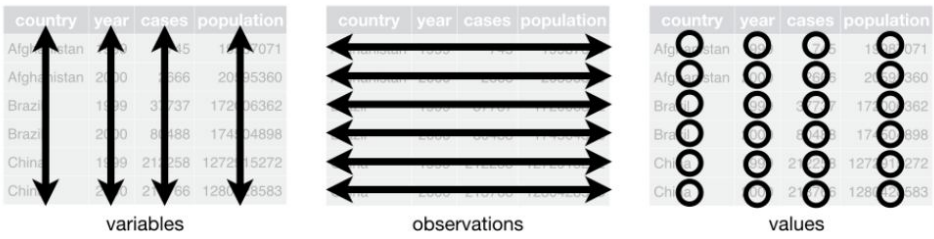

XỬ LÝ DỮ LIỆU VỚI GÓI TIDYR

- Một số lệnh cơ bản:

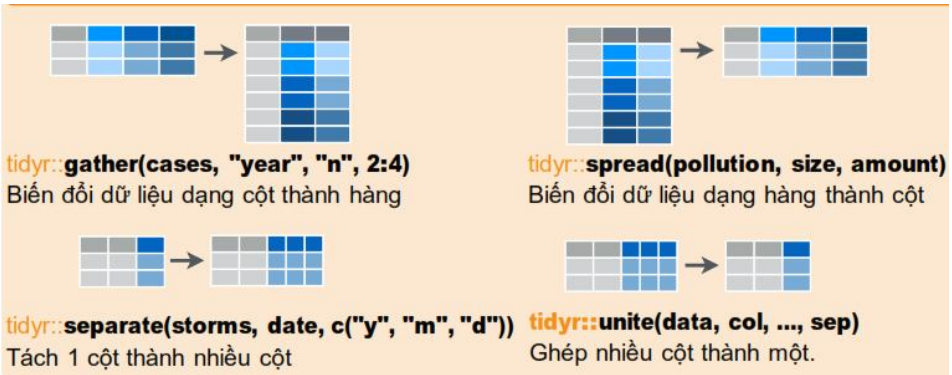

LỆNH GATHER()

Tác dụng: Biến đổi dữ liệu dạng cột thành hàng

Ví dụ:

```
diemthi
```

```
R> # A tibble: 5 x 4
R>     sbd   van ngoaingu  toan
R>   <int> <dbl>    <dbl> <dbl>
R> 1     1  6         5   0.5
R> 2     2  7.25      6.5 4.25
R> 3     3  6         8.5 4
R> 4     4  8         8.5 3.5
R> 5     5  7.75      7.75 7.25
```

```
diemthi_tidy
```

```
R> # A tibble: 15 x 3
R>      sbd mon       diem
R>    <int> <chr>    <dbl>
R>  1     1 van       6
R>  2     2 van       7.25
R>  3     3 van       6
R>  4     4 van       8
R>  5     5 van       7.75
R>  6     1 ngoaingu  5
R>  7     2 ngoaingu  6.5
R>  8     3 ngoaingu  8.5
R>  9     4 ngoaingu  8.5
R> 10     5 ngoaingu  7.75
R> 11     1 toan      0.5
R> 12     2 toan      4.25
R> 13     3 toan      4
R> 14     4 toan      3.5
R> 15     5 toan      7.25
```


LỆNH GATHER()

Câu lệnh:

gather(đối tượng, tên cột tổng hợp các cột cũ, tên cột tổng hợp các giá trị cũ, các cột cần tổng hợp)

Ví dụ:

gather(diemthi, mon, diem, van, ngoaingu, toan)

Van

Ngoaingu

toan

LỆNH SPREAD()

- **Tác dụng:** Biến đổi dữ liệu dạng hàng thành cột
- **Câu lệnh:**

```
spread(đối tượng, tên cột muốn tách thành cột mới,
        tên cột muốn tách thành các giá trị)
```

model	region	sales
Ford Ranger	North	653
Ford Ranger	Central	171
Ford Ranger	South	573
Honda City	North	301
Honda City	Central	203
Honda City	South	470

model	Central	North	South
Ford Ranger	171	653	573
Honda City	203	301	470

LỆNH UNITE()

- **Tác dụng:** Gộp nhiều cột thành 1 cột
- **Câu lệnh:**

```
unite(đối tượng, col = tên cột mới được gộp, tên cột gộp 1, tên cột gộp
    2,.. sep = "ngăn cách giữa các giá trị", remove = FALSE/TRUE)
```

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

LỆNH SEPARATE()

- **Tác dụng:** tách 1 cột thành nhiều cột
- **Câu lệnh:**

```
separate(đối tượng, tên cột cần tách, into = c("tên cột tách 1", "cột 2
  tách“,..), sep = "ngăn cách để tách“ hoặc số ký tự cần tách tính từ
                    trái, remove = FALSE/TRUE)
```


KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

LỆNH GSUB()

- **Tác dụng:** thay ký tự trong các giá trị
- **Câu lệnh:**

```
gsub("giá trị cần thay", "giá trị muốn thay", đối tượng$cột cần thay
giá trị)
```

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Biến đổi dữ liệu

với dplyr & tidyr

Cheat Sheet

RStudio

Câu lệnh

dplyr::**tbl_df(iris)**
Biến đổi dữ liệu sang dạng **tbl**, dạng dữ liệu này đơn giản hơn khi kiểm tra dữ liệu. R chỉ hiển thị dữ liệu vừa với màn hình hiển thị

```
Source: local data frame [150 x 5]

   Sepal.Length Sepal.Width Petal.Length
1           5.1         3.5          1.4
2           4.9         3.0          1.4
3           4.7         3.2          1.3
4           4.6         3.1          1.5
5           5.0         3.6          1.4
..          ...         ...          ...
Variables not shown: Petal.Width (dbl),
  Species (fctr)
```

dplyr::**glimpse(iris)**
Tóm tắt thông tin của định dạng dữ liệu tbl
utils::**View(iris)**
Hiển thị dữ liệu dạng bảng (tương tự như excel)

dplyr::**%>%**
Chuyển đổi tượng (object) ở phía bên trái dấu %>% thành biến (argument) của hàm bên phải dấu %>%

x %>% f(y) *cho kết quả tương tự như* **f(x, y)**
y %>% f(x, ., z) *cho kết quả tương tự như* **f(x, y, z)**

Sử dụng "piping" **%>%** làm cho việc theo dõi code đơn giản hơn rất nhiều, ví dụ:

```
iris %>%
  group_by(Species) %>%
  summarise(avg = mean(Sepal.Width)) %>%
  arrange(avg)
```

Tidy Data (Dữ liệu sạch) – Nền tảng của việc biến đổi dữ liệu

Dữ liệu sạch

Mỗi **cột** chứa một **biến**

Mỗi **hàng** chứa một **quan sát** (observation)

Trong dữ liệu sạch, R sẽ giữ nguyên định dạng các biến theo dạng vector

M * A

Reshaping Data - Thay đổi cấu trúc dữ liệu

tidyr::**gather(cases, "year", "n", 2:4)**
Biến đổi dữ liệu dạng cột thành hàng

tidyr::**spread(pollution, size, amount)**
Biến đổi dữ liệu dạng hàng thành cột

tidyr::**separate(storms, date, c("y", "m", "d"))**
Tách 1 cột thành nhiều cột

tidyr::**unite(data, col, ..., sep)**
Ghép nhiều cột thành một.

dplyr::**data_frame(a = 1:3, b = 4:6)**
Nhóm các véc-tơ thành data frame
dplyr::**arrange(mtcars, mpg)**
Sắp xếp các dòng theo một biến từ nhỏ đến lớn
dplyr::**arrange(mtcars, desc(mpg))**
Sắp xếp các dòng theo một biến từ lớn đến nhỏ
dplyr::**rename(tb, y = year)**
Thay đổi tên của một biến

Lấy dữ liệu theo dòng

dplyr::**filter(iris, Sepal.Length > 7)**
Lọc các dòng với điều kiện xác định
dplyr::**distinct(iris)**
Xóa các dòng có giá trị trùng nhau
dplyr::**sample_frac(iris, 0.5, replace = TRUE)**
Lấy ngẫu nhiên các quan sát theo tỉ lệ cho trước
dplyr::**sample_n(iris, 10, replace = TRUE)**
Lấy ngẫu nhiêu n dòng
dplyr::**slice(iris, 10:15)**
Lấy các dòng theo vị trí
dplyr::**top_n(storms, 2, date)**
Lấy và sắp xếp thứ tự n dòng đầu tiên

Các phép toán logic trong R

<	Nhỏ hơn	!=	Không bằng
>	Lớn hơn	%in%	Chứa trong nhóm
==	Bằng	is.na	Kiểm tra dữ liệu thiếu (NA)
<=	Nhỏ hơn hoặc bằng	!is.na	Kiểm tra dữ liệu không thiếu
>=	Lớn hơn hoặc bằng	&,|,!,xor,any,all	Toán tử kết hợp logic đơn giản trong R

Lấy dữ liệu: **devtools::install_github("rstudio/EDAWR")**

Lấy dữ liệu theo cột

dplyr::**select(iris, Sepal.Width, Petal.Length, Species)**
Chọn các biến (cột) theo tên

Các hàm với "select"- ?select

select(iris, contains("."))
Chọn các biến mà tên biến đó có chứa ký tự
select(iris, ends_with("Length"))
Chọn các biến mà tên biến đó kết thúc với một chuỗi ký tự
select(iris, everything())
Chọn tất cả các biến
select(iris, matches(".t."))
Chọn biến mà tên biến đó khớp với điền kiện cho trước
select(iris, num_range("x", 1:5))
Chọn các biến tên x1, x2, x3, x4, x5.
select(iris, one_of(c("Species", "Genus")))
Chọn các biến mà tên biến đó nằm trong 1 nhóm các tên biến
select(iris, starts_with("Sepal"))
Chọn các biến có tên bắt đầu với một chuỗi ký tự
select(iris, Sepal.Length:Petal.Width)
Chọn tất cả các biến từ Sepal.Length đến Petal.Width
select(iris, -Species)
Chọn tất cả các biến ngoại trừ Species

RStudio® is a trademark of RStudio, Inc. • CC BY RStudio • info@rstudio.com • 844-448-1212 • rstudio.com

Translator: ranalytics.vn

Xem thêm: Vignettes(package = c("dplyr", "tidyr")) • dplyr 0.4.0• tidyr 0.2.0 • Updated: 1/15

hoathongke.neu.edu.vn

11

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Tóm tắt dữ liệu

dplyr::**summarise(iris, avg = mean(Sepal.Length))**
Tóm tắt dữ liệu thành các dòng
dplyr::**summarise_each(iris, funs(mean))**
Áp dụng hàm với tất cả các cột trong dữ liệu
dplyr::**count(iris, Species, wt = Sepal.Length)**
Đếm số lượng các dòng khi giá trị của biến là duy nhất (có hoặc không có trọng số)

summary function

Summarise sử dụng các hàm tính toán một véc-tơ các giá trị và trả về giá trị, ví dụ:

dplyr::**first**
Giá trị đầu tiên của véc-tơ
dplyr::**last**
Giá trị cuối cùng của véc-tơ.
dplyr::**nth**
Giá trị thứ n của véc-tơ.
dplyr::**n**
Số lượng các quan sát trong véc-tơ
dplyr::**n_distinct**
Số lượng các giá trị khác nhau trong véc-tơ
IQR
IQR của một véc-tơ.

min
Giá trị nhỏ nhất của véc-tơ
max
Giá trị lớn nhất của véc-tơ
mean
Giá trị trung bình của véc-tơ
median
Trung vị của véc-tơ
var
Phương sai của véc-tơ
sd
Độ lệch tiêu chuẩn của véc-tơ

Nhóm dữ liệu

dplyr::**group_by(iris, Species)**
Nhóm các biến thành các hàng có cùng giá trị của Species
dplyr::**ungroup(iris)**
Loại bỏ nhóm
iris %>% group_by(Species) %>% summarise(…)
Tính toán và trả các giá trị với mỗi nhóm

Tạo các biến mới

dplyr::**mutate(iris, sepal = Sepal.Length + Sepal.Width)**
Tính toán và tạo một hoặc nhiều biến mới
dplyr::**mutate_each(iris, funs(min_rank))**
Áp dụng hàm cho mỗi biến
dplyr::**transmute(iris, sepal = Sepal.Length + Sepal.Width)**
Tính toán và tạo biến mới, loại bỏ biến cũ.

window function

Sử dụng "window function", các hàm này tính toán 1 véc-tơ & trả ra giá trị là 1 véc-tơ, ví dụ:

dplyr::**lead**
Copy & tạo 1 véc-tơ có giá trị của biến nhanh hơn 1 đơn vị
dplyr::**lag**
Copy & tạo 1 véc-tơ có giá trị của biến chậm hơn 1 đơn vị
dplyr::**dense_rank**
Thứ tự giá trị của biến (không tính trùng giá trị)
dplyr::**min_rank**
Thứ tự giá trị của biến (tính trùng giá trị)
dplyr::**percent_rank**
Thứ tự giá trị trong khoảng [0, 1].
dplyr::**row_number**
Thứ tự giá trị của biến (tính trùng giá trị - các giá trị trùng nhau được xếp thứ tự khác nhau)
dplyr::**ntile(x,n)**
Chia véc-tơ thành n nhóm
dplyr::**between(x,a,b)**
Kiểm tra các giá trị của x trong khoảng [a,b]

dplyr::**cume_dist**
Véc-tơ giá trị hàm phân phối với từng giá trị của biến
dplyr::**cumall**
Véc-tơ giá trị logic tích lũy theo điều kiện cho trước (tất cả các giá trị phải thỏa mãn)
dplyr::**cumany**
Véc-tơ giá trị logic theo điều kiện cho trước (có ít nhất 1 giá trị thỏa mãn)
dplyr::**cummean**
Véc-tơ giá trị trung bình tích lũy của x
Cumsum
Véc-tơ giá trị tổng tích lũy của x
Cummax
Véc-tơ chứa các giá trị lớn nhất của x theo thứ tự
cummin
Véc-tơ chứa các giá trị nhỏ nhất của x theo thứ tự
cumprod
Véc-tơ giá trị của tích
pmax
Véc-tơ giá trị lớn nhất
pmin
Véc-tơ giá trị nhỏ nhất

iris %>% group_by(Species) %>% mutate(…)
Tạo các biến mới với mỗi nhóm

Lấy dữ liệu: devtools: **install_github("rstudio/EDAWR")**

Nối dữ liệu (Combine Data Sets)

Mutating Joins

dplyr::**left_join(a, b, by = "x1")**
Ghép các dòng có cùng giá trị từ b đến a.

dplyr::**right_join(a, b, by = "x1")**
Ghép các dòng có cùng giá trị từ a đến b

dplyr::**inner_join(a, b, by = "x1")**
Giữ các giá trị có cả ở a & b

dplyr::**full_join(a, b, by = "x1")**
Giữ tất cả các giá trị ở a & b

Filtering Joins

dplyr::**semi_join(a, b, by = "x1")**
Giữ lại các dòng xuất hiện trong b

dplyr::**anti_join(a, b, by = "x1")**
Giư lại các dòng không có trong b

Set Operations

dplyr::**intersect(y, z)**
Các dòng có ở cả y & z

dplyr::**union(y, z)**
Dòng có trong y hoặc z.

dplyr::**setdiff(y, z)**
Dòng có trong y nhưng không có trong z

Binding

dplyr::**bind_rows(y, z)**
Nối dòng dữ liệu từ z sang y,

dplyr::**bind_cols(y, z)**
Nối cột dữ liệu từ z sang y
Lưu ý: trùng giá trị của biến.

RStudio® is a trademark of RStudio, Inc. • CC BY RStudio • info@rstudio.com • 844-448-1212 • rstudio.com

Translator: ranalytics.vn

Xem thêm: Vignettes(package = c("dplyr", "tidyr")) • dplyr 0.4.0• tidyr 0.2.0 • Updated: 1/15

athongke.neu.edu.vn

12

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

TẠO BẢNG VÀ ĐỒ THỊ VỚI R

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NỘI DUNG

- Lập bảng
- Vẽ đồ thị

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

1. LẬP BẢNG

- Lệnh **table** có sẵn trong R (đơn giản, ít tùy chọn, không linh hoạt)
- Lệnh **tabular** trong package **tables** (hỗ trợ xuất latex, pdf)

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

LẬP BẢNG: LỆNH TABLE

Bảng tần số

- Lập bảng 1 chiều:
  - ✓ `table(dataframe$cột/biến)`
- Lập bảng nhiều chiều:

```
table(dataframe$cột/biến1,
      dataframe$cột/biến2,..)
```

Thêm tổng số (dòng/cột): `addmargins(bảng)`

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

LẬP BẢNG: LỆNH TABLE

Bảng tần suất (cơ cấu):

- Tỷ lệ chung: `prop.table(bảng)`
- Tỷ lệ theo dòng: `prop.table(bảng, 1)`
- Tỷ lệ theo cột: `prop.table(bảng, 2)`

Làm tròn:

- `round(prop.table(bảng), số chữ số thập phân)`
- `round(100*prop.table(bảng), số chữ số thập phân)`

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

LẬP BẢNG: LỆNH TABULAR

- **Cấu trúc câu lệnh:**

  `tabular(dòng +/* dòng +/* ... ~ cột +/* cột +/* ...)`

- **Các dấu cơ bản:**
  - Dấu **~**: phân tách dòng với cột (dòng ~ cột)
  - Dấu **+**: thứ tự trên-dưới/trái-phải trong bảng (phân tổ đơn)
  - Dấu *****: mỗi phần tử phía sau nằm trong mỗi phần tử ở phía trước (phân tổ kết hợp)

Trong đó:

- *Tần số:* `1`
- *Tần suất:* `Percent()`
- *Thêm dòng/cột tổng:* `+ 1`
- *Tính các thống kê:* `tênbiến * (1 + mean + sd +...)`

LẬP BẢNG: LỆNH TABULAR

- **Lưu bảng đã tạo:**

```
write.csv.tabular(bảng,
                  file = "tên file.csv")
```


LẬP BẢNG: PHÂN TÍCH TƯƠNG QUAN

- **Cấu trúc câu lệnh:**
  - ***Cách 1:***

```
cor(đối tượng,
    method = "pearson"/"kendal"/"spearman")
```

  - ***Cách 2:*** cần package **Hmisc**

```
a <- rcorr(as.matrix(đối tượng))
```

→ Có 3 thành phần: hệ số tương quan, số quan sát và p-value. Tách riêng: `a$r`, `a$n`, `a$P`

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

2. VẼ ĐỒ THỊ

- Lệnh **plot** có sẵn trong R (đơn giản, ít tùy chọn, không linh hoạt)
- Lệnh **ggplot** trong package **ggplot2** (nhiều tùy chọn, thông dụng)
- Lệnh **ggplotly** trong package **plotly** (đồ thị tương tác)
- Package **gganimate** (đồ thị động)

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

VẼ ĐỒ THỊ: LỆNH PLOT

- Vẽ cho 1 biến:

```
plot(biến cần vẽ ~ biến phân tổ,
     main = "...",
     xlab = "...", ylab = "...")
```

Có thể thay `plot` *bằng:* `hist, boxplot, dotchart`

VẼ ĐỒ THỊ: LỆNH PLOT

- Câu lệnh:

```
plot(bảng,
      type = "p"/"l"/"b"/"c"/"h"/...,
      main = "...",
      xlab = "...", ylab = "...")
```

Có thể thay `plot` *bằng:* `pie, barplot`

VẼ ĐỒ THỊ: LỆNH PLOT

- Vẽ cho 2 biến:

```
plot(biến 1, biến 2,
      type = "p"/"l"/"b"/"c"/"h"/...,
      main = "...",
      xlab = "...", ylab = "...")
```

Có thể thay `plot` *bằng:* `pie, barplot`

VẼ ĐỒ THỊ: PACKAGE GGPLOT2

GGPLOT2 dựa trên cấu trúc của đồ họa, vẽ biểu đồ từ một số thành phần cơ bản:

- Data set: tập dữ liệu (phải là dataframe)
- A set of geoms: tập hợp vị trí của các điểm
- Coordinate system: hệ thống tọa độ

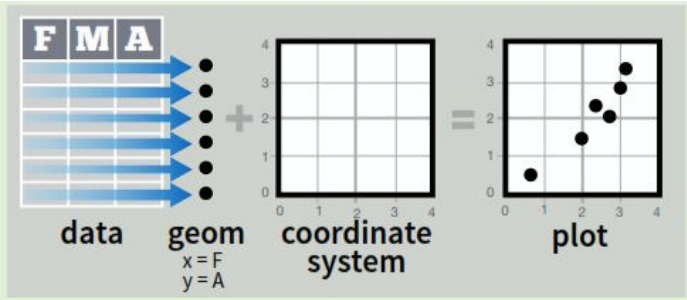

GIỚI THIỆU VỀ GGPLOT2

Để biểu đồ trở nên đẹp mắt và có tính thẩm mỹ hơn, cần có thêm thông tin về màu sắc (color), kích cỡ (size) của các điểm trong geoms.

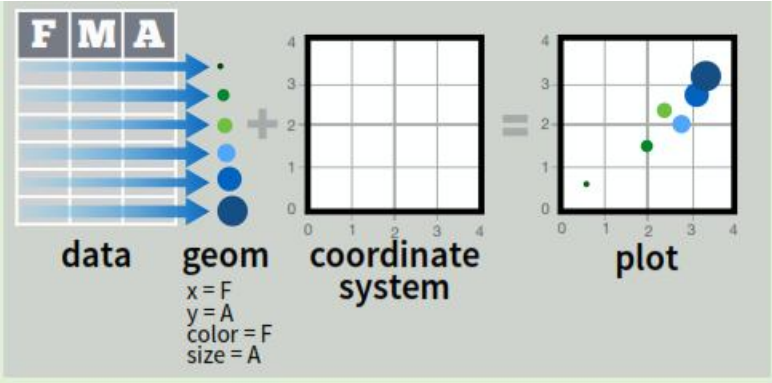

CẤU TRÚC CÂU LỆNH GGPLOT

- **Câu lệnh bắt đầu:** `ggplot(đối tượng)`
- Phân theo từng lớp, cách nhau bởi dấu "**+**":
  - `Aesthetics`: *xác định trục của biểu đồ*
  - `Geometric`: *xác định loại biểu đồ bar, dot, histogram,...*
  - `Facets`: *chia nhỏ biểu đồ*
  - `Statistics`: *vẽ các thống kê của dữ liệu*
  - `Coordinates`: *kiểm soát không gian trên biểu đồ*
  - `Scale:` *lựa chọn tỷ lệ*
  - `Theme`: *lựa chọn hình nền*
  - `Labels:` *gán tiêu đề và nhãn*

CÁC LAYER

- Xác định hai trục của biểu đồ: `aes(trục hoành, trục tung)`
- Xác định loại biểu đồ: `geom_loại biểu đồ(các lựa chọn)`
- Chia nhỏ biểu đồ: `facet_căn cứ chia(các lựa chọn)`
- Vẽ các thống kê của dữ liệu: `stat_các thống kê(các lựa chọn)`
- Vị trí chú giải: `theme(legend.position = "top"/"bottom"/"right"/"left")`
- Kiểm soát không gian (xoay, bỏ giá trị đột xuất, phóng to 1 khoảng,…)
  `coord_các lựa chọn(các lựa chọn)`
- Lựa chọn tỷ lệ: `scale_các lựa chọn(các lựa chọn)`
- Lựa chọn hình nền: `theme_loại hình nền()`
- Gán tiêu đề và nhãn:
```
labs(title = "tên biểu đồ",
     subtitlex = ,"...",
     x = "tên trục x",  y = "tên trục y",
     caption = "...")
```

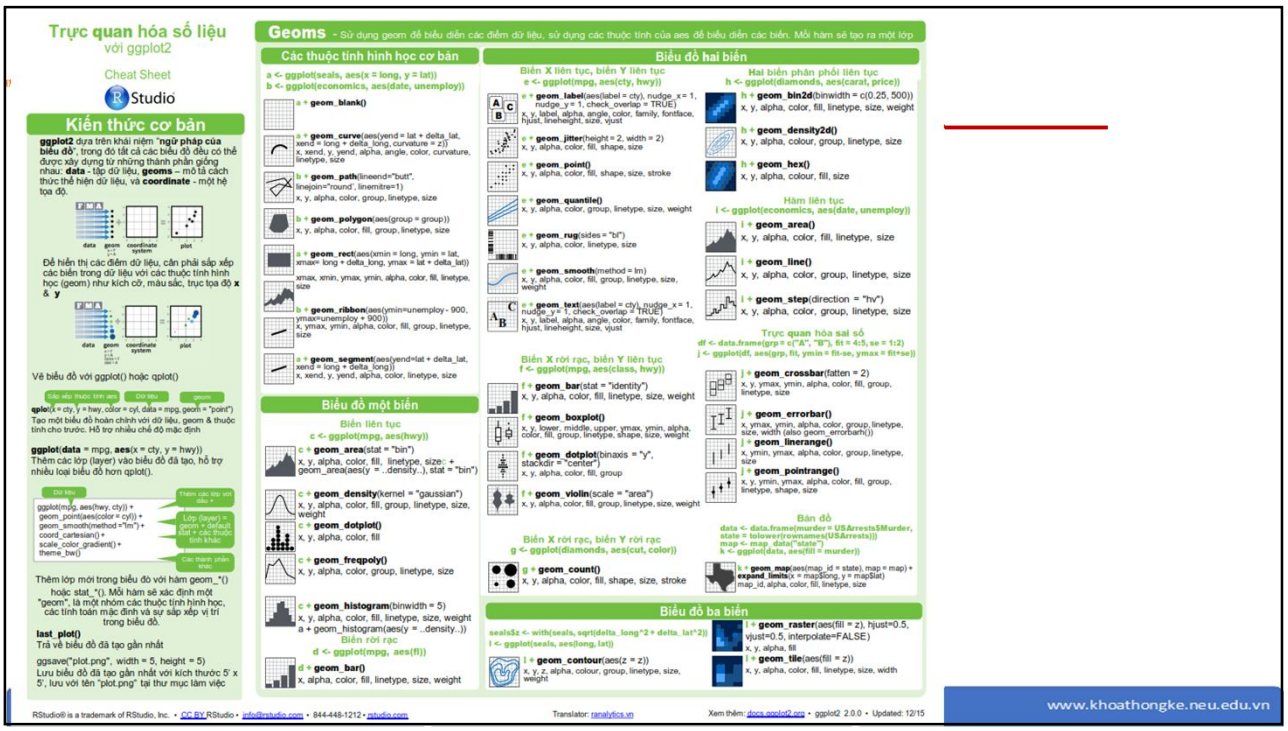
Trực quan hóa số liệu
với ggplot2
Cheat Sheet
Studio
Kiến thức cơ bản
Geoms - Sử dụng geom để biểu diễn các điểm dữ liệu, sử dụng các thuộc tính của aes để biểu diễn các biến. Mỗi hàm sẽ tạo ra một lớp
Các thuộc tính hình học cơ bản
Biểu đồ hai biến
Biểu đồ một biến
Biểu đồ ba biến
www.khoathongke.neu.edu.vn

29

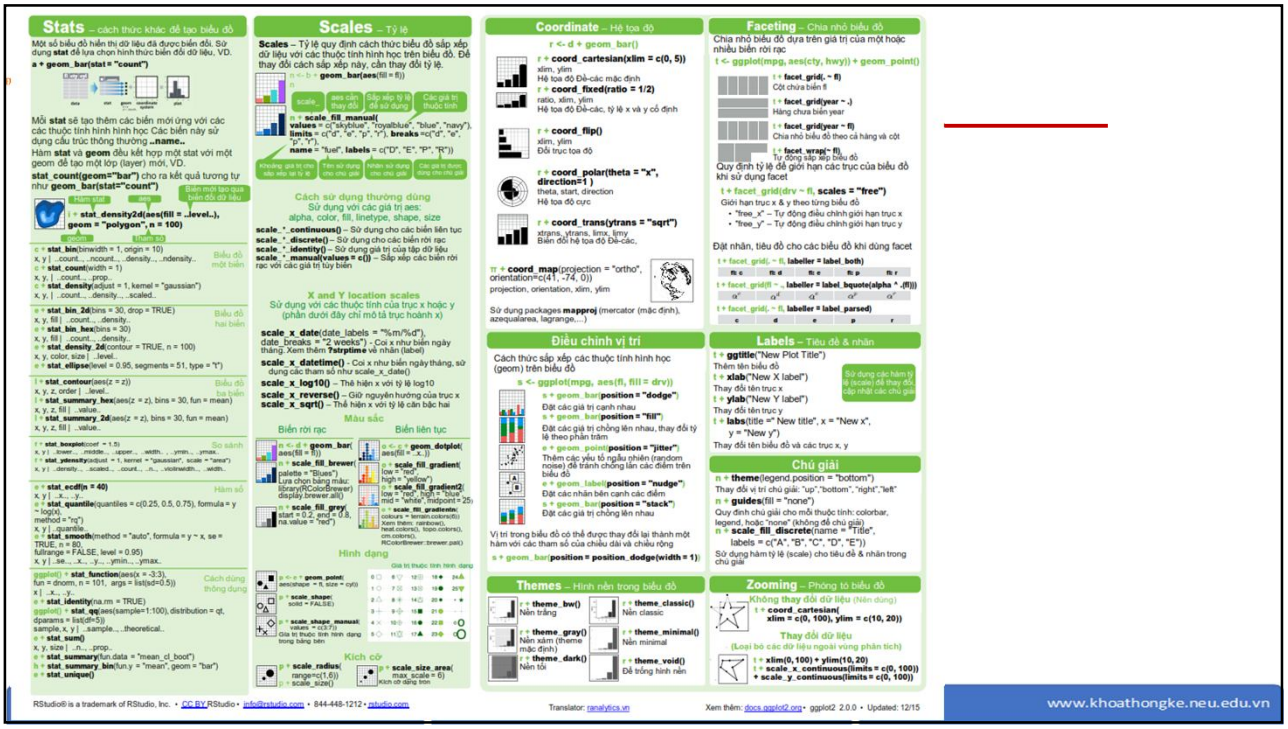
Stats – cách thức khác để tạo biểu đồ
Scales – Tỷ lệ
Coordinate – Hệ tọa độ
Faceting – Chia nhỏ biểu đồ
Điều chỉnh vị trí
Labels – Tiêu đề & nhãn
Themes – Hình nền trong biểu đồ
Zooming – Phóng to biểu đồ
Chú giải
www.khoathongke.neu.edu.vn

30

ĐỒ THỊ HỆ SỐ TƯƠNG QUAN

- Sử dụng package **corrplot**
- Cấu trúc câu lệnh:

```
ggcorrplot(cor(đối tượng), các tùy chọn)
```

Các tùy chọn:

- *Loại:* `method = c("square", "circle")`
- *Hình thức biểu hiện:* `type = "upper", "lower", "full"`
- *Hiện giá trị:* `lab = TRUE, lab_size = 3,`
- *Màu sắc:* `legend.title = "Corr", colors = c("blue", "white", "red"), outline.color = "gray"`
- *Thứ tự các biến:* `hc.order = TRUE/FALSE`

BIỂU ĐỒ TƯƠNG TÁC

- Sử dụng package **plotly**
- Câu lệnh: `ggplotly(đồ thị)`

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

BIỂU ĐỒ ĐỘNG
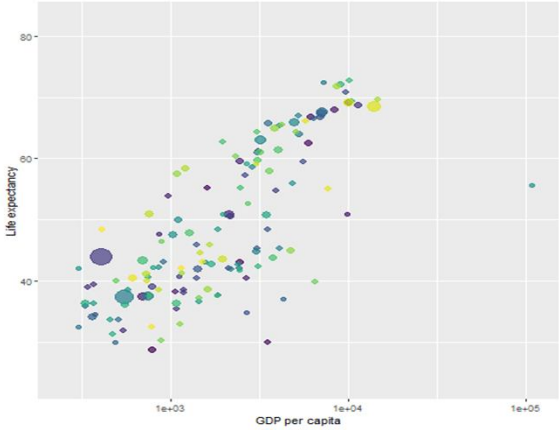
- Sử dụng package **gganimate, gifski, png**:
- Thêm layer:
  - `transition_time(biến)`
    `transition_states(biến)`
    `transition_reveal(biến)`
  - `shadow_mark()`
    `shadow_trail()`
  - `anim_save("tên file.gif")`