KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

TUẦN 5:
GIỚI THIỆU CHUNG VỀ KHAI PHÁ DỮ LIỆU

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NỘI DUNG

1. Khai phá dữ liệu là gì?
2. Quy trình khai phá dữ liệu
3. Các kỹ thuật khai phá dữ liệu
4. Công cụ khai phá dữ liệu

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

1. KHAI PHÁ DỮ LIỆU LÀ GÌ?

✓Sự bùng nổ của dữ liệu và dữ liệu lớn

✓Nhu cầu phát hiện tri thức từ dữ liệu

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

SỰ BÙNG NỔ CỦA DỮ LIỆU

- **Trong kỷ nguyên kỹ thuật số, các TB dữ liệu được tạo ra theo giây**
  - *Thiết bị di động, ảnh kỹ thuật số, tài liệu web*
  - *Các cập nhật Facebook, Tweets, Blogs, nội dung do người dùng tạo*
  - *Giao dịch, dữ liệu cảm biến, dữ liệu giám sát*
  - *Các truy vấn, các lần click chuột, các thao tác trên web*
  - *...*
- **Bộ nhớ chứa dữ liệu ngày càng rẻ**

SỰ BÙNG NỔ CỦA DỮ LIỆU

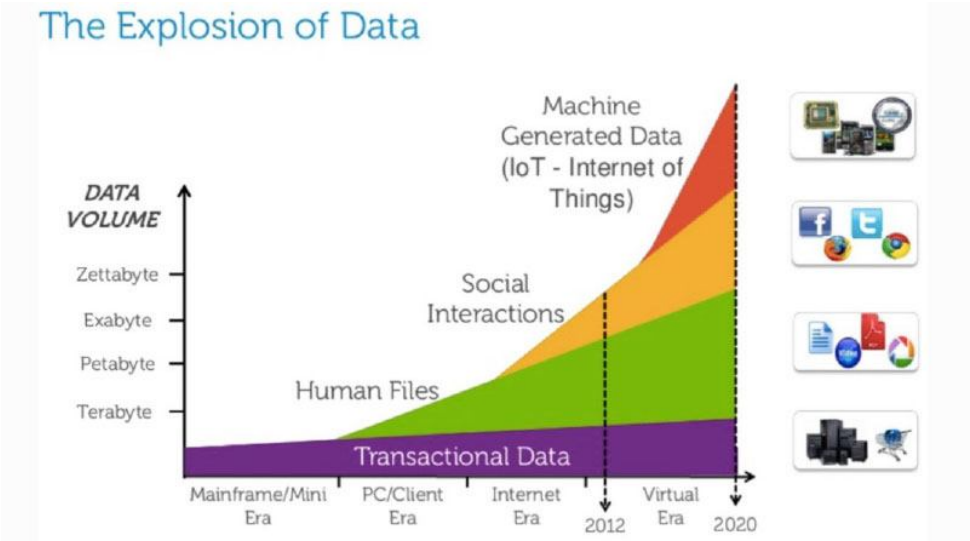

SỰ BÙNG NỔ CỦA DỮ LIỆU

Top 10 Largest Databases in the World - Read #1 Articles | 2021 (wheelhouse.com)

- **Thư viện quốc hội Mỹ:** 130 triệu tài liệu, 29 triệu sách, 10 nghìn tài liệu mới được bổ sung mỗi ngày, 530 dặm kệ sách, 5 triệu tài liệu kỹ thuật số, 20 terabytes dữ liệu văn bản
- **Cơ quan tình báo trung ương (CIA)**
- **Amazon:** 52 triệu khách hàng, hơn 42 terabytes dữ liệu
- **Youtube:** 100 triệu video được xem hàng ngày, 65 nghìn video được bổ sung mới mỗi ngày, 60% video được xem online, ít nhất 45 terabytes video. Dung lượng CSDL YouTube tăng gấp đôi sau mỗi chu kỳ 5 tháng
- ...

SỰ BÙNG NỔ CỦA DỮ LIỆU

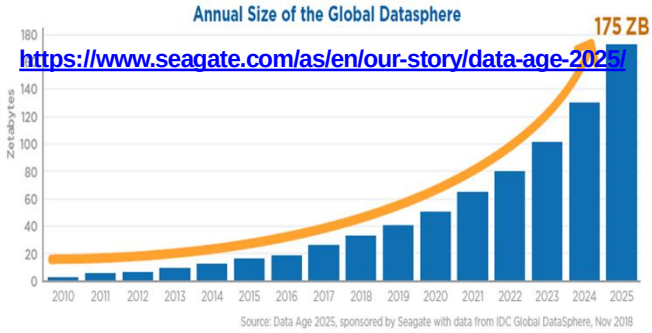

https://www.seagate.com/as/en/our-story/data-age-2025/

- Giá tạo dữ liệu ngày càng rẻ hơn
  - Chiều hướng giá tạo mới dữ liệu giảm dần
  - 0,5 xu Mỹ/1 GB vào năm 2009 giảm xuống 0,02 xu Mỹ /1 GB vào năm 2020
- Dung lượng tổng thể tăng
  - Độ dốc tăng càng cao
  - Đã đạt 33ZB năm 2018 (năm 2011 dự kiến đạt 35 ZB vào năm 2020)

SỰ BÙNG NỔ CỦA DỮ LIỆU

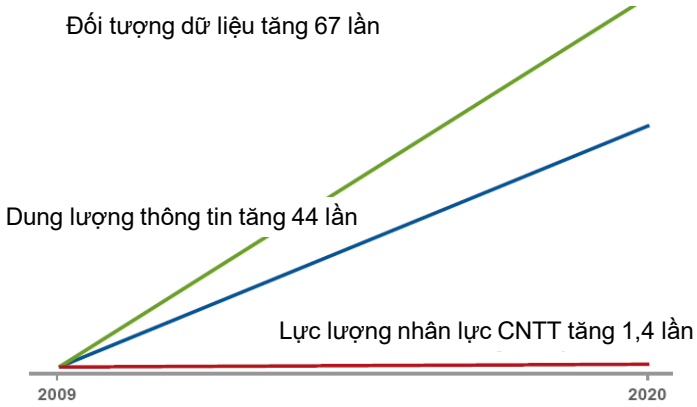

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NHU CẦU PHÁT HIỆN TRI THỨC

- Giả sử bạn là chủ một siêu thị và bạn đã thu thập hàng tỷ dữ liệu về hóa đơn mua hàng của khách.

TID	Mặt hàng
1	Bánh mì, Coca, Sữa
2	Bia, Bánh mì
3	Bia, Coca, Bỉm, Sữa
4	Bia, Bánh mì, Bỉm, Sữa
5	Coca, Bỉm, Sữa

Vị trí đặt sản phẩm

Tạo danh mục hàng

Các khuyến nghị, đề xuất

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NHU CẦU PHÁT HIỆN TRI THỨC

- Giả sử bạn là người phụ trách của ngân hàng. Bạn có dữ liệu về các giao dịch của tất cả khách hàng.

NHU CẦU PHÁT HIỆN TRI THỨC

- Giả sử bạn có được dữ liệu của từng cá nhân về:
  - Các trang web mở trên thanh công cụ
  - Các trang web mở qua click chuột
  - Các hoạt động tìm kiếm
  - Các quảng cáo được click
  - Thời gian của người dùng

NHU CẦU PHÁT HIỆN TRI THỨC

- Giả sử bạn là một nhà môi giới chứng khoán và bạn quan sát sự biến động của nhiều cổ phiếu theo thời gian

NHU CẦU PHÁT HIỆN TRI THỨC

- Giả sử bạn là giám đốc kinh doanh khách sạn. Bạn có dữ liệu là các nhận xét của khách hàng đối với khách sạn.

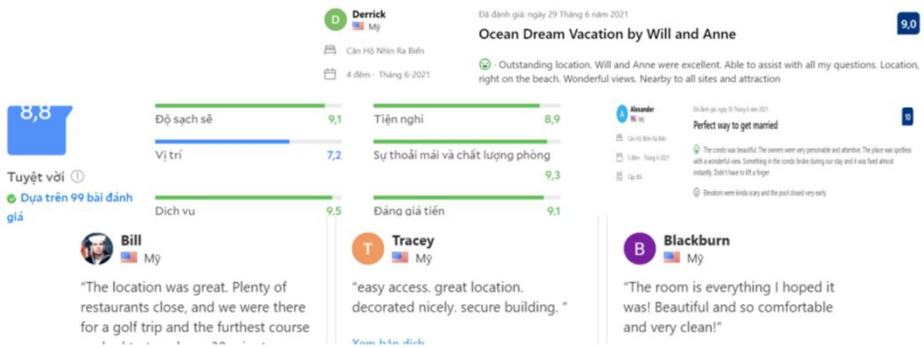

NHU CẦU PHÁT HIỆN TRI THỨC

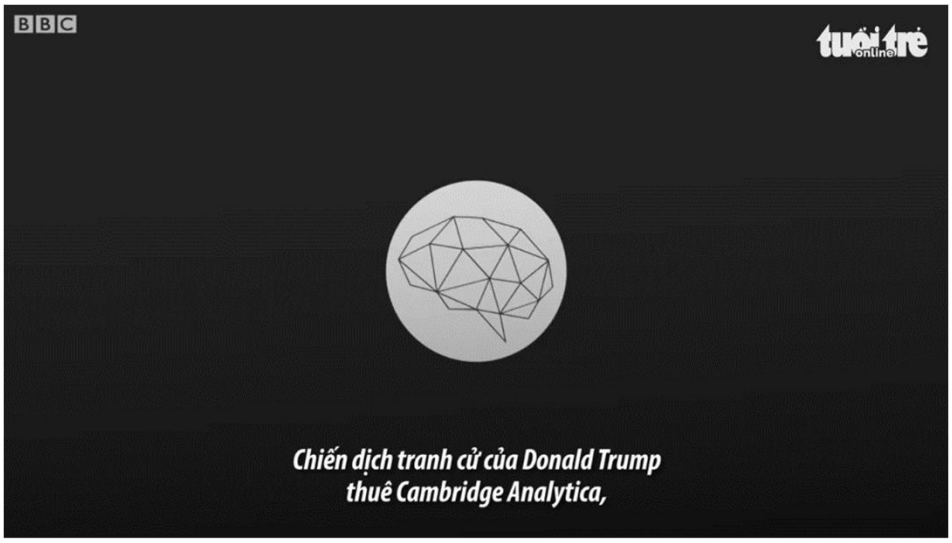

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NHU CẦU PHÁT HIỆN TRI THỨC

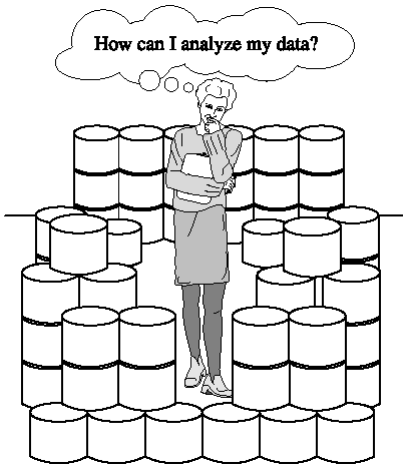

We are data rich, but information poor.

"Necessity is the mother of invention". - Plato

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NHU CẦU PHÁT HIỆN TRI THỨC

KHAI PHÁ DỮ LIỆU LÀ GÌ?

Hệ thống các phương pháp áp dụng cho các cơ sở dữ liệu lớn, phức tạp để loại bỏ các yếu tố ngẫu nhiên, khám phá các mẫu/mô hình, quy luật tiềm ẩn và các thông tin có giá trị trong dữ liệu.

Quá trình khám phá và phân tích khối lượng dữ liệu lớn để tìm ra các mô hình và quy tắc có ý nghĩa.

KHAI PHÁ DỮ LIỆU LÀ GÌ?

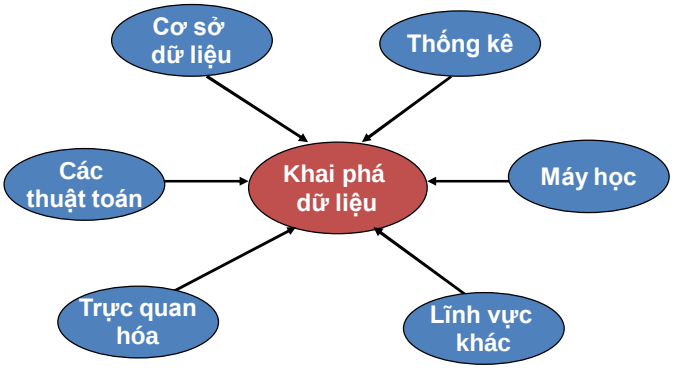

Khai phá dữ liệu là một lĩnh vực liên ngành

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

VAI TRÒ CỦA KHAI PHÁ DỮ LIỆU

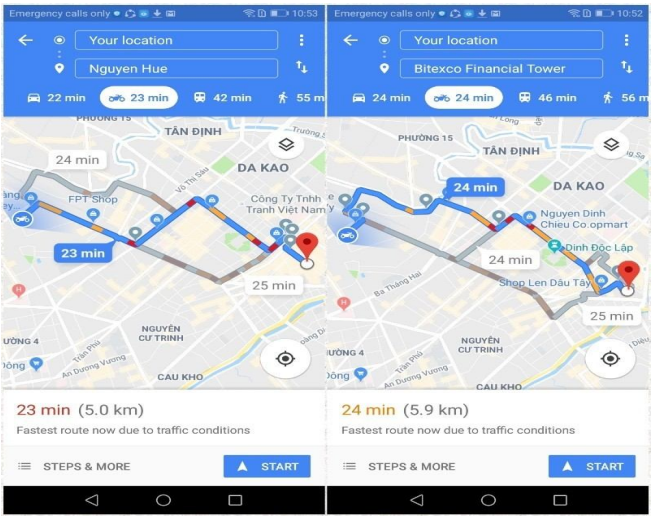

Tạo ra

giá trị

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

VAI TRÒ CỦA KHAI PHÁ DỮ LIỆU

Cầu thủ thứ 12 của Đức: Công nghệ và dữ liệu khổng lồ

13/06/2016 11:13 GMT+7

Để chuẩn bị cho các giải đấu, Đức hợp tác với hãng phần mềm SAP AG, sử dụng công cụ có tên Match Insights để phân tích dữ liệu từng cầu thủ.

Để chuẩn bị cho bất cứ trận đấu nào, đội tuyển Đức đều có một lượng dữ liệu khổng lồ trong tay.

Nhằm tìm kiếm lợi thế nhất định trước các đối thủ, đội tuyển Đức đã hợp tác với hãng phần mềm khổng lồ nước này là SAP AG để tạo ra một công cụ phân tích trận đấu đặc biệt, giúp thu thập, phân tích dữ liệu về hiệu suất hoạt động của các cầu thủ.

Dẫn đến

thành công

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

2. QUY TRÌNH KHAI PHÁ DỮ LIỆU

- ✓ Hệ thống khai phá dữ liệu
- ✓ Các loại dữ liệu được khai phá

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

QUY TRÌNH KHAI PHÁ DỮ LIỆU

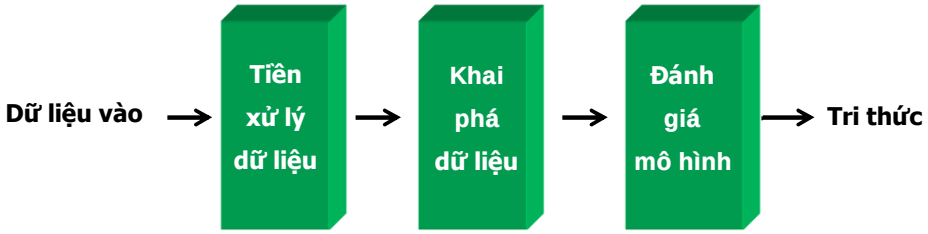

www.khoathongke.neu.edu.vn

KIẾN TRÚC HỆ THỐNG KHAI PHÁ DỮ LIỆU

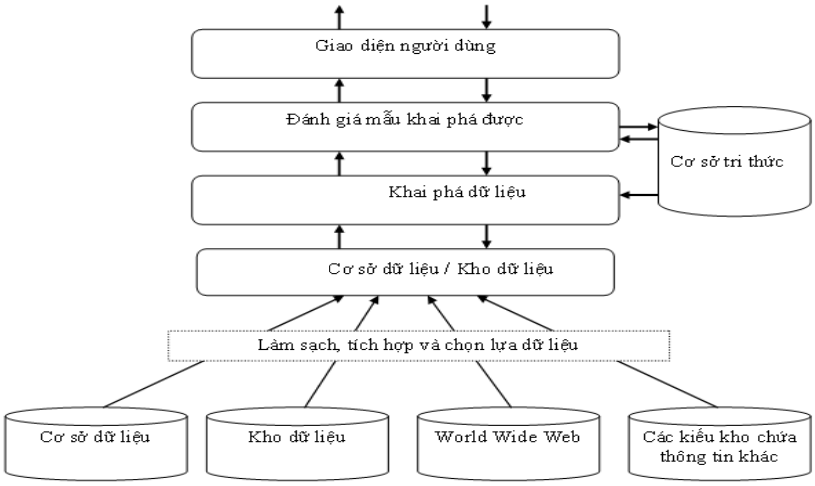

DỮ LIỆU ĐƯỢC KHAI PHÁ

DỮ LIỆU ĐƯỢC KHAI PHÁ

Dữ liệu có cấu trúc

Dữ liệu được tổ chức theo một cách thức đã được xác định trước, thường là trong các hàng và cột.

Dữ liệu phi cấu trúc

Bất kỳ dạng dữ liệu nào không phù hợp với các định dạng hoặc cơ sở dữ liệu có cấu trúc truyền thống

DỮ LIỆU ĐƯỢC KHAI PHÁ

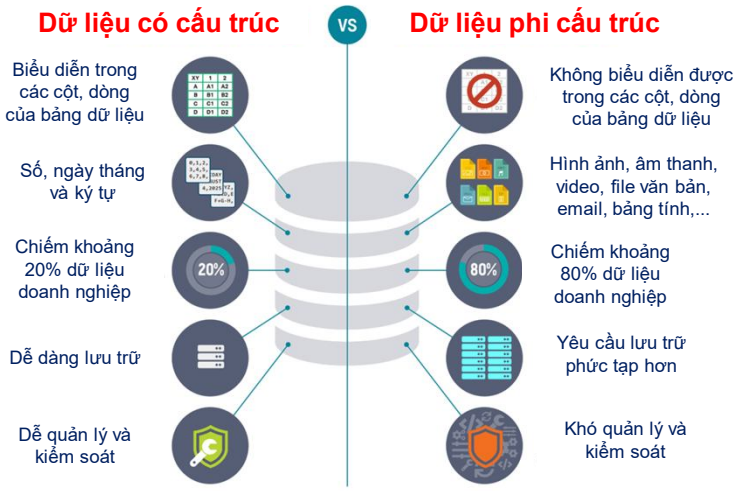

3. CÁC LOẠI KHAI PHÁ DỮ LIỆU

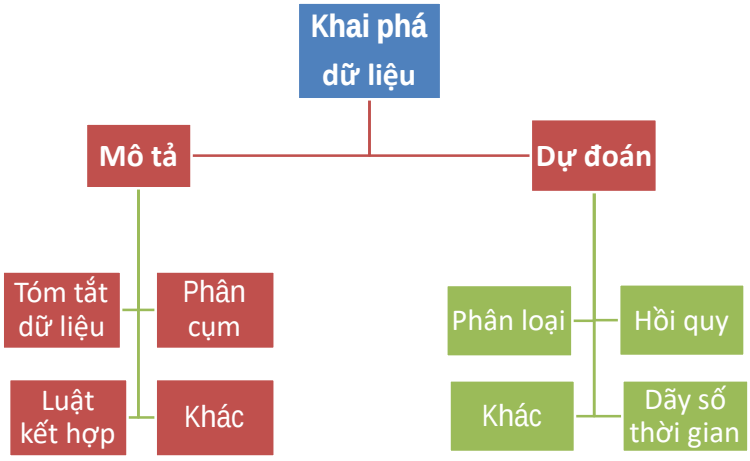

KHAI PHÁ DỮ LIỆU MÔ TẢ

- **Mô tả khái niệm: Đặc trưng và phân biệt**
  - Tìm các đặc trưng và tính chất của khái niệm
  - Tổng quát hóa, tóm tắt, phát hiện đặc trưng ràng buộc, tương phản
- **Quan hệ kết hợp**
  - Quan hệ kết hợp giữa các biến dữ liệu: Tương quan và nhân quả
  - Diaper vs Beer [50%, 75%]
  - Luật kết hợp: X→Y

KHAI PHÁ DỮ LIỆU MÔ TẢ

- **Phân cụm**
  - Nhóm dữ liệu thành các "lớp" mới
  - Cực đại tương tự nội bộ cụm
  - Cực tiểu tương tự giữa các cụm

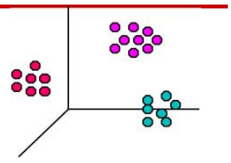

⇨ **Học không giám sát**

- **Ứng dụng**
  - Phân đoạn khách hàng
  - Chiến dịch marketing bao phủ
  - Sắp xếp và phân nhóm các tài liệu, bản ghi có liên quan
  - Nhóm các cổ phiếu biến động tương tự nhau trên thị trường
  - Giảm chiều dữ liệu

KHAI PHÁ DỮ LIỆU MÔ TẢ

- **Luật kết hợp**
  - Quan hệ kết hợp giữa các biến dữ liệu
  - Khai phá các liên kết tiềm ẩn

⇨ **Học không giám sát**

- **Ứng dụng**
  - Bày kệ hàng
  - Các chương trình khuyến mại
  - Hỗ trợ bán hàng trực tuyến
  - Chẩn đoán bệnh trong y tế

KHAI PHÁ DỮ LIỆU MÔ TẢ

- **Phân tích bất thường (đột biến)**

  Dữ liệu không tuân theo hành vi chung của toàn bộ dữ liệu

Học không giám sát

Học có giám sát

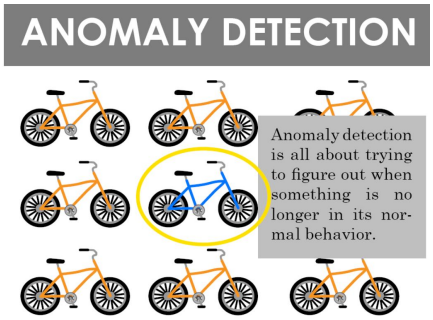

- **Ứng dụng**
  - Phát hiện gian lận
  - Xâm nhập mạng trái phép
  - Phân tích các sự kiện hiếm

KHAI PHÁ DỮ LIỆU DỰ ĐOÁN

- Xây dựng các mô hình (hàm) mô tả và phân biệt khái niệm cho các lớp hoặc khái niệm để dự đoán các giá trị chưa biết
- Các phương pháp:
  - *Hồi quy*
  - *Dãy số thời gian*
  - *Phân loại*

KHAI PHÁ DỮ LIỆU DỰ ĐOÁN

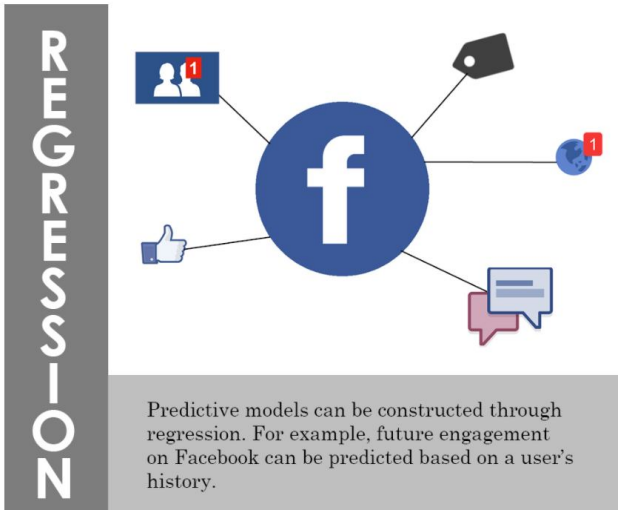

Học có giám sát

KHAI PHÁ DỮ LIỆU DỰ ĐOÁN

- **Phân loại (phân lớp) dữ liệu**
  - Dữ liệu đã có sẵn nhãn phân loại
  - Tìm ra điểm tương đồng giữa các nhãn
  - Mô tả/phát hiện lớp cho điểm dữ liệu mới

Học có giám sát

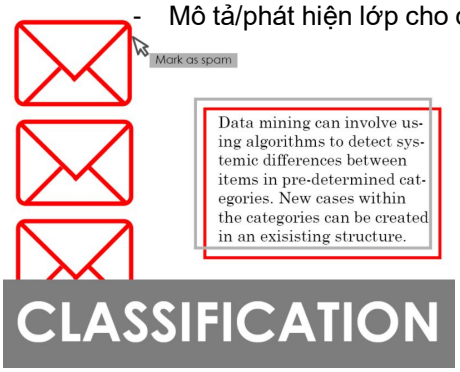

- **Ứng dụng**
  - Phân tích rủi ro, gian lận
  - Phân loại khách hàng
  - Phân loại trang web, email
  - Nhận dạng chữ viết, hình ảnh

CÁC PHƯƠNG PHÁP CHÍNH TRONG KHAI PHÁ DỮ LIỆU

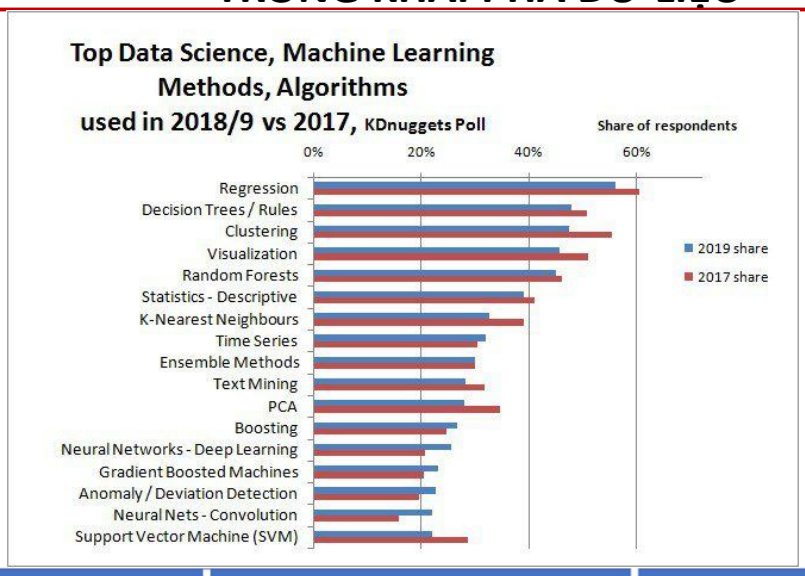

4. CÔNG CỤ KHAI PHÁ DỮ LIỆU