KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

TUẦN 7:

TIỀN XỬ LÝ DỮ LIỆU

www.khoathongke.neu.edu.vn

NỘI DUNG

1. Một số vấn đề cơ bản

2. Các kỹ thuật tiền xử lý dữ liệu

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

1. MỘT SỐ VẤN ĐỀ CƠ BẢN

- Tiền xử lý dữ liệu là gì?
- Yêu cầu của tiền xử lý dữ liệu
- Kỹ thuật tiền xử lý dữ liệu

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Tiền xử lý dữ liệu là gì?

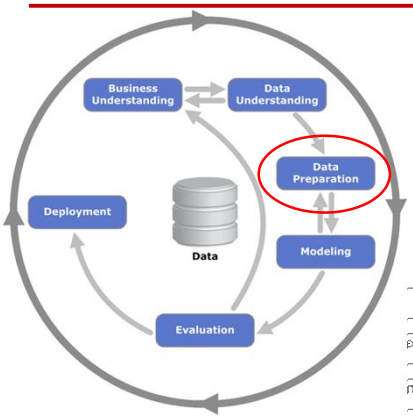

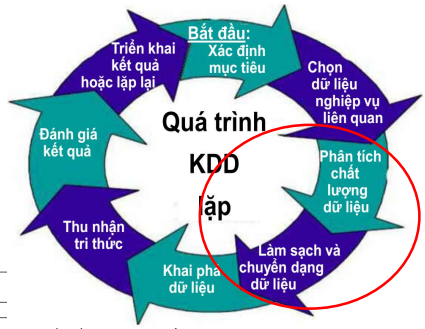

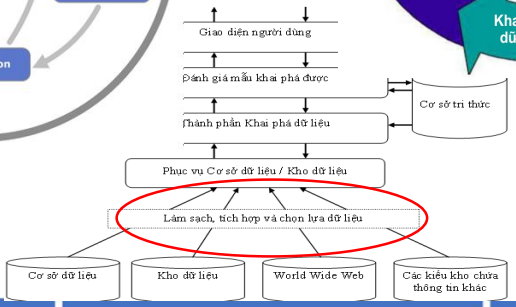

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Tiền xử lý dữ liệu là gì?

Quá trình xử lý dữ liệu thô để cải thiện chất lượng dữ liệu, từ đó cải thiện chất lượng của kết quả khai phá.

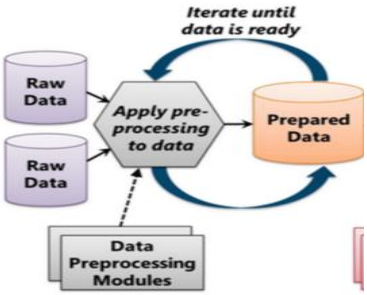

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Chất lượng dữ liệu

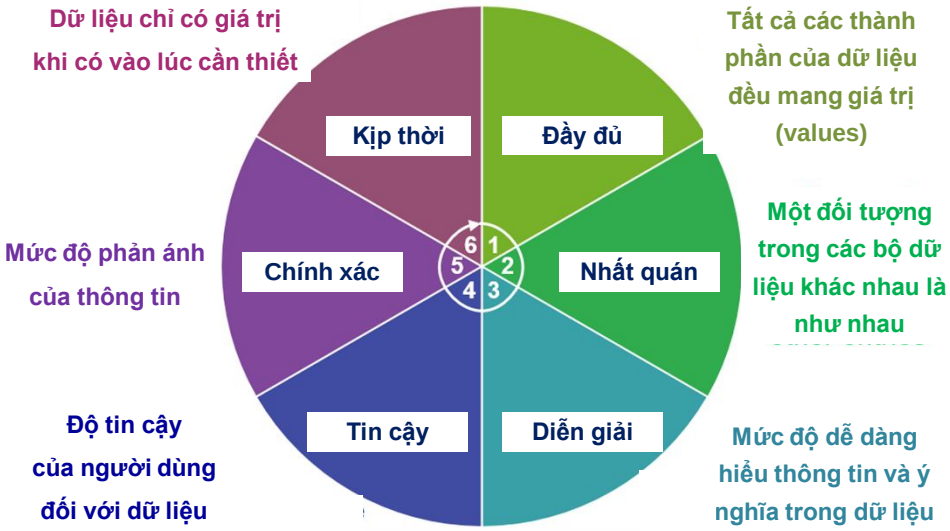

2. CÁC KỸ THUẬT TIỀN XỬ LÝ DỮ LIỆU

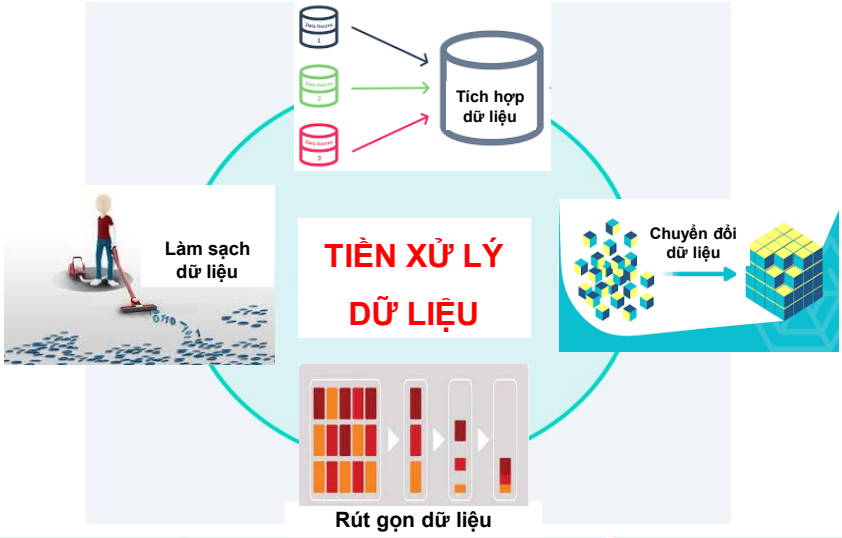

TÍCH HỢP DỮ LIỆU

Tích hợp dữ liệu là kết hợp dữ liệu từ nhiều nguồn khác nhau vào một tập dữ liệu duy nhất làm cho dữ liệu nhất quán trên nhiều nội dung và loại cấu trúc.

Quá trình này giúp giảm và tránh sự dư thừa cũng như không nhất quán trong dữ liệu, từ đó cải thiện độ chính xác và tốc độ của quá trình khai phá dữ liệu sau này

LÀM SẠCH DỮ LIỆU (Clean data)

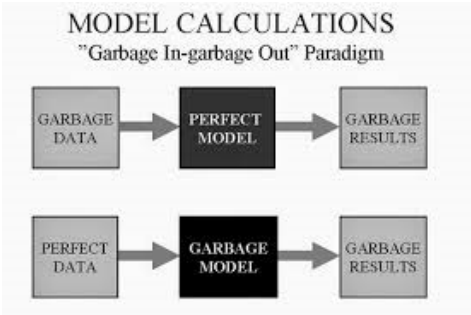

LÀM SẠCH DỮ LIỆU (Clean data)

- Xử lý dữ liệu khuyết thiếu
- Xử lý dữ liệu nhiễu
- Xác định các giá trị đột xuất

→ *tăng tối đa độ chính xác của dữ liệu, hạn chế tối đa việc loại bỏ dữ liệu*

→ *tạo điều kiện ứng dụng hiệu quả các công cụ phân tích, mang lại thông tin hữu ích và giá trị*

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Thế nào là dữ liệu khuyết thiếu?

- Không có giá trị tại một điểm dữ liệu nào đó

→ **Nguyên nhân?**

- Trường hợp phổ biến trong các bộ dữ liệu

	maxO3	T9	T12	T15	Ne9	Ne12	Ne15	Vx9	Vx12	Vx15	maxO3v	WindDirection
20010601	87	15.6	18.5	NA	4	4	8	0.6946	-1.7101	-0.6946	84	North
20010602	82	NA	NA	NA	5	5	7	-4.3301	-4	-3	87	North
20010603	92	15.3	17.6	19.5	2	NA	NA	2.9544	NA	0.5209	82	East
20010604	114	16.2	19.7	NA	1	1	0	NA	0.3473	-0.1736	92	North
20010605	94	NA	20.5	20.4	NA	NA	NA	-0.5	-2.9544	-4.3301	114	West
20010606	80	17.7	19.8	18.3	6	NA	7	-5.6382	-5	-6	94	West
...												
...												
20010924	76	13.3	17.7	17.7	NA	NA	NA	-0.9397	-0.766	-0.5	NA	West
20010925	NA	13.3	NA	17.8	3	5	NA	0	-1	-1.2856	76	South
20010927	77	16.2	20.8	NA	NA	NA	NA	-0.6946	-2	NA	71	South
20010928	99	NA	NA	NA	NA	NA	NA	1.5	0.8682	0.8682	NA	South
20010929	83	NA	NA	NA	NA	5	3	-4	-3.7588	-4	99	West
20010930	70	15.7	18.6	20.7	7	NA	7	NA	-1.0419	-4	83	South

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Hậu quả khi có dữ liệu khuyết thiếu

- Giảm kích thước mẫu và mất dữ liệu
- Tạo sự chênh lệch trong dữ liệu
- Nếu dữ liệu khuyết thiếu không ngẫu nhiên → sai lệch kết quả nghiên cứu

Các trường hợp khuyết dữ liệu

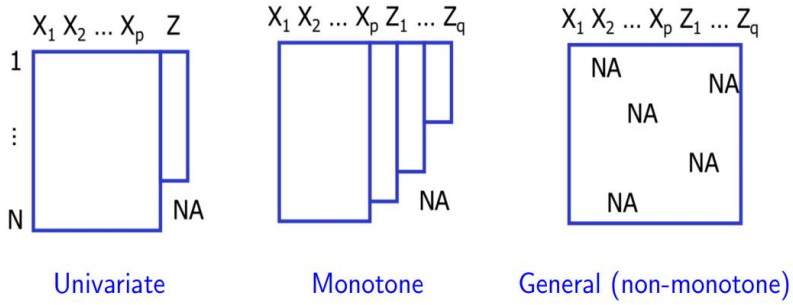

Univariate | Monotone | General (non-monotone)

Dữ liệu khuyết chỉ thuộc 1 biến

Dữ liệu khuyết có ở nhiều biến và số lượng giảm dần

Dữ liệu khuyết có khắp bộ dữ liệu

Cơ chế khuyết thiếu dữ liệu

Dữ liệu khuyết thiếu

hoàn toàn ngẫu nhiên (MCAR)

(Missing Completely At Random)

- Giá trị khuyết phân phối ngẫu nhiên
- Khả năng mỗi quan sát có khả năng bị khuyết như nhau
- Không liên quan đến bất kỳ biến nào trong tập dữ liệu

Complete data	
Age	IQ score
25	133
26	121
29	91
30	105
30	110
31	98
44	118
46	93
48	141
51	104
51	116
54	97

Incomplete data	
Age	IQ score
25	
26	121
29	91
30	
30	110
31	
44	118
46	93
48	
51	
51	116
54	

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Cơ chế khuyết thiếu dữ liệu

Dữ liệu khuyết thiếu ngẫu nhiên

(Missing At Random – MAR)

- Giá trị khuyết phân phối không ngẫu nhiên ở tất cả quan sát
- Khả năng mỗi quan sát có khả năng bị khuyết là khác nhau
- Có mối liên hệ với biến khác nhưng không có liên hệ với biến chứa giá trị khuyết thiếu

Complete data	
Age	IQ score
25	133
26	121
29	91
30	105
30	110
31	98
44	118
46	93
48	141
51	104
51	116
54	97

Incomplete data	
Age	IQ score
25	
26	
29	
30	
30	
31	
44	118
46	93
48	141
51	104
51	116
54	97

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Cơ chế khuyết thiếu dữ liệu

Dữ liệu khuyết thiếu không ngẫu nhiên (MNAR)

(Missing Not At Random)

- Phụ thuộc hoàn toàn vào chính biến bị missing, không liên quan tới các biến khác
- Nguyên nhân do chủ đích của người cung cấp thông tin
- Không có cơ sở để dự đoán

Complete data	
Age	IQ score
25	133
26	121
29	91
30	105
30	110
31	98
44	118
46	93
48	141
51	104
51	116
54	97

Incomplete data	
Age	IQ score
25	133
26	121
29	
30	
30	110
31	
44	118
46	
48	141
51	
51	116
54	

So sánh MCAR, MAR, MNAR

	MCAR	MAR	MNAR
Phân phối của dữ liệu khuyết thiếu	Ngẫu nhiên	Phi ngẫu nhiên	Phi ngẫu nhiên
Khả năng khuyết thiếu của quan sát	Như nhau	Khác nhau	Khác nhau
Cơ chế, nguyên nhân	Không liên quan tới bất kỳ biến nào	Liên quan tới biến khác nhưng không liên quan tới biến chứa giá trị khuyết	Chỉ liên quan tới biến chứa giá trị khuyết
Ảnh hưởng nếu loại quan sát	Không/ít làm sai lệch kết quả	Sai lệch kết quả	Sai lệch kết quả
Khả năng dự báo giá trị khuyết	Không	Có	Không
Phương pháp xử lý	- Loại bỏ - Thay thế	- Thay thế - Phương pháp chuyên sâu	Thu thập thêm dữ liệu và thông tin

So sánh MAR, MCAR, MNAR

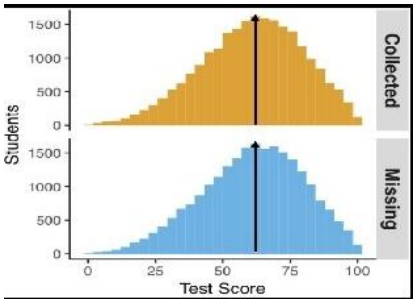

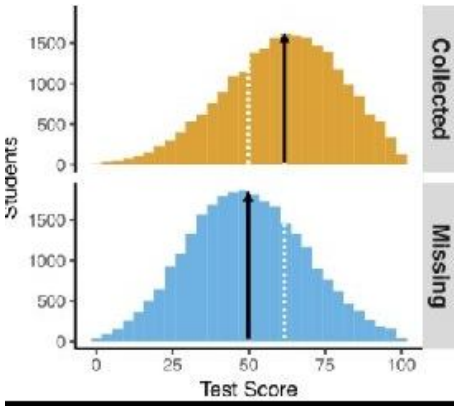

Xác định cơ chế gây khuyết dữ liệu

- MCAR và MAR:
  - *Vẽ đồ thị, xác định phân bố*
  - *Kiểm định t-test, Little's*

Thực hành R

- Kiểm tra dữ liệu khuyết thiếu:

```
anyNA(đối tượng)
is.na(đối tượng)          is.na(đối tượng$cột)
```

- Đếm số giá trị khuyết thiếu:

```
sum(is.na(đối tượng))
```

hoặc: `table(is.na(đối tượng))`

- Đếm số quan sát có giá trị khuyết thiếu theo cột:

```
colSums(is.na(đối tượng))
```

hoặc: `sum(is.na(đối tượng$cột))`

- Đếm số quan sát có dữ liệu trống theo dòng:

```
rowSums(is.na(đối tượng))
```

Thực hành R

Mô tả dữ liệu khuyết thiếu bằng đồ thị:

- Sử dụng package **visdat**
  - `vis_dat(đối tượng)`
  - `vis_miss(đối tượng)`

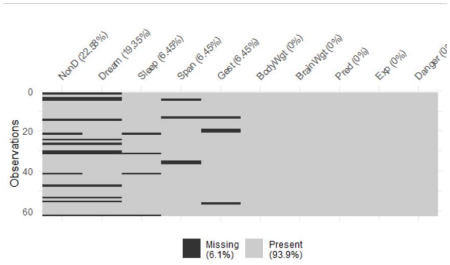

Đồ thị tương tác:

`ggplotly(vis_dat(đối tượng))`

Thực hành R

Mô tả dữ liệu khuyết thiếu bằng đồ thị:

- Sử dụng package **VIM**

`aggr(đối tượng, các tùy chọn)`

`summary(aggr(đối tượng, các tùy chọn)`

Các tùy chọn:

- Hiện số cạnh đồ thị Combinations: `numbers = TRUE`
- Hiện số lượng: `prop = FALSE`
- Sắp xếp biến theo số lượng missing: `sortVars = TRUE`
- Sắp xếp sự kết hợp quan sát và biến theo tần số /tần suất xuất hiện: `sortCombs = TRUE`

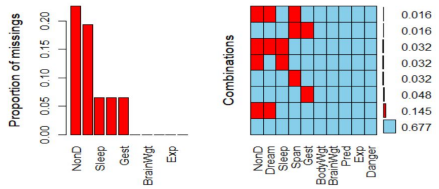

Thực hành R

Mô tả dữ liệu khuyết thiếu bằng đồ thị:

- Sử dụng package **VIM**

```
matrixplot(đối tượng)
```

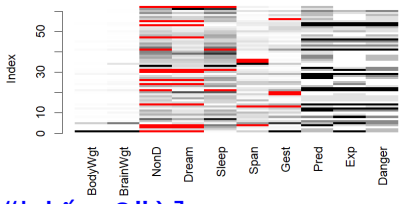


```
marginplot(đối tượng[c("biến 1","biến 2")],
                    các tùy chọn)
```

Các tùy chọn:

- Hiển thị số:
  `numbers = TRUE`
- Size của số:
  `cex.numbers = 0.5`

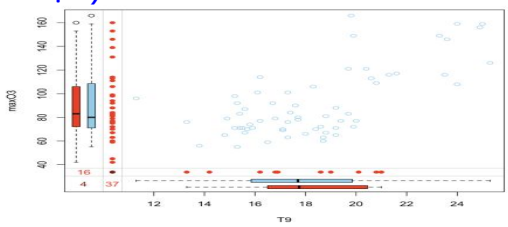

Thực hành R

Xác định cơ chế gây khuyết dữ liệu: package **naniar**

Cặp giả thuyết:

H_0: không có mối liên hệ giữa giá trị khuyết với các biến còn lại (MCAR)

H_1: có mối liên hệ giữa giá trị khuyết với các biến còn lại (MAR)

Kiểm định Little's với thống kê Chi-square:

```
mcar_test(đối tượng)
```

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Xử lý dữ liệu khuyết thiếu

- Xóa dữ liệu khuyết thiếu
- Điền giá trị khuyết thiếu:

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Xóa dữ liệu khuyết thiếu

Xóa dữ liệu khuyết thiếu

- **Xóa cả dòng (listwise)**
- **Xóa cả cột**

- Ưu điểm: *Đơn giản*
- Hạn chế:
  - *Mất thông tin khi số lượng giá trị khuyết thiếu lớn*
  - *Tăng phương sai của biến*
  - *Tăng độ chệch khi khuyết dữ liệu có hệ thống*

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Xóa dữ liệu khuyết thiếu

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	?	Married	?	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	?	Divorced	?	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	?	?	75K	No
10	No	Single	90K	Yes

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	?	Married	?	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	?	Divorced	?	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	?	?	75K	No
10	No	Single	90K	Yes

⇨

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
10	No	Single	90K	Yes

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	?	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	?	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	?	Married	75K	No
10	No	Single	90K	Yes

⇨

Tid		Marital Status	Taxable Income	Cheat
1		Single	125K	No
2		Married	100K	No
3		Single	70K	No
4		Married	120K	No
5		Divorced	95K	Yes
6		Married	60K	No
7		Divorced	220K	No
8		Single	85K	Yes
9		Married	75K	No
10		Single	90K	Yes

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Xoá dữ liệu khuyết thiếu

- Xóa các quan sát có giá trị khuyết thiếu theo cột: sử dụng package **tidyr**

```
drop_na(đối tượng,tên cột)
```

- Xóa toàn bộ quan sát có giá trị khuyết thiếu:

```
na.omit(đối tượng)
```

hoặc: `drop_na(đối tượng)`

- Xóa toàn bộ cột có giá trị khuyết thiếu:

```
đối tượng[colSums(is.na(đối tượng)) == 0]
```

Phương pháp điền giá trị khuyết thiếu

- Điền đơn khả năng *(Single imputation)*
  - ✓ *Mỗi giá trị thay thế được tính trên bộ dữ liệu chung, không chia nhỏ*
  - ✓ *Mỗi giá trị khuyết được thay thế 1 lần với chỉ 1 giá trị*
  - → Áp dụng: tỷ lệ dữ liệu khuyết thấp, số quan sát không nhiều

Phương pháp điền giá trị khuyết thiếu

- Điền đa khả năng *(Multiple imputation)*
  - ✓ *Mỗi giá trị khuyết được thay thế nhiều lần với nhiều giá trị khác nhau → tổ hợp thành giá trị đại diện*
  - ✓ *Sử dụng tất cả các dữ liệu trong bộ dữ liệu*

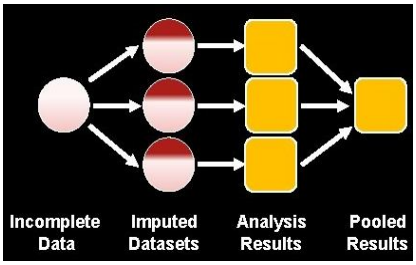

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Thay thế bằng một số giá trị đặc biệt

- **Các giá trị**:
  - Trung bình, trung vị, mốt của tập dữ liệu hoặc tập con dữ liệu
  - Một giá trị cố định (0)

Tid	Refund	Marital Status	Taxable Income	Cheat
1	?	Single	125K	No
2	No	?	?	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	?	Yes
6	No	?	60K	No
7	Yes	Divorced	220K	No
8	?	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes
	No	**Single**	**105K**	

⇨

Tid	Refund	Marital Status	Taxable Income	Cheat
1	**No**	Single	125K	No
2	No	**Single**	**105K**	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	**105K**	Yes
6	No	**Single**	60K	No
7	Yes	Divorced	220K	No
8	**No**	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Thay thế bằng một số giá trị đặc biệt

- **Ưu điểm:** bảo toàn giá trị trung bình/trung vị/mốt
- **Hạn chế:**
  - ➢ Làm giảm phương sai, độ lệch chuẩn

    → khoảng tin cậy bị thu hẹp
  - ➢ Làm sai lệch mối liên hệ tương quan giữa các biến
  - ➢ "Tệ nhất" trong các phương pháp

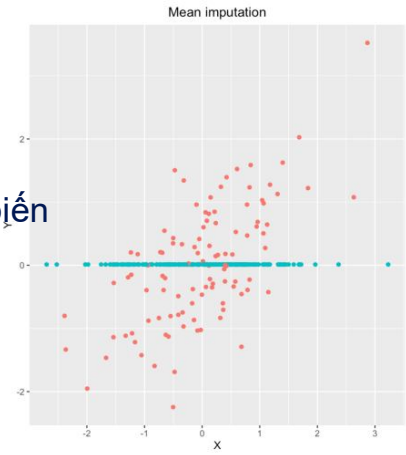

Thay thế bằng giá trị ngẫu nhiên

- **Hot-deck:**
  - *Chọn ngẫu nhiên giá trị của quan sát khác trong tổng thể để thay thế*
  - *Chọn ngẫu nhiên giá trị của quan sát khác trong mẫu gồm các quan sát tương đồng lấy từ tổng thể để thay thế*
  - *Chọn ngẫu nhiên giá trị của quan sát có điểm dữ liệu gần nhau*

Thực hành R: data sleep

- **Thay thế bằng hằng số:**
- ***Cách 1:***

```
mutate(đối tượng, biến khuyết = case_when
      (is.na(biến) ~ (mean(biến, na.rm=TRUE)),
          TRUE     ~ tên biến))
```

Trong đó, có thể thay mean bằng median, mode hay một giá trị bất kỳ

- ***Cách 2:*** sử dụng package **mice**

```
complete(mice(đối tượng, method = "mean")
```

Thực hành R

- **Thay thế bằng giá trị ngẫu nhiên:**
  - ***Cách 1:*** sử dụng package **mice**

```
complete(mice(đối tượng, method = "sample")
```

  - ***Cách 2:*** sử dụng package **VIM**

```
hotdeck(đối tượng)
```


Sử dụng phân tích hồi quy để thay thế

- **Ưu điểm:** Không phá vỡ mối liên hệ tương quan giữa các biến
- **Hạn chế:**
  - ➢ Làm giảm phương sai
  - ➢ Làm tăng hệ số tương quan giữa các biến

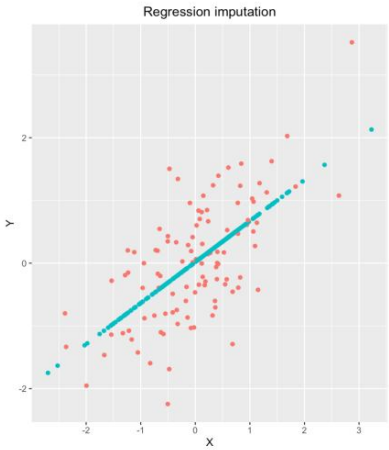

Sử dụng phân tích hồi quy để thay thế

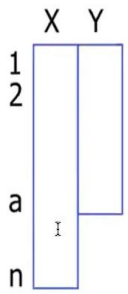

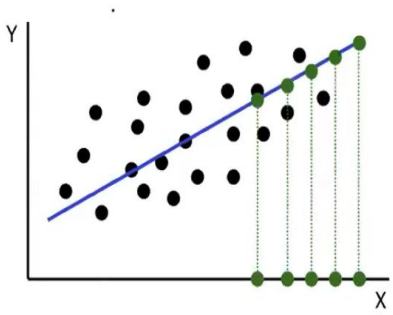

Dự đoán dựa vào mô hình hồi quy:

$$\hat{y}_i = \widehat{\beta_0} + \widehat{\beta_1} X_i$$

Sử dụng phân tích hồi quy ngẫu nhiên để thay thế

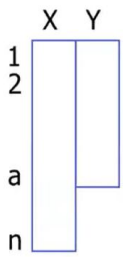

Stochastic Regression

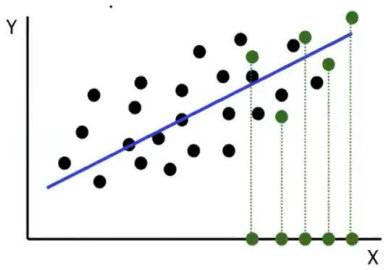

Dự đoán dựa vào mô hình hồi quy:

$$\hat{y}_i = \widehat{\beta_0} + \widehat{\beta_1} X_i + \epsilon_i \text{ với } \epsilon_i \sim N(0, \hat{\sigma}^2)$$

Sử dụng phân tích hồi quy ngẫu nhiên để thay thế

- **Ưu điểm:**
  - Không phá vỡ mối liên hệ tương quan giữa các biến
  - Bảo toàn phân phối của dữ liệu
- **Hạn chế:**
  - Giá trị dự đoán vượt ra ngoài khoảng giá trị có thể có
  - Hạn chế khi áp dụng đối với dữ liệu có phương sai sai số thay đổi

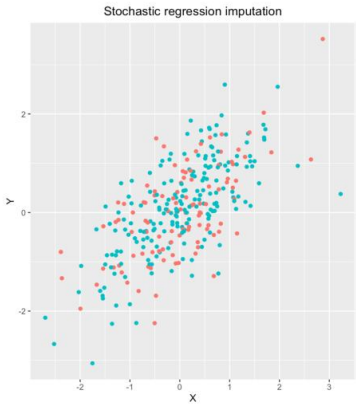

Thay thế giá trị khuyết thiếu

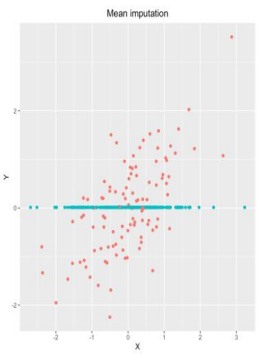

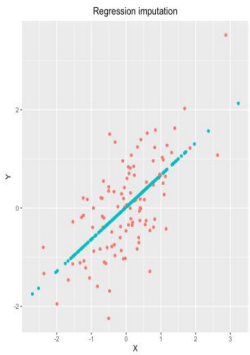

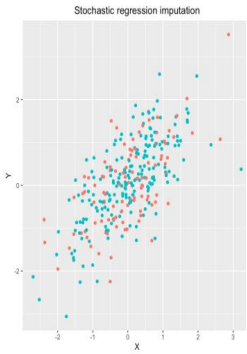

$\sigma_Y = 1$ $\hat{\sigma}_Y = 0.58$ $\hat{\sigma}_Y = 0.81$ $\hat{\sigma}_Y = 0.98$

$\rho = 0.7$ $\hat{\rho} = 0.43$ $\hat{\rho} = 0.86$ $\hat{\rho} = 0.69$

Thực hành R

- Xây dựng phương trình hồi quy tuyến tính đơn:

```
đối tượng mới <- lm(y ~ x, data = đối tượng)
summary(đối tượng mới)
```

- Điền giá trị khuyết thiếu từ phương trình hồi quy:

```
đối tượng %>%
mutate(biến khuyết = case_when
 (is.na(tên cột) ~ predict(đối tượng mới,.),
TRUE ~ tên cột))
```


Thực hành R

- Điền giá trị khuyết thiếu bằng package **mice**:
  - Hồi quy thông thường

```
complete(mice(đối tượng,
                method = "norm.predict"))
```

  - Hồi quy ngẫu nhiên (stochastic regression):

```
complete(mice(đối tượng,
          method = "norm.nob"))
```

Thay thế dựa vào phân tích xác suất

Sử dụng cây quyết định, rừng ngẫu nhiên,...:

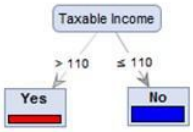

Tid	Refund	Marital Status	Taxable Income	Cheat
1	?	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	?	Divorced	95K	Yes
6	?	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Thực hành R

- Điền giá trị khuyết thiếu bằng package **mice**:
  - Cây quyết định

```
complete(mice(đối tượng, method = “cart”))
```

  - Rừng ngẫu nhiên

```
complete(mice(đối tượng, method = “rf”))
```

LÀM SẠCH DỮ LIỆU

DỮ LIỆU NHIỄU
VÀ DỮ LIỆU ĐỘT XUẤT

Dữ liệu nhiễu và dữ liệu đột xuất

- Nghiên cứu các con vật màu trắng

  → **Dữ liệu nhiễu**

- Nghiên cứu một đàn cừu

  → **Dữ liệu đột xuất**

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Dữ liệu nhiễu và dữ liệu đột xuất

	Dữ liệu nhiễu	Dữ liệu đột xuất
Bản chất	Không phải giá trị thực tế	Có thể là giá trị thực tế
Mong muốn xuất hiện	Không	Cần quan tâm
Vai trò	Không ứng dụng trong phân tích	Có thể sử dụng phân tích các trường hợp bất thường
Ảnh hưởng	Làm sai lệch kết quả mô hình (overfit)	Không làm sai lệch nhưng thường tạo lỗi
Phân phối	Thường theo phân phối của dữ liệu	Không theo phân phối của dữ liệu

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Dữ liệu nhiễu và dữ liệu đột xuất

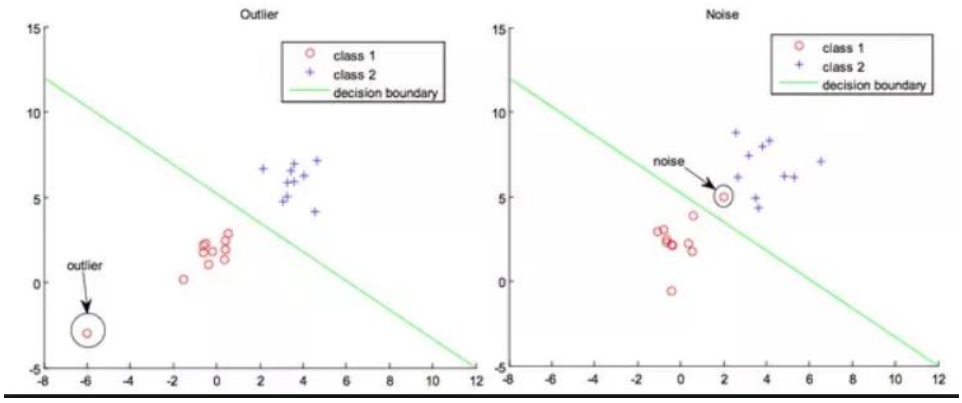

DỮ LIỆU NHIỄU

DỮ LIỆU NHIỄU

- Dữ liệu không mong muốn, bị sai lệch, không có ý nghĩa trong tập dữ liệu
- Tăng dung lượng lưu trữ một cách không cần thiết
- Ảnh hưởng, làm sai lệch đến kết quả phân tích

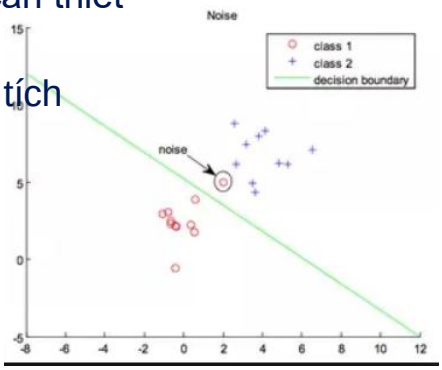

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NGUYÊN NHÂN XUẤT HIỆN DỮ LIỆU NHIỄU

- Công cụ thu thập dữ liệu bị lỗi
- Lỗi khi nhập/truyền liệu
- Không nhất quán trong việc đặt tên, mã hóa

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

TÁC DỤNG CỦA XỬ LÝ DỮ LIỆU NHIỄU

- Các thuật toán chạy nhanh hơn
- Mô hình đỡ phức tạp và dễ hiểu hơn
- Cải thiện độ chính xác của mô hình

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

NHẬN BIẾT VÀ GIẢM THIỂU NHIỄU

Nhiễu ngẫu nhiên Quan sát nhiễu Đặc điểm (biến) nhiễu	• Phân tổ • Phân cụm • Kiểm chứng chéo • Lọc biến • ...

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

DỮ LIỆU ĐỘT XUẤT

(outlier, anomaly)

THẾ NÀO LÀ DỮ LIỆU ĐỘT XUẤT?

- Là những điểm dữ liệu có giá trị khác xa so với phần còn lại của dữ liệu

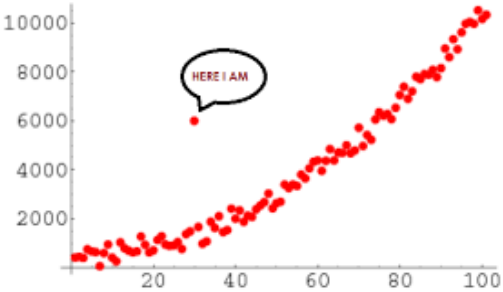

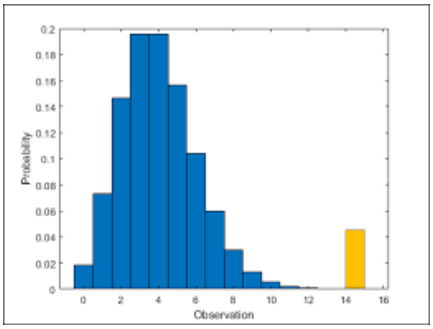

ẢNH HƯỞNG CỦA DỮ LIỆU ĐỘT XUẤT

- Làm tăng phương sai và giảm hiệu quả của phân tích
- Nếu dữ liệu đột xuất phân phối không ngẫu nhiên → giảm tính phân phối chuẩn của các quan sát
- Mô hình bị chệch

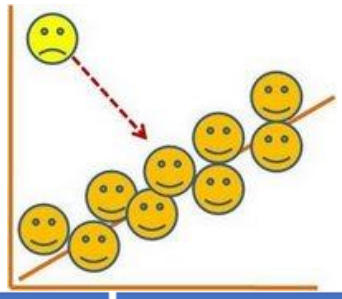

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

PHÂN LOẠI DỮ LIỆU ĐỘT XUẤT

Dựa vào mối liên hệ giữa các biến:

- **Dữ liệu đột xuất đơn biến:** sự xuất hiện dữ liệu đột xuất của một biến chỉ phụ thuộc vào bản thân biến đó
- **Dữ liệu đột xuất đa biến:** sự xuất hiện dữ liệu đột xuất của một biến phụ thuộc mối liên hệ giữa các biến

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

CÁCH XÁC ĐỊNH DỮ LIỆU ĐỘT XUẤT

- Dựa vào phân phối của dữ liệu:
  - *Z-score*
  - *Boxplot*
  - *Histogram*
  - *Các kiểm định: Grubbs, Dixon, Rosner,…*

Các phương pháp thống kê

- **Z-score**

$$z = \frac{x_i - \bar{\mu}}{\sigma}$$

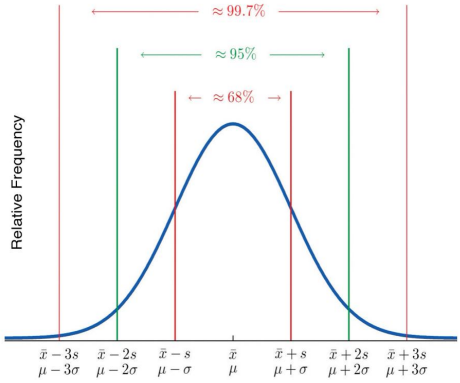

- **Hampel filter**

(Me – 3MAD; Me + 3MAD)

Trong đó:

MAD = Me($|x_i$ – Me(x_i)|)

Các phương pháp thống kê

- Boxplot
- Histogram

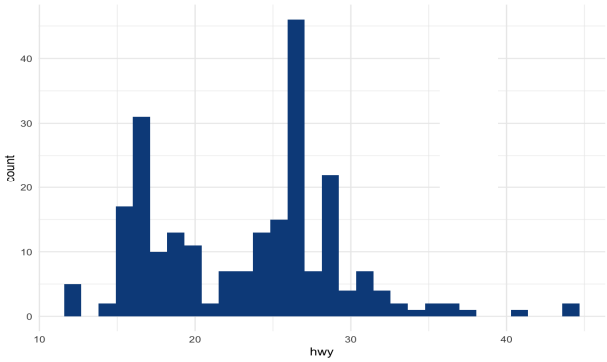

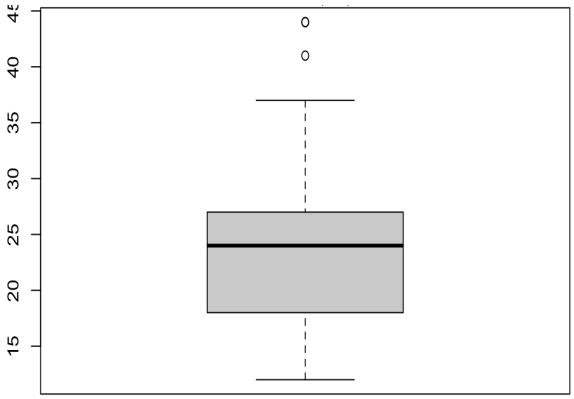

Các phương pháp thống kê

- Kiểm định từng giá trị riêng biệt
  - **Kiểm định Grubbs:** *không phù hợp với mẫu nhỏ, đặc biệt < 6*

$$G = \frac{\max|Y_i - \bar{Y}|}{S}$$

  - **Kiểm định Dixon:** *phù hợp với mẫu nhỏ (< 25-30)*

$$Q = \frac{\text{gap}}{\text{range}}$$

Các phương pháp thống kê

- Kiểm định các giá trị cùng một lúc
  - **Kiểm định Rosner:** *phù hợp với mẫu lớn (>20-25), phát triển trên ý tưởng của kiểm định Grubbs*

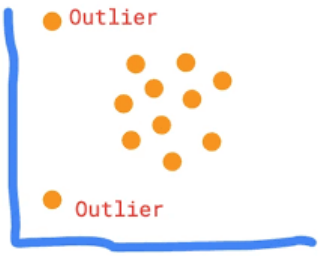

Thực hành R

- Dựa vào Z-score
  - *Xác định 2 giới hạn*

```
LB <- mean(đối tượng$biến) – 3*sd(đối tượng $biến)
UB <- mean(đối tượng $biến) + 3*sd(đối tượng $biến)
```

  - *Xác định giá trị đột xuất (nếu có)*

```
filter (đối tượng, biến < LB | biến > UB)
```


Thực hành R

- Hampel filter
  - *Xác định 2 giới hạn*

```
LB <- median(đối tượng $biến) – 3*mad(đối tượng $biến)
UB <- median(đối tượng $biến) + 3*mad(đối tượng $biến)
```

  - *Xác định giá trị đột xuất (nếu có)*

```
filter (đối tượng, biến < LB | biến > UB)]
```

Thực hành R

- Dựa vào đồ thị
  - *Histogram* `hist(đối tượng$biến)`
  - *Boxplot* `đối tượng mới <- boxplot(đối tượng $biến)`

    Tìm giá trị đột xuất: `đối tượng mới $ out`

Thực hành R

- Các kiểm định: sử dụng package **outliers**
  - *Kiểm định Grubbs:* `grubbs.test(đối tượng$biến, các tùy chọn)`
  - *Kiểm định Dixon:* `dixon.test(đối tượng$biến, các tùy chọn)`

Các tùy chọn:

- `type = 10/11:` Xác định 1 giá trị đột xuất ở 1 phía/ cả 2 phía
- `opposite = F/T`: xác định giá trị đột xuất là max/min
- `two.sided = F/T:` kiểm định 1 phía/2 phía

Thực hành R

- Các kiểm định: sử dụng package **EnvStats**
  - *Kiểm định Rosner*

```
rosnerTest(đối tượng, các tùy chọn)
```

Các tùy chọn:

- `k = 3:` số giá trị đột xuất nghi ngờ
- `alpha = 0.05:` mức ý nghĩa alpha

CÁCH XỬ LÝ DỮ LIỆU ĐỘT XUẤT

- Xóa quan sát (trong trường hợp giá trị đột xuất là nhiễu)
- Thay thế bằng giá trị khác: trung bình/trung vị/mốt hoặc multiple imputation (*tương tự giá trị khuyết thiếu*)
- Thay thế bằng giá trị biên
- Dự đoán dựa vào các thông tin đã có (*tương tự giá trị khuyết thiếu*)