KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

PHƯƠNG PHÁP PHÂN CỤM (CLUSTER ANALYSIS)

www.khoathongke.neu.edu.vn

1

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Nội dung

- Ý tưởng phân cụm
- Đo lường khoảng cách
- Phương pháp phân cụm
- Các bước thực hiện phân tích cụm

www.khoathongke.neu.edu.vn

2

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phân cụm

	Học có giám sát	Học không giám sát
Biến rời rạc	Phân loại	Phân cụm
Biến liên tục	Hồi quy	Giảm chiều

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phân tích cụm

- **Phân tích cụm (phân cụm)** là quá trình phân chia một tập các đối tượng dữ liệu (hay các quan sát) vào các tập hợp con. Mỗi tập hợp con này là một **cụm**, sao cho các đối tượng trong cùng một cụm là tương đồng với nhau, và bất tương đồng với các đối tượng trong các cụm khác.

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phân cụm

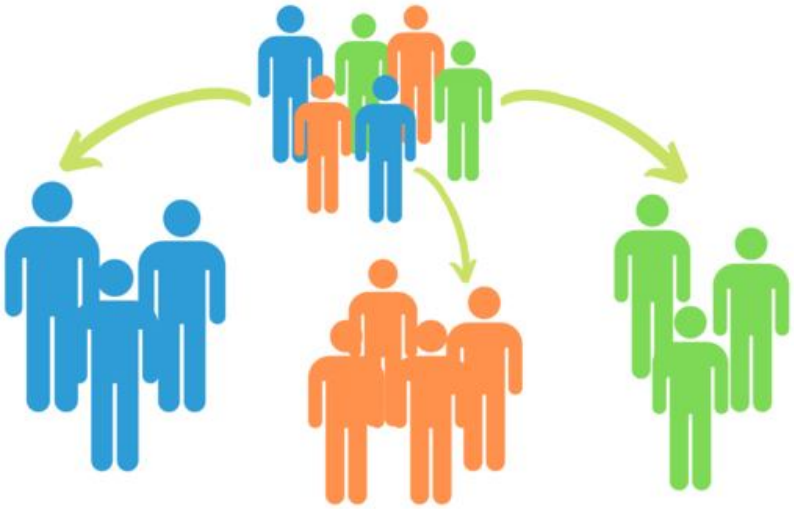

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Ý tưởng phân tích cụm

- Tìm sự tương đồng giữa các đối tượng (được xác định bằng các đặc điểm (biến) khác nhau)
- Phương pháp phân cụm giúp chúng ta mô tả (khai phá) dữ liệu

Ứng dụng phân cụm

- Phân nhóm khách hàng
- Đánh giá lựa chọn dự án
- Phân nhóm sản phẩm
- Chăm sóc sức khỏe dân cư
- Công nghệ thông tin
- ….

Dữ liệu

How many clusters?

Đo lường khoảng cách

Tên	Chiều cao	Cân nặng
Mary	128	54
Jack	158	86
Julie	177	82
Mark	131	59

- Tìm ra sự tương đồng giữa các đối tượng
- Tìm khoảng cách giữa các đối tượng

Đo lường khoảng cách

```
name=c("Mary", "Jack", "Julie", "Mark")
height=c(128, 158, 177, 131)
weight=c(54, 86, 82, 59)
plot(height, weight, main=" ", xlab="height", ylab="weight", pch=20, cl="blue")
text(height, weight, name, cex=1, col="red")
```

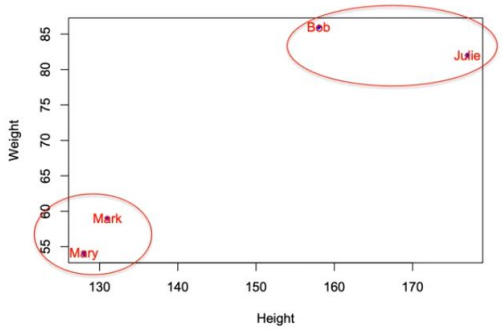

Đo lường khoảng cách

Tên	Chiều cao	Cân nặng
Mary	128	54
Jack	158	86
Julie	177	82
Mark	131	59

- Khoảng cách giữa Mary với Jack?

Chiều cao=|128-158|=30

Cân nặng =|54-86|=32

Tổng khoảng cách =62

- Khoảng cách giữa Mary với Mark

Chiều cao=|128-131|=3

Cân nặng =|54-82|=28

Tổng khoảng cách =31

Đo lường khoảng cách

Tên	Chiều cao	Cân nặng	Z (chiều cao)	Z (cân nặng)
Mary	128	54	-0,880	-1,010
Jack	158	86	0,408	0,979
Julie	177	82	1,223	0,730
Mark	131	59	-0,751	-0,699
Trung bình	148,5	70,25		
Độ lệch chuẩn	23,3	16,1		

- $z = \frac{x_i - \bar{x}}{s}$

```
z.height=scale(height)
z.weight=scale(weight)
```

Đo lường khoảng cách

Tên	Chiều cao	Cân nặng	Z (chiều cao)	Z (cân nặng)
Mary	128	54	-0,88	-1,01
Jack	158	86	0,41	0,98
Julie	177	82	1,22	0,73
Mark	131	59	-0,75	-0,70
Trung bình	148,5	70,25		
Độ lệch chuẩn	23,3	16,1		

- Khoảng cách giữa Mary với Jack?

Chiều cao=|-0,88-0,41|=1,28

Cân nặng =|-1,01-0,98|=1,98

Tổng khoảng cách =3.26

Khoảng cách giữa Mary với Mark

Chiều cao=|-0,88+0,75|=0,13

Cân nặng =|-0,88+0,70|=0,30

Tổng khoảng cách =0,43

Đo lường khoảng cách

- Khoảng cách Euclid
- Khoảng cách Manhattan
- Khoảng cách Minkowski
- Khoảng cách tương quan Pearson
- .....

Khoảng cách Euclid

- $d = \sqrt{\sum(x_{ik} - x_{jk})^2}$
- $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$

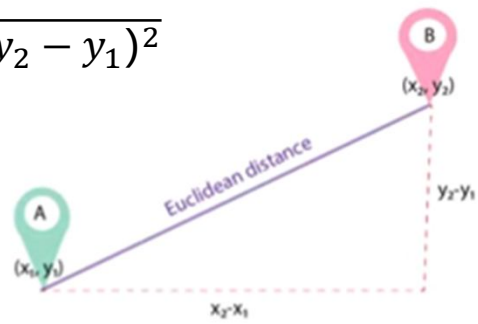

15

Khoảng cách Manhattan

$$d(i,j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \ldots + |x_{ip} - x_{jp}|$$

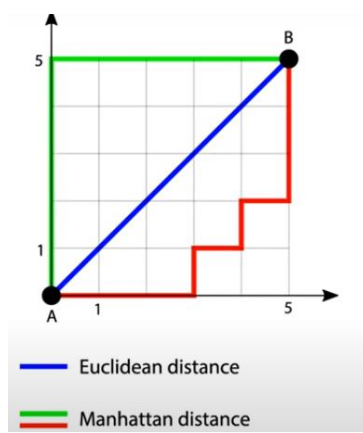

16

Khoảng cách Minkowski

$$d = \left(\sum_{i=1}^{n} (|x_i - y_i|)^p \right)^{1/p}$$

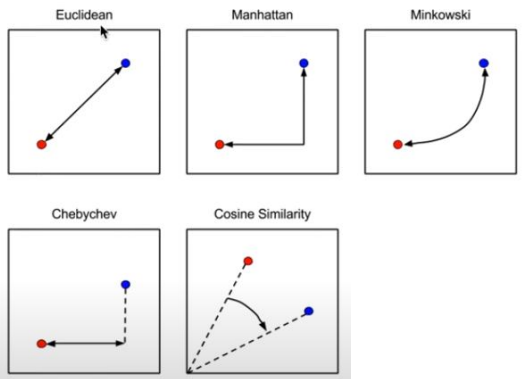

17

Phương pháp phân cụm

- Phân cụm phân cấp (**Hierarchical clustering)**
- Phân cụm phân hoạch **(Partitioning clustering)**
  - Phân cụm K-means
  - Phân cụm K-medoids (PAM, CLARA,...)
  - Phân cụm K-modes
  - .....

18

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp phân cụm phân cấp

Ý tưởng:

Ban đầu mỗi điểm (đối tượng) là một cụm riêng biệt. Thuật toán phân cụm phân cấp sẽ tạo ra các cụm lớn hơn bằng các sát nhập các cụm nhỏ hơn gần nhau nhất tại mỗi vòng lặp.

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp phân cụm phân cấp

Các tiêu chí chọn hai cụm để sát nhập

- **Centroid-linkage**: Sát nhập hai cụm có khoảng cách giữa hai tâm của hai cụm này là nhỏ nhất.
- **Single-linkage**: khoảng cách giữa hai điểm gần nhau nhất thuộc hai cụm. Sát nhập hai cụm có khoảng cách này nhỏ nhất.
- **Average-linkage**: trung bình các khoảng cách giữa hai cặp điểm bất kì thuộc hai cụm. Sát nhập hai cụm có khoảng cách này nhỏ nhất.
- **Complete-linkage**: khoảng cách giữa hai điểm xa nhau nhất của hai cụm, sát nhập hai cụm có khoảng cách này là nhỏ nhất.
- **Radius**: bán kính của một cụm là khoảng cách từ tâm tới điểm xa nhất của cụm, sát nhập hai cụm nếu hai cụm tạo ra một cụm có bán kính nhỏ nhất.
- **Diameter**: đường kính của một cụm là khoảng cách của hai điểm xa nhau nhất trong cụm, sát nhập hai cụm nếu chúng tạo nên một cụm có đường kính nhỏ nhất.

www.khoathongke.neu.edu.vn

Phương pháp phân cụm phân cấp

Các tiêu chí chọn hai cụm để sát nhập

Khoảng cách ngắn nhất giữa 2 điểm thuộc 2 cụm

Khoảng cách xa nhất giữa 2 điểm thuộc 2 cụm

Khoảng cách giữa hai "điểm trung bình" (centroid) của 2 cụm

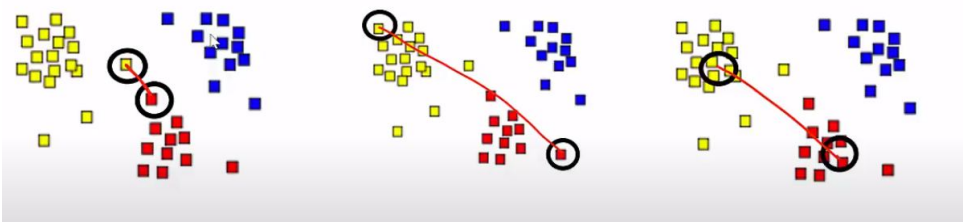

Phương pháp phân cụm phân cấp

Thuật toán:

- Gom tụ (Agglomerative)
- Phân tách (Divisive)

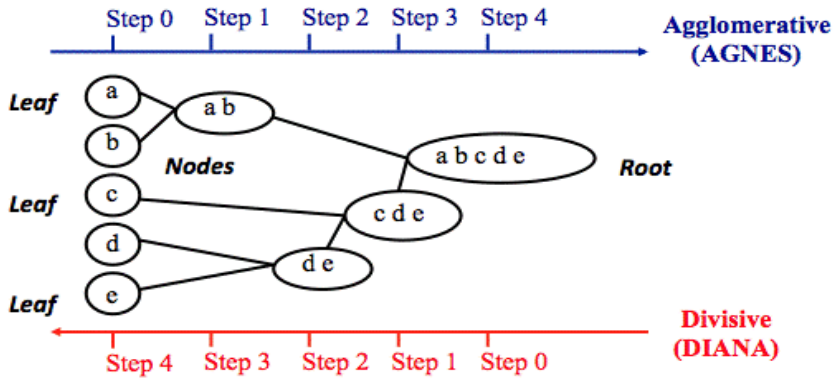

Các bước tiến hành

- B1: Xem mỗi quan sát là 1 cụm
- B2: Tính khoảng cách giữa các cụm
- B3: Gom các cụm dựa vào khoảng cách
- B4: Thực hiện B3 đến khi chỉ còn 1 cụm duy nhất
- B5: Biểu diễn kết quả trên biểu đồ

Biểu đồ cây (Dendrogram)

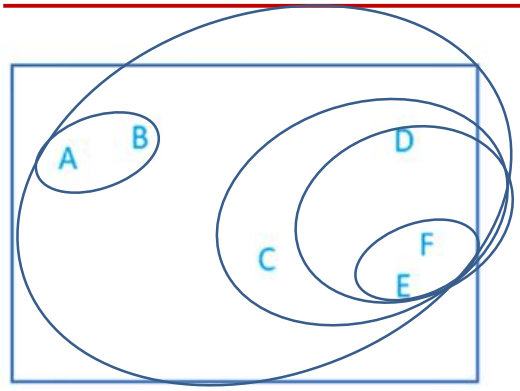

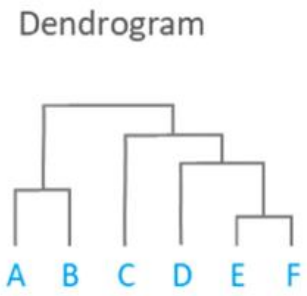

Ví dụ minh họa

ID	X	Y
A	18	0
B	22	0
C	43	0
D	42	0
E	27	0
F	25	0

ID	A	B	C	D	E	F
A	0	4	25	24	9	7
B		0	21	20	5	3
C			0	1	16	18
D				0	15	17
E					0	2
F						0

Khoảng cách xa nhất giữa 2 điểm thuộc 2 cụm

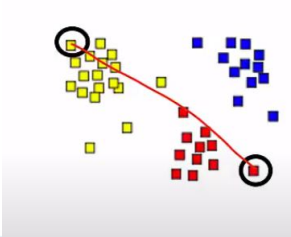

25

Ví dụ minh họa

ID	A	B	C	D	E	F
A	0	4	25	24	9	7
B		0	21	20	5	3
C			0	1	16	18
D				0	15	17
E					0	2
F						0

ID	X	Y
A	18	0
B	22	0
C	43	0
D	42	0
E	27	0
F	25	0

ID	A	B	CD	E	F
A	0	4	25	9	7
B		0	21	5	3
CD			0	16	18
E				0	2
F					0

26

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Ví dụ minh họa

ID	A	B	CD	E	F
A	0	4	25	9	7
B		0	21	5	3
CD			0	16	18
E				0	2
F					0

ID	A	B	CD	EF
A	0	4	25	9
B		0	21	5
CD			0	18
EF				0

ID	X	Y
A	18	0
B	22	0
C	43	0
D	42	0
E	27	0
F	25	0

27

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Ví dụ minh họa

ID	A	B	CD	EF
A	0	4	25	9
B		0	21	5
CD			0	18
EF				0

ID	AB	CD	EF
AB	0	25	9
CD		0	18
EF			0

ID	X	Y
A	18	0
B	22	0
C	43	0
D	42	0
E	27	0
F	25	0

28

Ví dụ minh họa

ID	AB	CD	EF
AB	0	25	9
CD		0	18
EF			0

ID	ABEF	CD
ABEF	0	25
CD		0

ID	X	Y
A	18	0
B	22	0
C	43	0
D	42	0
E	27	0
F	25	0

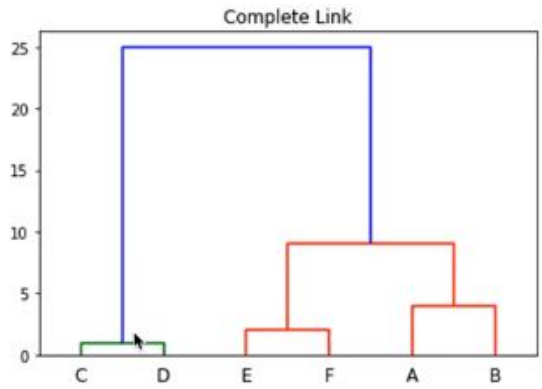

29

Biểu đồ cây

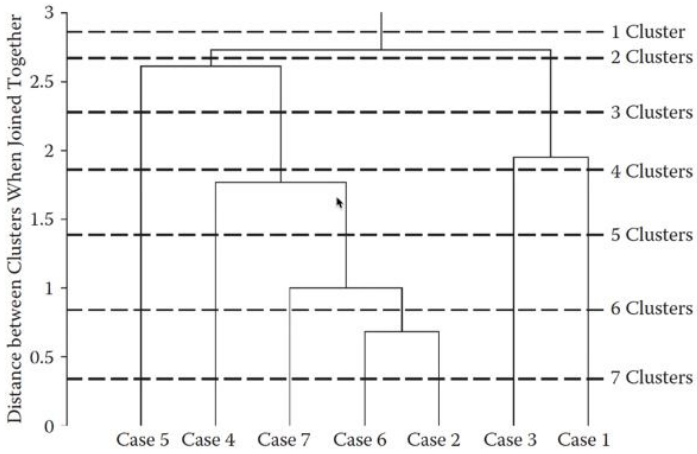

FIGURE 5.6 Dendrogram for first seven cases with possible numbers of clusters marked.

30

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp phân cụm phân hoạch

- Phân cụm K-means
- Phân cụm K-medoids (PAM, CLARA,...)
- Phân cụm K-modes
- ....

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp phân cụm K-means

- Là phương pháp rất phổ biến
- McQueen (1967), Lloyd (1957, 1982)
- Ý tưởng: Thuật toán đưa các quan sát vào k cụm, sao cho tổng biến thiên trong mỗi cụm càng nhỏ càng tốt.

Các thuật toán K-means

- Hartigan-Wong (1979)
- $W(c_k) = \Sigma(x_i - \mu_k)^2$
- Trong đó:
- x_i: các giá trị quan sát thuộc cụm C_K
- μ_k là giá trị trung bình của cụm

- Tổng biến thiên trong cụm WSS =$\Sigma\Sigma(x_i - \mu_k)^2$

Thuật toán của K-means

- Xác định k cần thiết
- Chọn ngẫu nhiên k giá trị trung tâm (ban đầu)
- Gán mỗi quan sát vào cụm (dựa vào khoảng cách)
- Cập nhật lại trung bình cụm
- Lặp lại khi giá trị trung tâm không thay đổi

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp K-means

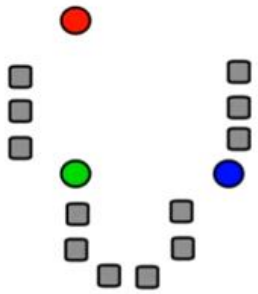

Step1: define *k* initial means (in this case *k*=3) randomly generated within the data domain

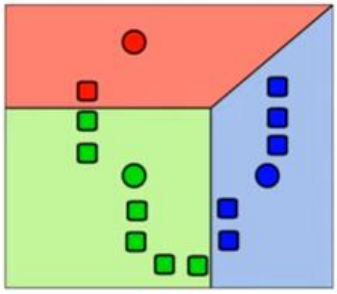

Step 2: *k* clusters are created by associating every observation with the nearest mean

35

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp K-means

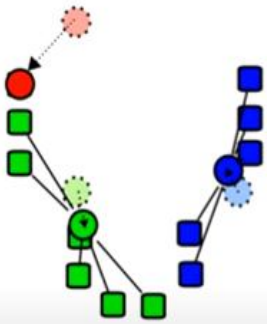

Step 3: the centrpid of each of the *k* clusters becomes the new mean.

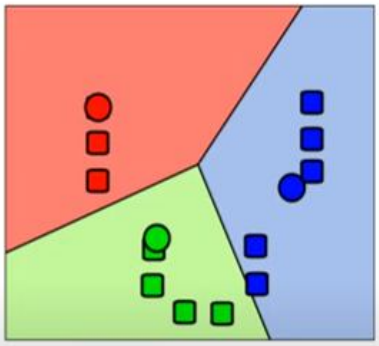

Steps 2 and 3 are repeated until convergence has been reached.

36

K-means

- Dữ liệu (2, 4, 10, 12, 3, 20, 30, 11, 25)
- Xác định k=2
- **Bước 1**
- Lấy 2 giá trị ngẫu nhiên M1=4, và M2=11
- Tính khoảng cách D1, D2
- Như vậy C1 ={2, 4, 3}
- C2={10, 12, 20, 30, 11, 25}

Dữ liệu	D1	D2	Cụm
2	2	9	C1
4	0	7	C1
10	6	1	C2
12	8	1	C2
3	1	8	C1
20	16	9	C2
30	26	19	C2
11	7	0	C2
25	21	14	C2

37

K-means

- **Bước 2**
- C1 ={2, 4, 3}
- C2={10, 12, 20, 30, 11, 25}
- Trung bình M1=3, M2 =18
- Tính lại khoảng cách D1, D2
- Cụm mới
- C1={2, 3, 4, 10}
  C2={12, 20, 30, 11, 25}

Dữ liệu	D1	D2	Cụm
2	1	16	C1
4	1	14	C1
10	7	8	C1
12	9	6	C2
3	0	15	C1
20	17	2	C2
30	27	12	C2
11	8	7	C2
25	22	7	C2

38

K-means

- **Bước 3**
- C1 ={2, 4, 3, 10}
- C2={12, 20, 30, 11, 25}
- Trung bình M1=4,75, M2 =19,6
- Tính lại khoảng cách D1, D2
- Cụm mới
- C1={2, 3, 4, 10, 11, 12}
- C2={20, 30, 25}

Dữ liệu	D1	D2	Cụm
2	2,75	17,6	C1
4	0,75	15,6	C1
10	5,25	9,6	C1
12	7,25	7,6	C1
3	1,75	16,6	C1
20	15,25	0,4	C2
30	25,25	10,4	C2
11	6,25	8,6	C1
25	20,25	5,4	C2

K-means

- **Bước 4**
- C1 ={2, 4, 3, 10}
- C2={12, 20, 30, 11, 25}
- Trung bình M1=7, M2 =25
- Tính lại khoảng cách D1, D2
- Cụm mới
- C1={2, 3, 4, 10, 11, 12}
- C2={20, 30, 25}

Dữ liệu	D1	D2	Cụm
2	5	23	C1
4	3	21	C1
10	3	15	C1
12	5	13	C1
3	4	22	C1
20	13	5	C2
30	23	5	C2
11	4	14	C1
25	18	0	C2

K-means

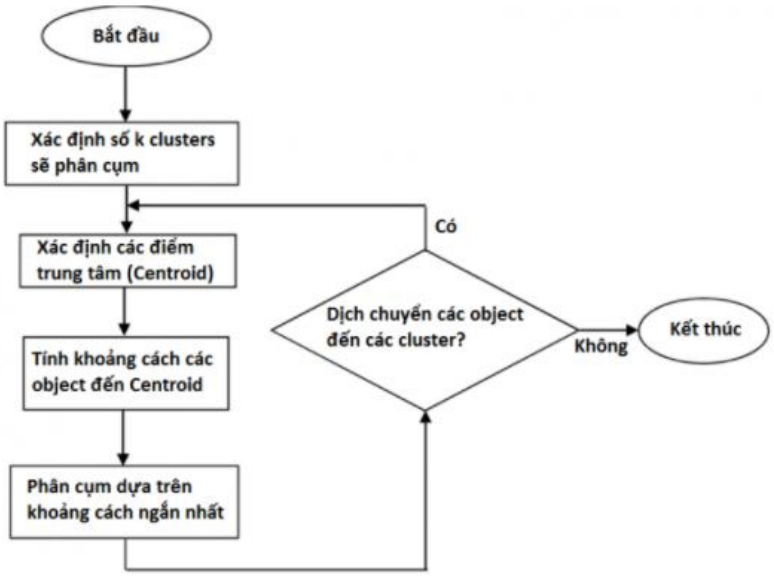

41

Xác định k tối ưu

- Đây là vấn đề rất quan trọng trong phân tích cụm
- Không có câu trả lời nhất quán
- Việc xác định hoàn toàn do chủ quan

42

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp xác định k

- Một số phương pháp phổ biến:
- Phương pháp Elbow
- Phương pháp trung bình Silhouette
- Phương pháp Gap-statistic

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Phương pháp Elbow

- Tiêu chuẩn: tổng bình phương trong mỗi cụm (WSS)
- Chọn k sao cho WSS không tăng nhiều khi thêm k
- Thuật toán:
- Tính toán WSS
- Sử dụng đồ thị Elbow
- Xác định điểm tối ưu

Phương pháp trung bình Silhouette

- Silhouette là thước đo sự tương đồng giữa cụm với các đơn vị cá thể
- Thuật toán:

- Tính Silhouette: $S(i) = \frac{b(i)-a(i)}{\max\{a(i),b(i)\}}$

a(i) khoảng cách trung bình từ i tới tất cả các đơn vị khác trong cụm

b(i) là khoảng cách trung bình (ngắn nhất) từ i tới các đơn vị khác của cụm không chứa i

Phương pháp Gap-Statistic

- Tính Gap-Statistic (G)
- G = WSS/Giá trị kỳ vọng giả thuyết vô hiệu (không có cụm nào)
- Thuật toán
- Lần lượt tính WSS cho k = 1, 2, 3,…
- Dùng phương pháp Boostrap, tính W_{ref}
- Tính $G = \frac{1}{B}\sum_{b=1}^{B}\log(W_{ref}) - \log(WSS)$
- Chọn k sao cho G nằm trong khoảng 1 độ lệch chuẩn k và k+1

Phương pháp K-medoids

Ý tưởng (tìm các đối tượng đại diện (medoids) trong các cụm

- PAM (Kaufmann & Rousseeuv (1987))
- CLARA (Kaufmann & Rousseeuv (1990)) – PAM trên mẫu lớn
- CLARANS (Ng & Han 1994): Lấy mẫu lại ngẫu nhiên

Thuật toán PAM

- Từ một tập hợp các medoids ban đầu và thay thế lặp đi lặp lại một trong các medoid bằng các đối tượng không phải medoid nếu nó cải thiện được tổng khoảng cách giữa các cụm
- Hoán chuyển hai đối tượng O_m và O_p, thuật toán PAM sử dụng tổng khoảng cách hoán chuyển C_{jmp} làm căn cứ
- $d(O_j, O_p)-d(O_j,O_m) <0$ thì chuyển O_p thay cho O_m
- O_m là đối tượng medoid hiện thời cần được thay thế
- O_p là đối tượng medoid thay thế cho Om
- O_j là đối tượng dữ liệu (không phải là medoid) có thể được di chuyển sang cụm khác

Thuật toán CLARA – Clustering LARge Application)

- Khắc phục nhược điểm của PAM khi k, n lớn
- CLARA trích mẫu cho tập dữ liệu, áp dụng PAM tìm ra các medoids cho mẫu này

Phương pháp phân cụm K-modes

Là một trong những thuật toán học máy không giám sát được sử dụng để phân cụm các biến phân loại.

- Sử dụng sự khác biệt thay vì xác định trung bình (k-means)
- Càng ít sự khác biệt thì dữ liệu càng giống nhau

Đo lường khoảng cách

quan sát	Giới	Kính	Râu	Cười	Mũ
1	m	y	n	y	n
2	f	n	n	y	n
3	m	y	n	n	n
4	m	n	n	n	n
5	m	n	n	y	n
6	m	n	y	n	y
7	m	y	n	y	n
8	m	n	n	y	n
9	m	y	y	y	n
10	f	n	n	n	n
11	m	n	y	n	n
12	f	n	n	n	n

Thuật toán

- Chọn ngẫu nhiên K quan sát và sử dụng chúng làm "cụm dẫn dắt"
- Tính toán sự khác biệt và chỉ định mỗi quan sát vào cụm gần nhất với nó
- Xác định các mode mới cho các cụm
- Lặp lại bước 2-3 cho đến khi các cụm không thay đổi

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Các thuật toán K-modes

- Ví dụ: Có thông tin về dữ liệu màu tóc, màu mắt, màu da của 8 người như sau: Phân thành 3 cụm

Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P2	brunette	gray	brown
P3	red	green	brown
P4	black	hazel	brown
P5	brunette	amber	fair
P6	black	gray	brown
P7	red	green	fair
P8	black	hazel	fair

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Các thuật toán K-modes

B1: Chọn ngẫu nhiên 3 người làm 3 cụm "dẫn dắt"

Leader			
Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P7	red	green	fair
P8	black	hazel	fair

Các thuật toán K-modes

B2: Tính khoảng cách từng người so với 3 cụm "dẫn dắt", quy ước trùng biểu hiện là 0, khác là 1

Leader			
Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P7	red	green	fair
P8	black	hazel	fair

Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P2	brunette	gray	brown
P3	red	green	brown
P4	black	hazel	brown
P5	brunette	amber	fair
P6	black	gray	brown
P7	red	green	fair
P8	black	hazel	fair

	Cluster 1	Cluster 2	Cluster 3
P1	0	2	2
P2	3	3	3
P3	3	1	3
P4	3	3	1
P5	1	2	2
P6	3	3	2
P7	2	0	2
P8	2	2	0

Các thuật toán K-modes

B3: Xác định khoảng cách nhỏ nhất của từng quan sát với các cụm (nếu có nhiều khoảng cách nhỏ nhất bằng nhau ->chọn ngẫy nhiên vào 1 cụm nào đó)

	Cluster 1	Cluster 2	Cluster 3
P1	0 ✓	2	2
P2	3 ✓	3	3
P3	3	1 ✓	3
P4	3	3	1 ✓
P5	1 ✓	2	2
P6	3	3	2 ✓
P7	2	0 ✓	2
P8	2	2	0 ✓

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Các thuật toán K-modes

Cụm 1 (P1, P2, P5), cụm 2 (P3, P7), cụm 3 (P4, P6, P8)

Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P2	brunette	gray	brown
P5	brunette	amber	fair
P3	red	green	brown
P7	red	green	fair
P4	black	hazel	brown
P6	black	gray	brown
P8	black	hazel	fair

57

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

Các thuật toán K-modes

B4: Chọn đặc điểm của từng cụm mới (dựa trên mode)

New Leader			
Cluser	Hair color	Eye color	Skin color
1	brunette	amber	fair
2	red	green	fair
3	black	hazel	brown

58

Các thuật toán K-modes

Lặp lại B2

New Leader			
Cluser	Hair color	Eye color	Skin color
1	brunette	amber	fair
2	red	green	fair
3	black	hazel	brown

	Cluster 1	Cluster 2	Cluster 3
P1	1	2	3
P2	2	3	2
P3	3	1	2
P4	3	3	0
P5	0	2	3
P6	3	3	1
P7	2	0	3
P8	2	2	1

Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P2	brunette	gray	brown
P3	red	green	brown
P4	black	hazel	brown
P5	brunette	amber	fair
P6	black	gray	brown
P7	red	green	fair
P8	black	hazel	fair

Các thuật toán K-modes

- Lặp lại B3

	Cluster 1	Cluster 2	Cluster 3
P1	1 ✓	2	3
P2	2 ✓	3	2
P3	3	1 ✓	2
P4	3	3	0 ✓
P5	0 ✓	2	3
P6	3	3	1 ✓
P7	2	0 ✓	3
P8	2	2	1 ✓

Các thuật toán K-modes

- Lặp lại B4

Person	Hair color	Eye color	Skin color
P1	blonde	amber	fair
P2	brunette	gray	brown
P6	black	gray	brown
P7	red	green	fair
P4	black	hazel	brown
P5	brunette	amber	fair
P3	red	green	brown
P8	black	hazel	fair

Các thuật toán K-modes

- Packages: klaR
- kmodes(data, modes, iter.max = 10, weighted = FALSE, fast = TRUE)

Data: A matrix or data frame of categorical data. Objects have to be in rows, variables in columns.

Modes: Either the number of modes or a set of initial (distinct) cluster modes. If a number, a random set of (distinct) rows in data is chosen as the initial modes.

iter.max: The maximum number of iterations allowed.

weighted: Whether usual simple-matching distance between objects is used, or a weighted version of this distance.

fast: Logical Whether a fast version of the algorithm should be applied.