KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# PHÂN LOẠI DỮ LIỆU (CLASSIFICATION)





KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

## NỘI DUNG

- Phân loại dữ liệu là gì?
- Các thuật toán phân loại dữ liệu
  - *K-nearest neighbour*
  - *Decision tree*
  - *Random forest*
  - *Support Vector Machine*
  - *...*

# PHÂN LOẠI DỮ LIỆU LÀ GÌ?

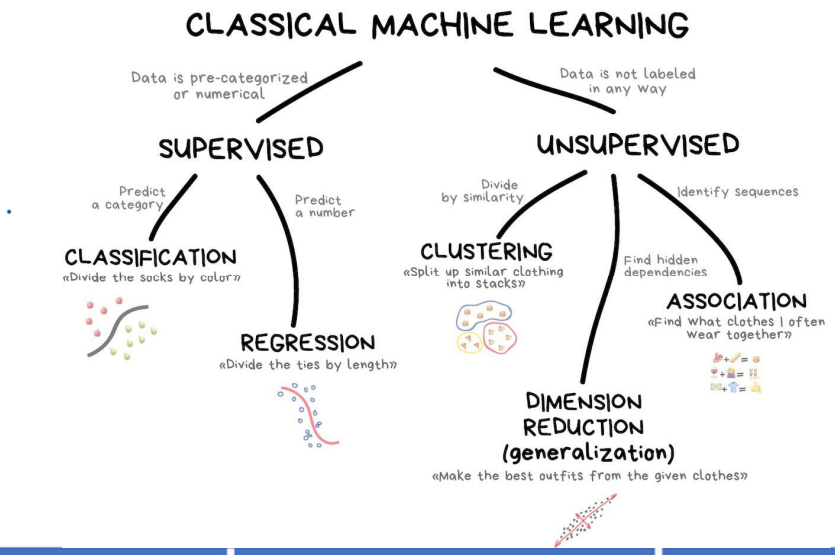




# VÍ DỤ 1

| Tid | Refund | Marital Status | Taxable Income | Evade |
|---|---|---|---|---|
| 1 | Yes | Single | 125K | No |
| 2 | No | Married | 100K | No |
| 3 | No | Single | 70K | No |
| 4 | Yes | Married | 120K | No |
| 5 | No | Divorced | 95K | Yes |
| 6 | No | Married | 60K | No |
| 7 | Yes | Divorced | 220K | No |
| 8 | No | Single | 85K | Yes |
| 9 | No | Married | 75K | No |
| 10 | No | Single | 90K | Yes |

Một người có Taxable income là 100K, refund là Yes và Marital status là Marrried có khả năng trốn thuế không?

# VÍ DỤ 2

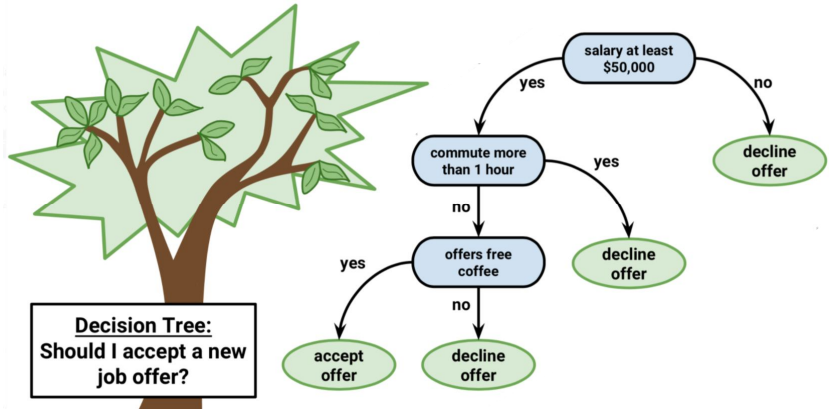


Có nên nhận lời mời của một công ty trả lương $60,000, có phục vụ cà phê nhưng ở xa (mất 1,5 giờ để đến công ty) không?



# PHÂN LOẠI DỮ LIỆU LÀ GÌ?

- Phân loại dữ liệu khác nhau theo các lớp khác nhau dựa trên các yếu tố, tính chất tương đồng và thông tin thể hiện sự liên quan giữa các dữ liệu
- Đặc điểm:
  - ✓ Dựa vào thuật toán để tìm ra điểm tương đồng
  - ✓ Dữ liệu đã có sẵn nhãn phân loại

# PHÂN LOẠI DỮ LIỆU LÀ GÌ?

- Ứng dụng:
  - ✓ Ngân hàng: xác định rủi ro tín dụng, giao dịch lừa đảo,…
  - ✓ Chẩn đoán y tế: xác định bệnh lý, xác định thuốc phù hợp,…
  - ✓ Giáo dục: phân loại học sinh để hỗ trợ phù hợp
  - ✓ Thương mại điện tử: phân loại khách hàng để xây dựng chiến lược marketing phù hợp
  - ✓ Kinh tế: dự báo xu hướng thị trường chứng khoán, sự kiện kinh tế trong tương lai,…
  - ✓ Nhận dạng: chữ viết, hình ảnh,...
  - ✓ Phân loại trang web, email,...



# CÁC BƯỚC PHÂN LOẠI

- **Bước 1.** Chuẩn bị dữ liệu: làm sạch dữ liệu, chuẩn hóa dữ liệu, phân chia dữ liệu thành tập huấn luyện (training data set) và tập kiểm tra (test data set) theo phương pháp:
  - ✓ **Hold out:**
    - ➢ *Ưu điểm:* nhanh chóng, đơn giản, linh hoạt
    - ➢ *Hạn chế:* phụ thuộc sự biến thiên giữa hai bộ dữ liệu dẫn đến khác biệt trong phân loại, dự báo

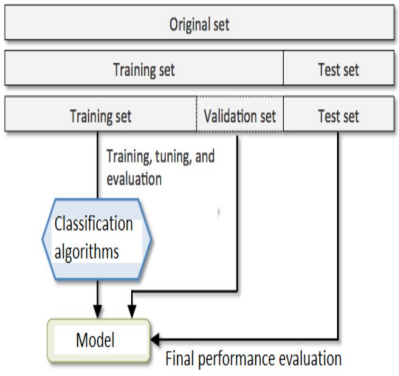

# CÁC BƯỚC PHÂN LOẠI

- **Bước 1.** Chuẩn bị dữ liệu: làm sạch dữ liệu, chuẩn hóa dữ liệu, phân chia dữ liệu thành tập huấn luyện (training data set) và tập kiểm tra (test data set) theo phương pháp:

✓ **Cross-validation:** Phương pháp phổ biến là k-fold.

- *Ưu điểm:* làm giảm đáng kể phương sai và độ lệch chuẩn
- *Hạn chế:* thực hiện phức tạp, mất nhiều thời gian hơn

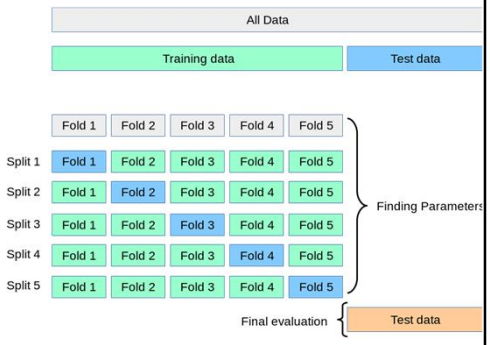




# CÁC BƯỚC PHÂN LOẠI

- **Bước 2.** Huấn luyện (học): xây dựng mô hình phân loại trên cơ sở tập huấn luyện, sử dụng các thuật toán phân loại

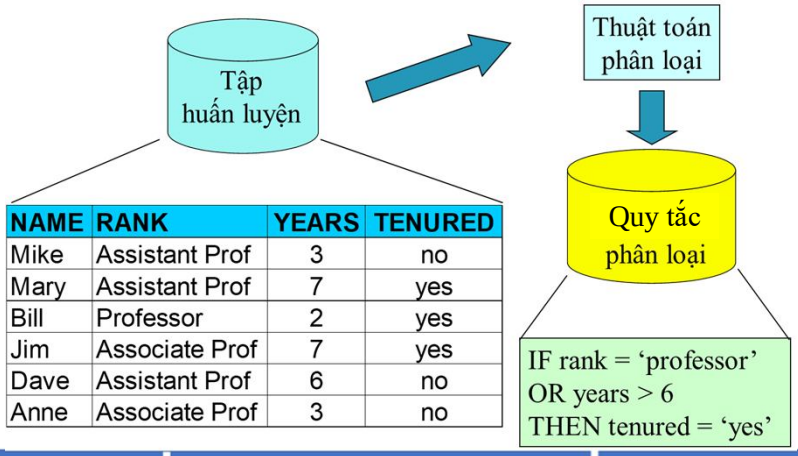


| NAME | RANK | YEARS | TENURED |
|---|---|---|---|
| Mike | Assistant Prof | 3 | no |
| Mary | Assistant Prof | 7 | yes |
| Bill | Professor | 2 | yes |
| Jim | Associate Prof | 7 | yes |
| Dave | Assistant Prof | 6 | no |
| Anne | Associate Prof | 3 | no |

# CÁC BƯỚC PHÂN LOẠI

- **Bước 3.** Kiểm tra, đánh giá mô hình dựa trên tập kiểm tra
- **Bước 4.** Ứng dụng phân loại đối với dữ liệu mới

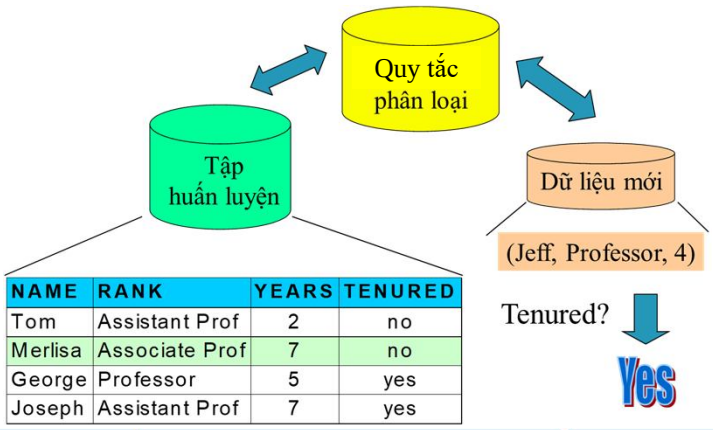


| NAME | RANK | YEARS | TENURED |
|---|---|---|---|
| Tom | Assistant Prof | 2 | no |
| Merlisa | Associate Prof | 7 | no |
| George | Professor | 5 | yes |
| Joseph | Assistant Prof | 7 | yes |



# CÁC THUẬT TOÁN PHÂN LOẠI DỮ LIỆU

- K-nearest neighbor
- Decision tree
- Random forest
- Support Vector Machine
- ...

# K-NEAREST NEIGHBOR (KNN)

- "***Gần mực thì đen, gần đèn thì rạng***"
- Dựa vào khoảng cách giữa điểm dữ liệu

cần phân loại với điểm dữ liệu đã phân loại trước đó

- Quá trình học và phân loại dựa trực tiếp trên

đơn vị cần phân loại, không học từ tập dữ liệu huấn luyện

→ **Lazy learning method**

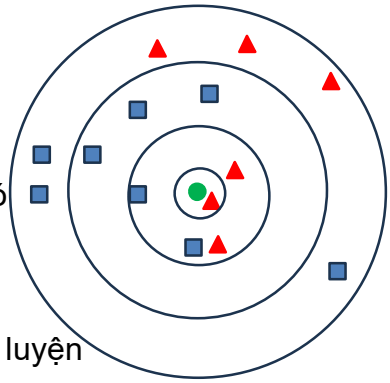



# K-NEAREST NEIGHBOR (KNN)

- Ưu điểm:
  - ✓ Không cần giả định về phân phối của dữ liệu
  - ✓ Thuật toán đơn giản, dễ thực hiện
  - ✓ Tính toán đơn giản
- Hạn chế:
  - ✓ K nhỏ: rất nhạy cảm với nhiễu
  - ✓ K lớn: gồm quá nhiều loại
  - ✓ Mất nhiều thời gian thực hiện
  - ✓ Yêu cầu bộ nhớ lớn

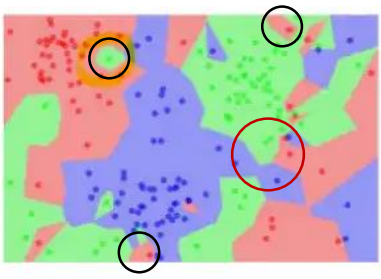

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# K-NEAREST NEIGHBOR (KNN)

**Ví dụ:** Lấy mẫu 15 khách hàng đã được phân loại khả năng nợ xấu (tập huấn luyện) để dự đoán khả năng nợ xấu của khách hàng tín dụng mới. Trong đó: Khả năng nợ xấu có hai biểu hiện: 0 – không, 1 – có)

| ID | Độ tuổi | Giới tính | Học vấn | Hôn nhân | Sở hữu BĐS | Thu nhập | Khoản vay | Thời hạn vay | Nợ xấu |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 25 | Nam | ĐH | Độc thân | Ở cùng bố mẹ | 7000000 | 20000000 | 6 | 0 |
| 2 | 40 | Nam | THPT | Đã kết hôn | Nhà sở hữu | 20000000 | 100000000 | 9 | 0 |
| 3 | 35 | Nữ | ĐH | Từng ly hôn | Nhà thuê | 12000000 | 30000000 | 4 | 1 |
| 4 | 27 | Nam | THPT | Đã kết hôn | Ở cùng bố mẹ | 9000000 | 15000000 | 6 | 0 |
| 5 | 31 | Nữ | THCS | Độc thân | Nhà thuê | 6000000 | 23000000 | 6 | 1 |
| 6 | 36 | Nữ | ĐH | Đã kết hôn | Nhà sở hữu | 8000000 | 20000000 | 6 | 1 |
| 7 | 48 | Nam | ĐH | Độc thân | Nhà thuê | 7000000 | 10000000 | 3 | 0 |
| 8 | 26 | Nữ | ĐH | Đã kết hôn | Nhà thuê | 8000000 | 10000000 | 3 | 1 |
| 9 | 33 | Nam | CĐ | Từng ly hôn | Ở cùng bố mẹ | 5000000 | 12000000 | 4 | 1 |
| 10 | 29 | Nam | THPT | Độc thân | Nhà thuê | 10000000 | 25000000 | 9 | 0 |
| 11 | 38 | Nam | THPT | Đã kết hôn | Nhà sở hữu | 15000000 | 60000000 | 9 | 0 |
| 12 | 44 | Nữ | ĐH | Độc thân | Nhà sở hữu | 14000000 | 20000000 | 4 | 1 |
| 13 | 42 | Nam | ĐH | Đã kết hôn | Nhà sở hữu | 10000000 | 30000000 | 4 | 0 |
| 14 | 28 | Nữ | ĐH | Độc thân | Nhà thuê | 7000000 | 20000000 | 6 | 1 |
| 15 | 30 | Nữ | ĐH | Đã kết hôn | Ở cùng bố mẹ | 6000000 | 16000000 | 6 | 1 |
| 16 | 32 | Nam | ĐH | Đã kết hôn | Nhà sở hữu | 15000000 | 40000000 | 6 | ???? |



KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# K-NEAREST NEIGHBOR (KNN): Các bước thực hiện

- Tiền xử lý dữ liệu: làm sạch dữ liệu, chuẩn hóa dữ liệu nếu dữ liệu định lượng không cùng đơn vị tính, xử lý dữ liệu trống,...

Biến độc lập (x)

Biến mục tiêu (y)

| ID | Độ tuổi | Giới tính | Học vấn | Hôn nhân | Sở hữu BĐS | Thu nhập | Khoản vay | Thời hạn vay | Nợ xấu |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 0.00 | Nam | ĐH | Độc thân | Ở cùng bố mẹ | 0.13 | 0.11 | 0.50 | 0 |
| 2 | 0.65 | Nam | THPT | Đã kết hôn | Nhà sở hữu | 1.00 | 1.00 | 1.00 | 0 |
| 3 | 0.43 | Nữ | ĐH | Từng ly hôn | Nhà thuê | 0.47 | 0.22 | 0.17 | 1 |
| 4 | 0.09 | Nam | THPT | Đã kết hôn | Ở cùng bố mẹ | 0.27 | 0.06 | 0.50 | 0 |
| 5 | 0.26 | Nữ | THCS | Độc thân | Nhà thuê | 0.07 | 0.14 | 0.50 | 1 |
| 6 | 0.48 | Nữ | ĐH | Đã kết hôn | Nhà sở hữu | 0.20 | 0.11 | 0.50 | 1 |
| 7 | 1.00 | Nam | ĐH | Độc thân | Nhà thuê | 0.13 | 0.00 | 0.00 | 0 |
| 8 | 0.04 | Nữ | ĐH | Đã kết hôn | Nhà thuê | 0.20 | 0.00 | 0.00 | 1 |
| 9 | 0.35 | Nam | CĐ | Từng ly hôn | Ở cùng bố mẹ | 0.00 | 0.02 | 0.17 | 1 |
| 10 | 0.17 | Nam | THPT | Độc thân | Nhà thuê | 0.33 | 0.17 | 1.00 | 0 |
| 11 | 0.57 | Nam | THPT | Đã kết hôn | Nhà sở hữu | 0.67 | 0.56 | 1.00 | 0 |
| 12 | 0.83 | Nữ | ĐH | Độc thân | Nhà sở hữu | 0.60 | 0.11 | 0.17 | 1 |
| 13 | 0.74 | Nam | ĐH | Đã kết hôn | Nhà sở hữu | 0.33 | 0.22 | 0.17 | 0 |
| 14 | 0.13 | Nữ | ĐH | Độc thân | Nhà thuê | 0.13 | 0.11 | 0.50 | 1 |
| 15 | 0.22 | Nữ | ĐH | Đã kết hôn | Ở cùng bố mẹ | 0.07 | 0.07 | 0.50 | 1 |
| 16 | 0.30 | Nam | ĐH | Đã kết hôn | Nhà sở hữu | 0.67 | 0.33 | 0.50 | ???? |

Giá trị

# K-NEAREST NEIGHBOR (KNN): Các bước thực hiện

- Tính khoảng cách giữa điểm dữ liệu chưa phân loại với điểm dữ liệu đã phân loại, sắp xếp theo thứ tự từ nhỏ đến lớn
  - Một số công thức tính khoảng cách đối với biến định lượng:
    - ✓ Khoảng cách Euclidean: $d(x,y) = \sqrt{\sum(x_i - y_i)^2}$
    - ✓ Khoảng cách Mahattan: $d(x,y) = \sqrt{\sum|x_i - y_i|}$

    *(Có thể sử dụng công thức gia quyền nếu tầm quan trọng của các biến i khác nhau)*
  - Đối với biến định tính (quy về biến giả):
    - Cùng biểu hiện: khoảng cách = 0
    - Khác biểu hiện: khoảng cách = 1



# K-NEAREST NEIGHBOR (KNN): Tính khoảng cách

| ID | Độ tuổi | Giới tính | Học vấn | Hôn nhân | Sở hữu BĐS | Thu nhập | Khoản vay | Thời hạn vay | Nợ xấu |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 0.00 | Nam | ĐH | Độc thân | Ở cùng bố mẹ | 0.13 | 0.11 | 0.50 | 0 |
| 2 | 0.65 | Nam | THPT | Đã kết hôn | Nhà sở hữu | 1.00 | 1.00 | 1.00 | 0 |
| 3 | 0.43 | Nữ | ĐH | Từng ly hôn | Nhà thuê | 0.47 | 0.22 | 0.17 | 1 |
| 4 | 0.09 | Nam | THPT | Đã kết hôn | Ở cùng bố mẹ | 0.27 | 0.06 | 0.50 | 0 |
| 5 | 0.26 | Nữ | THCS | Độc thân | Nhà thuê | 0.07 | 0.14 | 0.50 | 1 |
| 6 | 0.48 | Nữ | ĐH | Đã kết hôn | Nhà sở hữu | 0.20 | 0.11 | 0.50 | 1 |
| 7 | 1.00 | Nam | ĐH | Độc thân | Nhà thuê | 0.13 | 0.00 | 0.00 | 0 |
| 8 | 0.04 | Nữ | ĐH | Đã kết hôn | Nhà thuê | 0.20 | 0.00 | 0.00 | 1 |
| 9 | 0.35 | Nam | CĐ | Từng ly hôn | Ở cùng bố mẹ | 0.00 | 0.02 | 0.17 | 1 |
| 10 | 0.17 | Nam | THPT | Độc thân | Nhà thuê | 0.33 | 0.17 | 1.00 | 0 |
| 11 | 0.57 | Nam | THPT | Đã kết hôn | Nhà sở hữu | 0.67 | 0.56 | 1.00 | 0 |
| 12 | 0.83 | Nữ | ĐH | Độc thân | Nhà sở hữu | 0.60 | 0.11 | 0.17 | 1 |
| 13 | 0.74 | Nam | ĐH | Đã kết hôn | Nhà sở hữu | 0.33 | 0.22 | 0.17 | 0 |
| 14 | 0.13 | Nữ | ĐH | Độc thân | Nhà thuê | 0.13 | 0.11 | 0.50 | 1 |
| 15 | 0.22 | Nữ | ĐH | Đã kết hôn | Ở cùng bố mẹ | 0.07 | 0.07 | 0.50 | 1 |
| 16 | 0.30 | Nam | ĐH | Đã kết hôn | Nhà sở hữu | 0.67 | 0.33 | 0.50 | ???? |

$$d(ID16, ID1) = \sqrt{(0.3 - 0.0)^2 + 0^2 + 0^2 + 1^2 + 1^2 + (0.67 - 0.13)^2 + (0.33 - 0.11)^2 + (0.5 - 0.5)^2} = 1.557$$

# K-NEAREST NEIGHBOR (KNN): Tính khoảng cách

- Tính khoảng cách giữa điểm dữ liệu chưa phân loại với điểm dữ liệu đã phân loại, sắp xếp theo thứ tự từ bé đến lớn

| ID | d (ID 16, ID ...) | Xếp hạng | Nợ xấu |
|---|---|---|---|
| 1 | 1.557 | 6 | 0 |
| 2 | 1.389 | 4 | 0 |
| 3 | 1.784 | 11 | 1 |
| 4 | 1.511 | 5 | 0 |
| 5 | 2.097 | 15 | 1 |
| 6 | 1.140 | 1 | 1 |
| 7 | 1.771 | 10 | 0 |
| 8 | 1.626 | 9 | 1 |
| 9 | 1.912 | 14 | 1 |
| 10 | 1.845 | 13 | 0 |
| 11 | 1.170 | 2 | 0 |
| 12 | 1.563 | 8 | 1 |
| 13 | 1.195 | 3 | 0 |
| 14 | 1.834 | 12 | 1 |
| 15 | 1.561 | 7 | 1 |



# K-NEAREST NEIGHBOR (KNN): Các bước thực hiện

- Chọn k bất kỳ, là số điểm dữ liệu đã phân loại có khoảng cách gần nhất với điểm dữ liệu chưa phân loại
- Chọn các điểm dữ liệu có giá trị khoảng cách bé nhất với điểm dữ liệu cần phân loại dựa trên k

| ID | d (ID 16, ID ...) | Xếp hạng | Nợ xấu |
|---|---|---|---|
| 1 | 1.557 | 6 | 0 |
| 2 | 1.389 | 4 | 0 |
| 3 | 1.784 | 11 | 1 |
| 4 | 1.511 | 5 | 0 |
| 5 | 2.097 | 15 | 1 |
| 6 | 1.140 | 1 | 1 |
| 7 | 1.771 | 10 | 0 |
| 8 | 1.626 | 9 | 1 |
| 9 | 1.912 | 14 | 1 |
| 10 | 1.845 | 13 | 0 |
| 11 | 1.170 | 2 | 0 |
| 12 | 1.563 | 8 | 1 |
| 13 | 1.195 | 3 | 0 |
| 14 | 1.834 | 12 | 1 |
| 15 | 1.561 | 7 | 1 |

| | Khách hàng |
|---|---|
| K = 1 | |
| K = 2 | |
| K = 3 | |
| K = 4 | |
| K = 5 | |
| K = 6 | |
| K = 7 | |

# K-NEAREST NEIGHBOR (KNN): Các bước thực hiện

- Dựa vào biểu hiện phổ biến nhất của biến phân loại ứng với từng giá trị k để gán cho điểm dữ liệu chưa phân loại.
  - ✓ Dựa vào Mốt
  - ✓ Dựa vào khoảng cách

| | Khách hàng | Nợ xấu = 0 | Nợ xấu = 1 |
|---|---|---|---|
| K = 1 | ID 6 | 0 | 1 |
| K = 2 | ID 6, ID 11 | 1 | 1 |
| K = 3 | ID 6, ID 11, ID 13 | 2 | 1 |
| K = 4 | ID 6, ID 11, ID 13, ID 2 | 3 | 1 |
| K = 5 | ID 6, ID 11, ID 13, ID 2, ID 4 | 4 | 1 |
| K = 6 | ID 6, ID 11, ID 13, ID 2, ID 4, ID 1 | 5 | 1 |
| K = 7 | ID 6, ID 11, ID 13, ID 2, ID 4, ID 1, ID 15 | 5 | 2 |



# K-NEAREST NEIGHBOR (KNN): Các bước thực hiện

- Đánh giá mô hình trên cơ sở tập dữ liệu kiểm tra
  - ✓ **Accuracy:** khả năng dự báo chính xác hay xác định đúng nhóm cho dữ liệu cần phân loại
  - ✓ **Robustness:** khả năng mô hình xử lý nhiễu hoặc dữ liệu trống để đưa ra dự đoán chính xác
  - ✓ **Speed:** tốc độ hay khả năng mô hình đưa ra kết quả, chi phí tính toán khi sử dụng mô hình
  - ✓ **Scalability:** khả năng xây dựng mô hình phân loại hiệu quả trong xử lý, phân tích lượng lớn dữ liệu
  - ✓ **Interpretability:** khả năng giải thích, mức độ phức tạp của mô hình, phương pháp xây dựng mô hình

# K-NEAREST NEIGHBOR (KNN): Đánh giá mô hình

- Đánh giá độ chính xác của mô hình (**Accuracy):** sử dụng bảng tiếp liên (Confusion matrix/Error matrix/Contingency table)
  - **Precision (Positive Predicted Value):** tỷ lệ các trường hợp positive được phân loại đúng
  - **Sensitivity (Recall)**: tỷ lệ các trường hợp positive thực sự được phân loại đúng
  - **Negative Predicted Value:** tỷ lệ các trường hợp negative được phân loại đúng
  - **Specificity:** tỷ lệ các trường hợp negative thực sự được phân loại đúng
  - **Accuracy:** tỷ lệ tất cả các trường hợp được phân loại đúng
  - **Error rate** = 1 – Accuracy

| | | Predicted Class: Positive | Predicted Class: Negative | |
|---|---|---|---|---|
| Actual Class | Positive | True Positive (TP) | False Negative (FN) Type II Error | **Sensitivity** $\frac{TP}{(TP+FN)}$ |
| | Negative | False Positive (FP) Type I Error | True Negative (TN) | **Specificity** $\frac{TN}{(TN+FP)}$ |
| | | **Precision** $\frac{TP}{(TP+FP)}$ | **Negative Predictive Value** $\frac{TN}{(TN+FN)}$ | **Accuracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$ |



# K-NEAREST NEIGHBOR (KNN): Đánh giá mô hình

- Đánh giá độ chính xác của mô hình (**Accuracy):** sử dụng bảng tiếp liên (Confusion matrix/Error matrix/Contingency table)
  - **Accuracy:** tỷ lệ tất cả các trường hợp được phân loại đúng
  - **Error rate** = 1 – Accuracy

| | | Predicted Class: Positive | Predicted Class: Negative | |
|---|---|---|---|---|
| Actual Class | Positive | True Positive (TP) | False Negative (FN) Type II Error | **Sensitivity** $\frac{TP}{(TP+FN)}$ |
| | Negative | False Positive (FP) Type I Error | True Negative (TN) | **Specificity** $\frac{TN}{(TN+FP)}$ |
| | | **Precision** $\frac{TP}{(TP+FP)}$ | **Negative Predictive Value** $\frac{TN}{(TN+FN)}$ | **Accuracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$ |

www.khoathongke.neu.edu.vn

24

# K-NEAREST NEIGHBOR (KNN): Đánh giá mô hình

- Hệ số phù hợp trong dự đoán (Kappa):

$$\text{Kappa} = \frac{\text{Độ chính xác thực nghiệm} - \text{Độ chính xác ngẫu nhiên}}{1 - \text{Độ chính xác ngẫu nhiên}}$$

➢ *Độ chính xác thực nghiệm: Accuracy*

➢ *Độ chính xác ngẫu nhiên:*

- P(P.P and A.P) = P(P.P) x P(A.P)

$$= \frac{(TP+FP)}{TP+FP+FN+TN} \times \frac{(TP+FN)}{TP+FP+FN+TN}$$

- P(P.N and A.N) = P(P.N) x P(A.N)

$$= \frac{(TN+FN)}{TP+FP+FN+TN} \times \frac{(TN+FP)}{TP+FP+FN+TN}$$

| | | Predicted Class: Positive | Predicted Class: Negative | |
|---|---|---|---|---|
| Actual Class | Positive | True Positive (TP) | False Negative (FN) Type II Error | Sensitivity $\frac{TP}{(TP+FN)}$ |
| | Negative | False Positive (FP) Type I Error | True Negative (TN) | Specificity $\frac{TN}{(TN+FP)}$ |
| | | Precision $\frac{TP}{(TP+FP)}$ | Negative Predictive Value $\frac{TN}{(TN+FN)}$ | Accuracy $\frac{TP+TN}{(TP+TN+FP+FN)}$ |

**Kappa nằm trong khoảng 0 – 1.**

**Giá trị Kappa càng lớn, sự phù hợp của dự đoán càng cao**



# K-NEAREST NEIGHBOR (KNN): Đánh giá mô hình

- Ví dụ phân loại khả năng nợ xấu đối với 63 khách hàng.
  - ➢ Xác định Positive và Negative trong ví dụ này?
  - ➢ So sánh kết quả dự đoán với dữ liệu thực tế

| Thực tế \ Dự đoán | Không | Có | Tổng |
|---|---|---|---|
| Không | 35 | 6 | **41** |
| Có | 2 | 20 | **22** |
| **Tổng** | **37** | **26** | **63** |

➢ Accuracy = $\frac{35+20}{63}$ = 0.873

➢ Kappa = $\frac{0.873 - \frac{37}{63}\times\frac{41}{63} - \frac{26}{63}\times\frac{22}{63}}{1 - \frac{37}{63}\times\frac{41}{63} - \frac{26}{63}\times\frac{22}{63}}$ = 0.7319

# K-NEAREST NEIGHBOR (KNN): Đánh giá mô hình

- **F1 score**: Kết hợp Precision và Negative Predictive Value. Công thức giản đơn:

$$F_1 = \left(\frac{\text{Sensitivity}^{-1} + \text{Precision}^{-1}}{2}\right)^{-1} = 2 \times \frac{\text{Precision} \times \text{Sensitivity}}{\text{Precision} + \text{Sensitivity}}$$

hoặc công thức có trọng số:

$$F_1 = (1 + \beta^2) \times \frac{\text{Precision} \times \text{Sensitivity}}{\beta^2\text{Precision} + \text{Sensitivity}}$$

**$F_1$ nằm trong khoảng 0 – 1. Giá trị $F_1$ càng lớn, hiệu quả phân tích của mô hình càng cao**



# K-NEAREST NEIGHBOR (KNN): Đánh giá mô hình

- **Lift chart và Gaint chart:** định lượng hiệu quả theo % của tập dữ liệu tổng thể và kết hợp đồ thị trực quan để so sánh giữa các giá trị k khác nhau

$$\text{Lift(positive)} = \frac{\frac{TP}{TP + FP}}{\frac{TP + FN}{TP + TN + FP + FN}}$$

$$\text{Lift(negative)} = \frac{\frac{TN}{TN + FN}}{\frac{TN + FP}{TP + TN + FP + FN}}$$

| | Positive | Negative | |
|---|---|---|---|
| **Positive** | True Positive (TP) | False Negative (FN) Type II Error | **Sensitivity** $\frac{TP}{(TP+FN)}$ |
| **Negative** | False Positive (FP) Type I Error | True Negative (TN) | **Specificity** $\frac{TN}{(TN+FP)}$ |
| | **Precision** $\frac{TP}{(TP+FP)}$ | **Negative Predictive Value** $\frac{TN}{(TN+FN)}$ | **Accuracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$ |

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# MỞ RỘNG: KNN REGRESSION

- **Áp dụng khi biến phân loại là biến định lượng**
- Các bước thực hiện:
  - ➢ Chạy thuật toán phân loại trên cơ sở xây dựng mô hình hồi quy biến phân loại theo các biến khác
  - ➢ Đánh giá độ chính xác của mô hình dựa vào MSE, MAE, RMSE



KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# K-NEAREST NEIGHBOR (KNN)

**Các bước thực hiện khi sử dụng phần mềm:**

- Tiền xử lý dữ liệu: giá trị khuyết thiếu, đột xuất, chuẩn hóa dữ liệu,...
- Phân chia dữ liệu
- Chọn k tốt nhất trên cơ sở tập huấn luyện
- Chạy thuật toán phân loại và gán giá trị cho điểm dữ liệu cần phân loại
- Đánh giá độ chính xác của mô hình

# CÂY QUYẾT ĐỊNH (DECISION TREE)

- Tạo ra mô hình dự đoán giá trị của biến mục tiêu (target variable) bằng cách học các quy tắc quyết định đơn giản được suy ra từ các đặc trưng dữ liệu (data features)

→ **Eager learning method**

- Ý tưởng: phân loại theo dạng hình cây có gốc, thân, lá kết nối với nhau bằng các cành, có tác động đến quyết định cuối cùng.

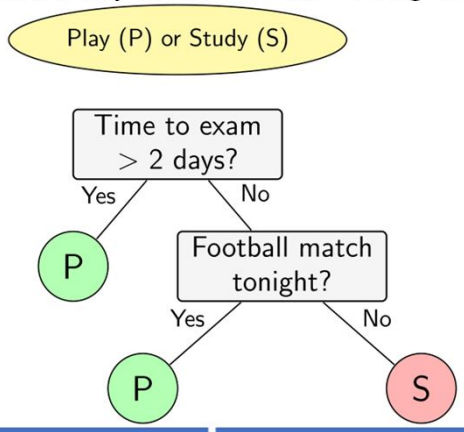




# CÂY QUYẾT ĐỊNH (DECISION TREE)

- Ưu điểm:
  - ✓ Đơn giản, trực quan, dễ hiểu, dễ giải thích
  - ✓ Ít bị ảnh hưởng bởi lượng biến đột xuất hay dữ liệu trống
  - ✓ Không cần giả định ban đầu, kết quả khách quan
  - ✓ Huấn luyện nhanh, không cần đổi biến, chính xác cao

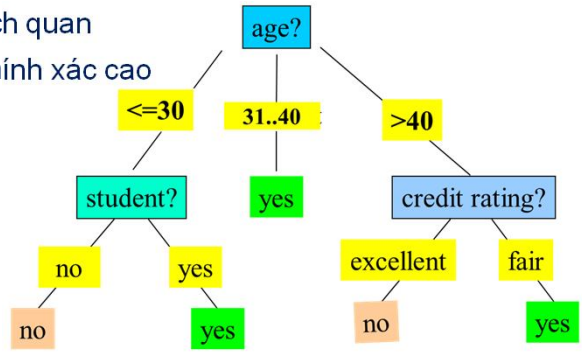

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# CÂY QUYẾT ĐỊNH (DECISION TREE)

- Hạn chế:
  - ✓ Thực hiện trên dữ liệu ít biến
  - ✓ Đối với biến định lượng, chỉ dự báo trong phạm vi giá trị đã có
  - ✓ Không hỗ trợ truy vấn ngược, khó phát hiện lỗi nếu có
  - ✓ Chỉ quan tâm hiệu quả tại từng node
  - ✓ Nếu một điểm dữ liệu mới rơi vào nhầm nhánh ở ngay những lần phân chia đầu tiên, kết quả cuối cùng sẽ khác đi rất nhiều.



KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# CÂY QUYẾT ĐỊNH (DECISION TREE)

- **Phân loại:**
  - ✓ Cây quyết định biến phân loại (Categorical Variable Decision Tree): Cây quyết định có biến mục tiêu là biến phân loại
  - ✓ Cây quyết định biến liên tục (Continuous Variable Decision Tree): Cây quyết định có biến mục tiêu là biến liên tục

# CÂY QUYẾT ĐỊNH (DECISION TREE)

- Cấu trúc cây quyết định: Cố gắng tìm ra một tập hợp các nhánh lá tối ưu nhất: 100% lá thuần khiết (pure leaf node)

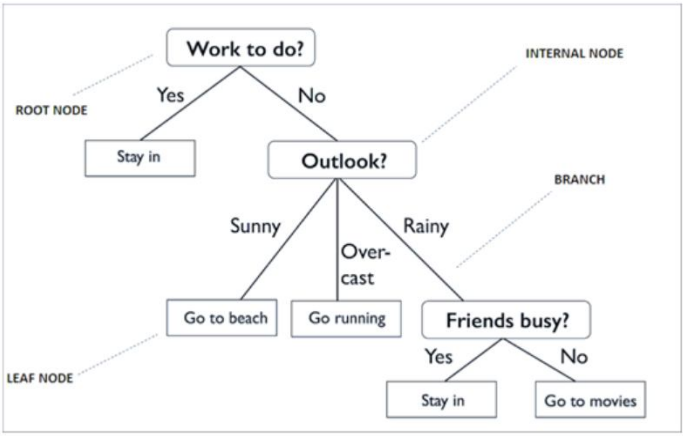




# CÂY QUYẾT ĐỊNH (DECISION TREE)

- Các thuật toán cây quyết định:
  - CART
  - ID3, C4.5, C5.0
  - Chi-Square
  - Reduction in Variance
  - ...

# THUẬT TOÁN CART

- Thuật toán CART (Classification and Regression Tree):
  - Giới thiệu lần đầu năm 1985 bởi nhà thống kê LEO Breiman và cộng sự
  - Chỉ phân chia được 2 nhánh/lần
  - Là một tập các IF-ELSE
  - Ý tưởng chung: tìm các node chứa các đối tượng dữ liệu tương đồng nhau

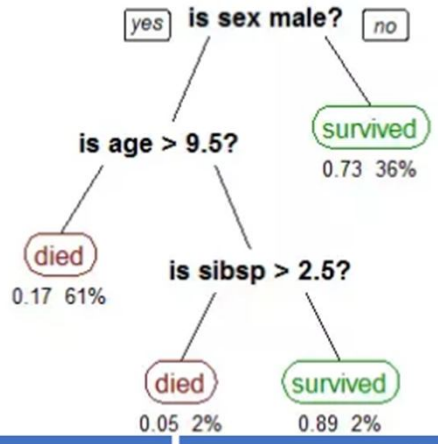




# THUẬT TOÁN CART

- Sử dụng Gini để tạo các điểm chia:
  - Gini xác định tính đồng nhất của mỗi node, tìm ra cách phân nhánh tối ưu nhất.
  - Đo lường tần suất một đối tượng dữ liệu ngẫu nhiên trong tập hợp dữ liệu ban đầu được phân loại không chính xác.
  - Có thể sử dụng cho cả dữ liệu định tính và định lượng

# THUẬT TOÁN CART:
# Dữ liệu định tính

- Công thức tính GINI xác định độ "pha tạp" của node

$$G(i) = 1 - \sum[p(j|i)]^2$$

*i: node bất kỳ*

*j: biểu hiện thứ j của biến mục tiêu*

*p: xác suất để 1 điểm dữ liệu trong i có biểu hiện j*

- Công thức tìm cách chia tối ưu nhất:

$$G_{split} = \sum \frac{n_i}{n} G_i$$

*$n_i$: số điểm dữ liệu có trong node của nhánh được phân*

*n: số điểm dữ liệu có trong node được dùng để phân nhánh*

**Hệ số $G_{split}$ càng nhỏ, phân nhánh càng tối ưu**



# THUẬT TOÁN CART:
# Dữ liệu định tính

- **Ví dụ:** Xây dựng cây quyết định để dự đoán biến **play**: có ra ngoài chơi không?

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 3 | overcast | hot | high | weak | yes |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 7 | overcast | cool | normal | strong | yes |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

# THUẬT TOÁN CART:
# Dữ liệu định tính

- Tính GINI cho từng node nhỏ của node Outlook và tính GINI split của node Outlook: $G(i) = 1 - \sum [p(j|i)]^2$ $\quad G_{split} = \sum \frac{n_i}{n} G_i$

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 3 | overcast | hot | high | weak | yes |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 7 | overcast | cool | normal | strong | yes |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

| Outlook | Play = No | Play = Yes | n |
|---|---|---|---|
| Sunny | 3 | 2 | 5 |

- $G(Sunny) = 1 - (3/5)^2 - (2/5)^2 = 0.48$
- $G(Overcast) = 1 - (0/4)^2 - (4/4)^2 = 0$: pure leaf
- $G(Rainy) = 1 - (2/5)^2 - (3/5)^2 = 0.48$

→ $G_{split} = 5/14*0.48 + 4/14*0 + 5/14*0.48 = 0.34$



# THUẬT TOÁN CART:
# Dữ liệu định tính

- Tính GINI split cho các node còn lại và so sánh

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 3 | overcast | hot | high | weak | yes |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 7 | overcast | cool | normal | strong | yes |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

- $G_{split}$ (Outlook) = 0.34
- $G_{split}$ (Temperature) = 0.43
- $G_{split}$ (Humidity) = 0.37
- $G_{split}$ (Wind) = 0.43

⇨ Root node là Outlook

# THUẬT TOÁN CART:
# Dữ liệu định tính

Vẽ cây quyết định với Root node và tiếp tục các bước tương tự để xác định các node tiếp theo.

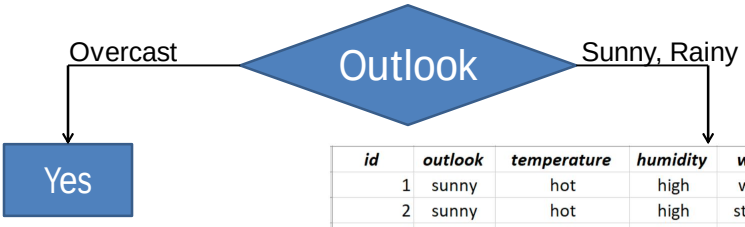


| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 14 | rainy | mild | high | strong | no |



# THUẬT TOÁN CART:
# Dữ liệu định lượng

- Sử dụng độ lệch chuẩn và giá trị giảm thiểu độ lệch chuẩn tại mỗi node phân nhánh (Standard Deviation Reduction – SDR)

$$SDR = SD(\text{biến mục tiêu}) - SD(\text{biến mục tiêu}|t)$$

- Có thể sử dụng RMSE, SS, SSE, SSD thay thế
- Giá trị của biến mục tiêu sau cùng tại các nhánh lá là giá trị trung bình của các đối tượng dữ liệu bên trong node.

# THUẬT TOÁN CART:
# Dữ liệu định lượng

- **Ví dụ:** Xây dựng cây quyết định để dự đoán biến **Điểm trung bình tích lũy**

| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 1 | Ít | Loại Giỏi | Nữ | Có | 8.5 |
| 2 | Trung bình | Loại Giỏi | Nữ | Không | 8.2 |
| 3 | Trung bình | Loại Khá | Nam | Có | 7.8 |
| 4 | Nhiều | Loại Khá | Nam | Không | 7.5 |
| 5 | Nhiều | Loại Giỏi | Nam | Không | 7.9 |
| 6 | Ít | Loại Giỏi | Nữ | Có | 8.2 |
| 7 | Trung bình | Loại Khá | Nam | Không | 7.2 |
| 8 | Ít | Loại Khá | Nữ | Không | 7.5 |
| 9 | Trung bình | Loại Khá | Nam | Không | 7.8 |
| 10 | Nhiều | Loại Khá | Nam | Có | 8 |



# THUẬT TOÁN CART:
# Dữ liệu định lượng

SDR = SD(biến mục tiêu) – SD(biến mục tiêu|t)

| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 1 | Ít | Loại Giỏi | Nữ | Có | 8.5 |
| 2 | Trung bình | Loại Giỏi | Nữ | Không | 8.2 |
| 3 | Trung bình | Loại Khá | Nam | Có | 7.8 |
| 4 | Nhiều | Loại Khá | Nam | Không | 7.5 |
| 5 | Nhiều | Loại Giỏi | Nam | Không | 7.9 |
| 6 | Ít | Loại Giỏi | Nữ | Có | 8.2 |
| 7 | Trung bình | Loại Khá | Nam | Không | 7.2 |
| 8 | Ít | Loại Khá | Nữ | Không | 7.5 |
| 9 | Trung bình | Loại Khá | Nam | Không | 7.8 |
| 10 | Nhiều | Loại Khá | Nam | Có | 8 |

- SD(ĐTB) = 0.369
- Mức độ đi làm thêm:
  - SD(ĐTB|Ít) = 0.42; SD(ĐTB|Trung bình) = 0.357; SD(Nhiều) = 0.216
  - SD(ĐTB|Mức độ đi làm thêm) = 3/10*0.42 + 4/10*0.357+3/10*0.216=0.333
- SDR(Mức độ đi làm thêm) = 0.369 – 0.333 = 0.036

# THUẬT TOÁN CART:
# Dữ liệu định lượng

| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 1 | Ít | Loại Giỏi | Nữ | Có | 8.5 |
| 2 | Trung bình | Loại Giỏi | Nữ | Không | 8.2 |
| 3 | Trung bình | Loại Khá | Nam | Có | 7.8 |
| 4 | Nhiều | Loại Khá | Nam | Không | 7.5 |
| 5 | Nhiều | Loại Giỏi | Nam | Không | 7.9 |
| 6 | Ít | Loại Giỏi | Nữ | Có | 8.2 |
| 7 | Trung bình | Loại Khá | Nam | Không | 7.2 |
| 8 | Ít | Loại Khá | Nữ | Không | 7.5 |
| 9 | Trung bình | Loại Khá | Nam | Không | 7.8 |
| 10 | Nhiều | Loại Khá | Nam | Có | 8 |

- SDR(Mức độ đi làm thêm) = 0.036
- SDR(Thành tích học tập) = 0.126
- SDR(Giới tính) = 0.06
- SDR(Tham gia NCKH) = 0.1

**Thành tích học tập là root node**



# THUẬT TOÁN CART:
# Dữ liệu định lượng

- Vẽ cây quyết định với Root node

| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 1 | Ít | Loại Giỏi | Nữ | Có | 8.5 |
| 2 | Trung bình | Loại Giỏi | Nữ | Không | 8.2 |
| 5 | Nhiều | Loại Giỏi | Nam | Không | 7.9 |
| 6 | Ít | Loại Giỏi | Nữ | Có | 8.2 |

| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 3 | Trung bình | Loại Khá | Nam | Có | 7.8 |
| 4 | Nhiều | Loại Khá | Nam | Không | 7.5 |
| 7 | Trung bình | Loại Khá | Nam | Không | 7.2 |
| 8 | Ít | Loại Khá | Nữ | Không | 7.5 |
| 9 | Trung bình | Loại Khá | Nam | Không | 7.8 |
| 10 | Nhiều | Loại Khá | Nam | Có | 8 |

- Quyết định dừng nhánh hay đi tiếp dựa vào:
  - Giới hạn về tổng số đối tượng của 1 node
  - Hệ số biến thiên V

# THUẬT TOÁN CART:
# Dữ liệu định lượng

- Tính hệ số biến thiên V

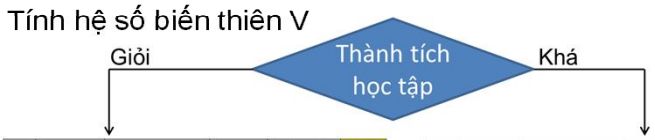


| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 1 | Ít | Loại Giỏi | Nữ | Có | 8.5 |
| 2 | Trung bình | Loại Giỏi | Nữ | Không | 8.2 |
| 5 | Nhiều | Loại Giỏi | Nam | Không | 7.9 |
| 6 | Ít | Loại Giỏi | Nữ | Có | 8.2 |

| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 3 | Trung bình | Loại Khá | Nam | Có | 7.8 |
| 4 | Nhiều | Loại Khá | Nam | Không | 7.5 |
| 7 | Trung bình | Loại Khá | Nam | Không | 7.2 |
| 8 | Ít | Loại Khá | Nữ | Không | 7.5 |
| 9 | Trung bình | Loại Khá | Nam | Không | 7.8 |
| 10 | Nhiều | Loại Khá | Nam | Có | 8 |

V(ĐTB|Giỏi) = $\frac{0.212}{8.2}$ × 100 = 2.59%  V(ĐTB|Khá) = $\frac{0.262}{7.63}$ × 100 = 3.44%

Có thể dừng ở node Giỏi và tạo thêm nhánh trong node Khá

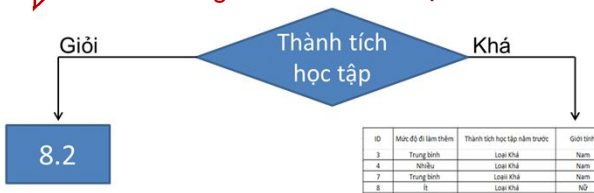


| ID | Mức độ đi làm thêm | Thành tích học tập năm trước | Giới tính | Từng tham gia phong trào nghiên cứu khoa | Điểm trung bình tích lũy |
|---|---|---|---|---|---|
| 3 | Trung bình | Loại Khá | Nam | Có | 7.8 |
| 4 | Nhiều | Loại Khá | Nam | Không | 7.5 |
| 7 | Trung bình | Loại Khá | Nam | Không | 7.2 |
| 8 | Ít | Loại Khá | Nữ | Không | 7.5 |
| 9 | Trung bình | Loại Khá | Nam | Không | 7.8 |
| 10 | Nhiều | Loại Khá | Nam | Có | 8 |



# Thuật toán CART

- Overfitting và Underfitting:

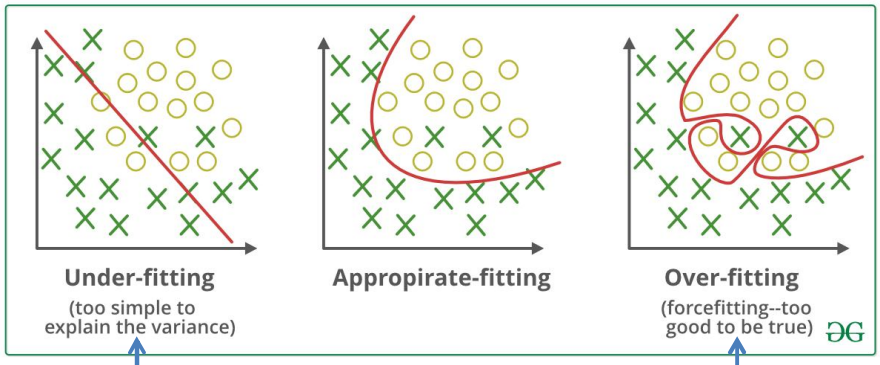


Cây quá ngắn → **Tiêu chuẩn dừng (Stop criterion)** ← Cây quá dài

# TIÊU CHUẨN DỪNG

- Node có entropy bằng 0 (mọi điểm trong node đều thuộc một loại)
- Cây đạt độ cao cho trước
- Độ đo lựa chọn thuộc tính nhỏ hơn ngưỡng đặt trước
- Số lượng điểm dữ liệu nhỏ hơn ngưỡng đặt trước
- Tổng số node lá vượt quá một ngưỡng nào đó

**ĐẶT CÁC NGƯỠNG:**

- Tối thiểu số lượng quan sát trong node phân nhánh
- Tối thiểu số lượng quan sát trong node lá
- Tối đa số lượng thuộc tính dùng để phân nhánh
- Tối đa chiều sâu của cây quyết định



# TIÊU CHUẨN DỪNG

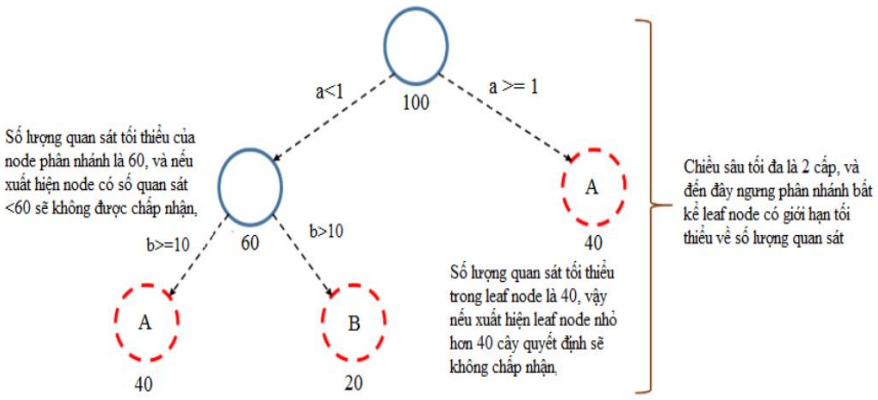

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# PHƯƠNG PHÁP CẮT TỈA (PRUNING)

- Cắt tỉa trước (Pre-pruning): dừng phân nhánh nếu:
  - ✓ Tất cả các quan sát nằm trong cùng 1 phân lớp
  - ✓ Tất cả các giá trị của biến dữ liệu là như nhau
  - ✓ Số quan sát trong node thấp hơn ngưỡng
  - ✓ Node không cải thiện được mức độ đồng nhất (Gini, Entropy)
  - ✓ Sai số tổng quát nhỏ hơn ngưỡng
- Cắt tỉa sau (Post-pruning): cắt tỉa cây sau khi đã phát triển đầy đủ. Thay thế cây con bằng nút lá dựa vào Mode.



KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# CẮT TỈA SAU

- Các bước:
  - ➢ Xây dựng cây quyết định hoàn chỉnh
  - ➢ Tính độ hiệu quả của cây quyết định
  - ➢ Chọn các nhánh không hiệu quả và xác định **phương thức điều chỉnh**
  - ➢ Đánh giá mô hình sau khi điều chỉnh
  - ➢ Tiếp tục thực hiện đến khi đạt hiệu quả cao nhất

# CẮT TỈA SAU

- Phương thức điều chỉnh:

Rút gọn mô hình từ dưới lên

Subtree replacement (Bottom-up)

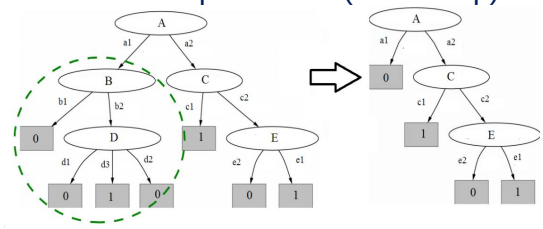


Rút gọn mô hình từ trên xuống

Subtree raising (Top-down)

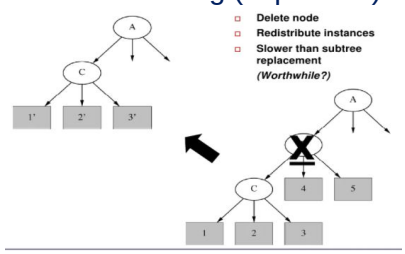




# THUẬT TOÁN ID3, C4.5, C5.0

- ID3 do nhà nghiên cứu khoa học máy tính Ross Quinlan đề xuất vào năm 1986 dựa trên lý thuyết thông tin của Claude Shannon. C4.5 và C5.0 là các phiên bản hoàn thiện hơn.
- C4.5 được sử dụng phổ biến, có các cải thiện so với ID3:
  - Áp dụng được đối với dữ liệu định tính và định lượng
  - Xử lý được khi dữ liệu không đầy đủ
  - Cắt tỉa cành khi cây quá cồng kềnh (overfitting)
  - Có thể tính đến trọng số khi phân nhóm

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# THUẬT TOÁN ID3, C4.5, C5.0

- C5.0 có các cải thiện so với C4.5:
  - Thực hiện nhanh, tốn ít bộ nhớ
  - Cây quyết định nhỏ hơn
  - Bổ sung một số thuộc tính mới như ngày, giờ, dấu thời gian, thuộc tính theo thang đo thứ tự và nhãn dữ liệu
  - Xử lý tốt dữ liệu lớn có nhiều thuộc tính
  - Độ chính xác cao hơn
  - Winnowing - một tùy chọn C5.0 tự động để loại bỏ những thuộc tính có thể không hữu ích



KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

# THUẬT TOÁN ID3, C4.5, C5.0

- Sử dụng Entropy và Infomation Gain (ID3) hoặc Gain Ratio (C4.5, C5.0) để phân chia
- Lựa chọn cách phân nhánh tối ưu dựa trên cơ sở tối đa hóa lượng thông tin nhận vào (information maximization), giảm thiểu tối đa sự hỗn độn và nhiễu loạn trong từng node (entropy reduction)

  → **Entropy càng nhỏ càng tốt**

  → **Information gain và Gain Ratio càng lớn càng tốt**

# THUẬT TOÁN ID3, C4.5, C5.0

- Công thức tính Entropy:

$$\text{Entropy}(i) = -\sum p(i|t)\log_2 p(i|t)$$

$$\text{Entropy}(t) = \sum \frac{n_i}{n}\text{Entropy}(i)$$

- Công thức tính Information Gain:

$$\text{Gain}_{split} = \text{Entropy}(i) - \text{Entropy}(t)$$

- Công thức tính Gain Ratio:

$$\text{GainRATIO}_{split} = \frac{\text{Gain}_{split}}{\text{SplitINFO}}$$

$$\text{SplitINFO} = -\sum \frac{n_i}{n} log_2 \frac{n_i}{n}$$



# THUẬT TOÁN ID3, C4.5, C5.0

- **Ví dụ:** Xây dựng cây quyết định để dự đoán biến **play**: có ra ngoài chơi không?

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 3 | overcast | hot | high | weak | yes |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 7 | overcast | cool | normal | strong | yes |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

# THUẬT TOÁN ID3, C4.5, C5.0

- Tính Entropy của biến mục tiêu: **Entropy(i) =** $-\sum p(i|t)\log_2 p(i|t)$

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 3 | overcast | hot | high | weak | yes |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 7 | overcast | cool | normal | strong | yes |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

Entropy(play) = - [5/14*$\log_2$(5/14) + 9/14*$\log_2$(9/14)] = 0.65



# THUẬT TOÁN ID3, C4.5, C5.0

- Tính Entropy của từng thuộc tính: **Entropy(t) =** $-\sum p(i|t)\log_2 p(i|t)$

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |

Entropy(sunny) = - [3/5*$\log_2$(3/5) + 2/5*$\log_2$(2/5)]
= 0.673

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 3 | overcast | hot | high | weak | yes |
| 7 | overcast | cool | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |

Entropy(overcast) = - 4/4*$\log_2$(4/4) = 0

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 10 | rainy | mild | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

Entropy(rainy) = - [3/5*$\log_2$(3/5) + 2/5*$\log_2$(2/5)]
= 0.673

→ **Entropy(outlook) =** $\sum \frac{n_i}{n} \mathrm{Entropy}(i)$ = 5/14 * 0.673 + 4/14 * 0 + 5/14 * 0.673 = 0.48

# THUẬT TOÁN ID3, C4.5, C5.0

→ **Entropy(outlook) =** 0.48

Tương tự, **Entropy(temperature)** = 0.631

**Entropy(humidity)** = 0.547

**Entropy(wind)** = 0.618

→ **Root node là Outlook**



# THUẬT TOÁN ID3, C4.5, C5.0

- Vẽ cây quyết định với Root node và tiếp tục các bước tương tự để xác định các node tiếp theo.

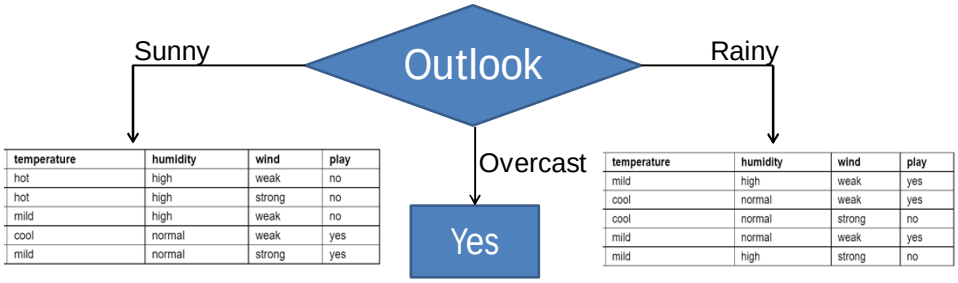


| temperature | humidity | wind | play |
|---|---|---|---|
| hot | high | weak | no |
| hot | high | strong | no |
| mild | high | weak | no |
| cool | normal | weak | yes |
| mild | normal | strong | yes |

| temperature | humidity | wind | play |
|---|---|---|---|
| mild | high | weak | yes |
| cool | normal | weak | yes |
| cool | normal | strong | no |
| mild | normal | weak | yes |
| mild | high | strong | no |

# THUẬT TOÁN ID3, C4.5, C5.0

- Tính Information Gain: $Gain_{split}$ = Entropy(p) – Entropy(t)
- Tính GainRATIO: $GainRATIO_{split} = \frac{Gain_{split}}{SplitINFO}$; SplitINFO = $-\sum \frac{n_i}{n} log_2 \frac{n_i}{n}$

| Thuộc tính t | Entropy(t) | Entropy(p) | Gain | SplitINFO | GainRATIO |
|---|---|---|---|---|---|
| Outlook | 0.480 | 0.650 | 0.170 | | |
| Temperature | 0.631 | 0.650 | 0.019 | | |
| Humidity | 0.547 | 0.650 | 0.103 | | |
| Wind | 0.618 | 0.650 | 0.032 | | |



# THUẬT TOÁN ID3, C4.5, C5.0

| id | outlook | temperature | humidity | wind | play |
|---|---|---|---|---|---|
| 1 | sunny | hot | high | weak | no |
| 2 | sunny | hot | high | strong | no |
| 3 | overcast | hot | high | weak | yes |
| 4 | rainy | mild | high | weak | yes |
| 5 | rainy | cool | normal | weak | yes |
| 6 | rainy | cool | normal | strong | no |
| 7 | overcast | cool | normal | strong | yes |
| 8 | sunny | mild | high | weak | no |
| 9 | sunny | cool | normal | weak | yes |
| 10 | rainy | mild | normal | weak | yes |
| 11 | sunny | mild | normal | strong | yes |
| 12 | overcast | mild | high | strong | yes |
| 13 | overcast | hot | normal | weak | yes |
| 14 | rainy | mild | high | strong | no |

SplitINFO = $-\sum \frac{n_i}{n} \log_2 \frac{n_i}{n}$

| Outlook | $n_i$ |
|---|---|
| Sunny | 5 |
| Overcast | 4 |
| Rainy | 5 |
| **Tổng** | **14** |

SplitINFO(outlook) = $-5/14*\log_2(5/14) – 4/14*\log_2(4/14) -5/14*\log_2(5/14)$

= 1.577

# THUẬT TOÁN ID3, C4.5, C5.0

- Tính Information Gain: $Gain_{split}$ = Entropy(i) – Entropy(t)
- Tính GainRATIO: $GainRATIO_{split} = \frac{Gain_{split}}{SplitINFO}$; SplitINFO = $-\sum \frac{n_i}{n} log_2 \frac{n_i}{n}$

| Thuộc tính t | Entropy(t) | Entropy(i) | Gain | SplitINFO | GainRATIO |
|---|---|---|---|---|---|
| Outlook | 0.480 | 0.650 | 0.170 | 1.577 | 0.108 |
| Temperature | 0.631 | 0.650 | 0.019 | 1.557 | 0.012 |
| Humidity | 0.547 | 0.650 | 0.103 | 1.000 | 0.103 |
| Wind | 0.618 | 0.650 | 0.032 | 0.985 | 0.032 |