HỌC PHẦN

NHỮNG NGUYÊN LÝ CƠ BẢN CỦA KHAI PHÁ DỮ LIỆU

TS Trần Thị Nga

Khoa Thống kê – Trường ĐH KTQD

Email: ttnga@neu.edu.vn

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

XỬ LÝ DỮ LIỆU VỚI R

(GÓI DPLYR)

1. CÁC ĐỘNG TỪ XỬ LÝ CHO 1 BỘ DỮ LIỆU

- Đổi tên cột, dòng: `rename, colnames, rownames`
- Lọc dữ liệu: `select, filter, distinct, sample_n, sample_frac, slice, top_n, top_frac`
- Sắp xếp lại dữ liệu: `arrange, sort`
- Tạo biến mới: `mutate`
- Tóm tắt dữ liệu: `summarise, colSums, table`

BÀI TẬP VẬN DỤNG

Bài 1

Đọc dữ liệu **air-quality.csv**, thực hiện các yêu cầu sau:

1) Tạo dataframe **bai5** gồm các cột ***year***, ***month***, ***aqi***, và ***aqi_categ.***
2) Kiểm tra cấu trúc dữ liệu. Bộ dữ liệu có giá trị trống không? Nếu có, hãy liệt kê các biến có giá trị trống và số lượng dòng trống tương ứng.
3) In ra kết quả 15 quan sát có mức **aqi** lớn nhất, nhỏ nhất và sắp xếp theo thứ tự?
4) Tính trung bình và trung vị chỉ số ***aqi*** theo từng năm và từng tháng trong năm.
5) Xác định số quan sát ở mỗi năm.
6) Xác định các thống kê mô tả của biến ***aqi*** và bảng tần số của ***aqi_categ*** theo thứ tự mức độ ô nhiễm tăng dần
7) Tạo thêm biến **quarter** đứng sau biến **year,** nhận các giá trị từ 1 đến 4 theo các quý trong năm. Lưu kết quả vào file bai4.xlsx. Tạo dataframe mới với 4 cột ***year***, ***quarter, aqi_mean*** và ***aqi_med*** (là trung bình và trung vị về ***aqi*** của từng quý).
8) Chọn thời gian nghiên cứu trong ***quý 4 năm 2016***. Có bao nhiêu quan sát trong khoảng thời gian này? Xác định số lần đo tương ứng với từng mức chất lượng không khí **air_categ**?
9) Tháng nào trong ***quý 4 năm 2016*** có nhiều lần đo có **aqi_categ** ở mức ***Unhealthy*** nhất?
10) Tính trung bình và trung vị cho biến **hour** và **aqi** theo từng quý trong năm (trên **data air_quality**).

BÀI TẬP VẬN DỤNG

Bài 2

Tải package **gapminder** và đọc dữ liệu **gapminder** trong package này:

1) Tính tuổi thọ trung bình (***mean_lifeExp) và dân số trung bình mean_pop*** giai đoạn 1952-2007 của các quốc gia theo từng châu lục và gán vào dataframe **cau1**.
2) Tạo dataframe chỉ gồm 4 cột cuối với dữ liệu của riêng Việt Nam giai đoạn 1952 – 2007. Hãy tính GDP của Việt Nam trong từng năm của giai đoạn này.
3) Lọc dữ liệu các quốc gia trong năm 2007, tạo cột mới ***percentile*** chỉ rõ mức phân vị về GDP của từng quốc gia (sử dụng lệnh **percent_rank**). In ra kết quả 10% quốc gia có mức phân vị cao nhất và 10% quốc gia có mức phân vị thấp nhất với thông tin về quốc gia, châu lục, GDP và phân vị về GDP.