HỌC PHẦN

NHỮNG NGUYÊN LÝ CƠ BẢN CỦA KHAI PHÁ DỮ LIỆU

TS Trần Thị Nga

Khoa Thống kê – Trường ĐH KTQD

Email: ttnga@neu.edu.vn

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

XỬ LÝ DỮ LIỆU VỚI R

(GÓI DPLYR – tiếp)

BÀI TẬP THỰC HÀNH

1. Xem cấu trúc các dữ liệu có sẵn trong R data của package **dplyr**: **band_instruments, band_instruments2** và **band_members**
2. Ghép các cột của **band_instruments** và **band_instruments2**. Nhận xét kết quả từ các câu lệnh khác nhau?
3. Ghép các cột của **band_instruments** và **band_members**. Nhận xét kết quả từ các câu lệnh khác nhau?
4. Sửa tên cột ***name*** trong **band_instruments** thành ***artist***, thêm quan sát Tom/bass và gán vào object mới là **band**.
5. Ghép các dòng của **band** và **band_instruments2.** Có sự khác biệt gì khi dùng các câu lệnh khác nhau?
6. Nối các dòng của dữ liệu **band** và **band_instruments2**
7. Nối các cột của dữ liệu **band** và **band_instruments2.** Có nhận xét gì?

XỬ LÝ DỮ LIỆU VỚI R

(GÓI TIDYR)

XỬ LÝ DỮ LIỆU VỚI GÓI TIDYR

- Một số lệnh cơ bản:

tidyr::**gather(cases, "year", "n", 2:4)**
Biến đổi dữ liệu dạng cột thành hàng

tidyr::**spread(pollution, size, amount)**
Biến đổi dữ liệu dạng hàng thành cột

tidyr::**separate(storms, date, c("y", "m", "d"))**
Tách 1 cột thành nhiều cột

tidyr::unite(data, col, ..., sep)
Ghép nhiều cột thành một.

Tóm tắt dữ liệu

dplyr::**summarise(iris, avg = mean(Sepal.Length))**
Tóm tắt dữ liệu thành các dòng
dplyr::**summarise_each(iris, funs(mean))**
Áp dụng hàm với tất cả các cột trong dữ liệu
dplyr::**count(iris, Species, wt = Sepal.Length)**
Đếm số lượng các dòng khi giá trị của biến là duy nhất (có hoặc không có trọng số)

Summarise sử dụng các hàm tính toán một véc-tơ các giá trị và trả về giá trị, ví dụ:

dplyr::**first**
Giá trị đầu tiên của véc-tơ
dplyr::**last**
Giá trị cuối cùng của véc-tơ.
dplyr::**nth**
Giá trị thứ n của véc-tơ.
dplyr::**n**
Số lượng các quan sát trong véc-tơ
dplyr::**n_distinct**
Số lượng các giá trị khác nhau trong véc-tơ
IQR
IQR của một véc-tơ.

min
Giá trị nhỏ nhất của véc-tơ
max
Giá trị lớn nhất của véc-tơ
mean
Giá trị trung bình của véc-tơ
median
Trung vị của véc-tơ
var
Phương sai của véc-tơ
sd
Độ lệch tiêu chuẩn của véc-tơ

Nhóm dữ liệu

dplyr::**group_by(iris, Species)**
Nhóm các biến thành các hàng có cùng giá trị của Species
dplyr::**ungroup(iris)**
Loại bỏ nhóm
iris %>% group_by(Species) %>% summarise(…)
Tính toán và trả các giá trị với mỗi nhóm

Tạo các biến mới

dplyr::**mutate(iris, sepal = Sepal.Length + Sepal.Width)**
Tính toán và tạo một hoặc nhiều biến mới
dplyr::**mutate_each(iris, funs(min_rank))**
Áp dụng hàm cho mỗi biến
dplyr::**transmute(iris, sepal = Sepal.Length + Sepal.Width)**
Tính toán và tạo biến mới, loại bỏ biến cũ.

Sử dụng "window function", các hàm này tính toán 1 véc-tơ & trả ra giá trị là 1 véc-tơ, ví dụ:

dplyr::**lead**
Copy & tạo 1 véc-tơ có giá trị của biến nhanh hơn 1 đơn vị
dplyr::**lag**
Copy & tạo 1 véc-tơ có giá trị của biến chậm hơn 1 đơn vị
dplyr::**dense_rank**
Thứ tự giá trị của biến (không tính trùng giá trị)
dplyr::**min_rank**
Thứ tự giá trị của biến (tính trùng giá trị)
dplyr::**percent_rank**
Thứ tự giá trị trong khoảng [0, 1].
dplyr::**row_number**
Thứ tự giá trị của biến (tính trùng giá trị - các giá trị trùng nhau được xếp thứ tự khác nhau)
dplyr::**ntile(x,n)**
Chia véc-tơ thành n nhóm
dplyr::**between(x,a,b)**
Kiểm tra các giá trị của x trong khoảng [a,b]

dplyr::**cume_dist**
Véc-tơ giá trị hàm phân phối với từng giá trị của biến
dplyr::**cumall**
Véc-tơ giá trị logic tích lũy theo điều kiện cho trước (tất cả các giá trị phải thỏa mãn)
dplyr::**cumany**
Véc-tơ giá trị logic theo điều kiện cho trước (có ít nhất 1 giá trị thỏa mãn)
dplyr::**cummean**
Véc-tơ giá trị trung bình tích lũy của x
Cumsum
Véc-tơ giá trị tổng tích lũy của x
Cummax
Véc-tơ chứa các giá trị lớn nhất của x theo thứ tự
cummin
Véc-tơ chứa các giá trị nhỏ nhất của x theo thứ tự
cumprod
Véc-tơ giá trị của tích
pmax
Véc-tơ giá trị lớn nhất
pmin
Véc-tơ giá trị nhỏ nhất

iris %>% group_by(Species) %>% mutate(…)
Tạo các biến mới với mỗi nhóm

Lấy dữ liệu: devtools::**install_github("rstudio/EDAWR")**

Nối dữ liệu (Combine Data Sets)

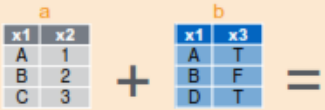

Mutating Joins

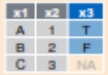

dplyr::**left_join(a, b, by = "x1")**
Ghép các dòng có cùng giá trị từ b đến a.

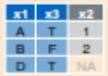

dplyr::**right_join(a, b, by = "x1")**
Ghép các dòng có cùng giá trị từ a đến b

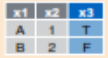

dplyr::**inner_join(a, b, by = "x1")**
Giữ các giá trị có cả ở a & b

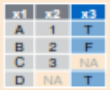

dplyr::**full_join(a, b, by = "x1")**
Giữ tất cả các giá trị ở a & b

Filtering Joins

dplyr::**semi_join(a, b, by = "x1")**
Giữ lại các dòng xuất hiện trong b

dplyr::**anti_join(a, b, by = "x1")**
Giư lại các dòng không có trong b

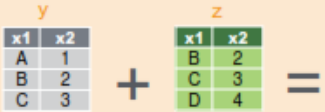

Set Operations

dplyr::**intersect(y, z)**
Các dòng có ở cả y & z

dplyr::**union(y, z)**
Dòng có trong y hoặc z.

dplyr::**setdiff(y, z)**
Dòng có trong y nhưng không có trong z

Binding

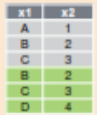

dplyr::**bind_rows(y, z)**
Nối dòng dữ liệu từ z sang y,

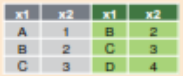

dplyr::**bind_cols(y, z)**
Nối cột dữ liệu từ z sang y
Lưu ý: trùng giá trị của biến.

BÀI TẬP THỰC HÀNH

Sử dụng dữ liệu **billboard** trong gói tidyr trả lời các câu hỏi sau:

1. Mô tả cấu trúc dữ liệu: số dòng, số cột,…
2. Đổi tên cột ***wk1*** thành ***1***. Lọc những bài hát có thứ hạng trên 50 trong cột này. Có bao nhiêu bài hát?
3. Thu gọn dữ liệu từ cột thành dòng với 2 cột mới là ***week*** và ***rank.*** Thực hiện các yêu cầu dưới với dataframe vừa tạo thành.
4. Sắp xếp dữ liệu theo thứ tự tăng dần đối với cột ***rank***
5. Xóa hết các ký tự “wk” ở cột ***week***
6. Tách cột ***date.entered*** thành 3 cột ***day, month, year***
7. Tạo biến mới ***quarter*** trên cơ sở biến ***month***
8. Tính thứ hạng trung bình của từng bài hát.
9. Sắp xếp thứ hạng trung bình các bài hát đó từ cao xuống thấp
10. Tạo báo cáo Rmarkdown để diễn giải các câu hỏi trên.