HỌC PHẦN

NHỮNG NGUYÊN LÝ CƠ BẢN CỦA KHAI PHÁ DỮ LIỆU

TS Trần Thị Nga

Khoa Thống kê – Trường ĐH KTQD

Email: ttnga@neu.edu.vn

KHOA THỐNG KÊ
ĐẠI HỌC KINH TẾ QUỐC DÂN

TẠO BẢNG VÀ ĐỒ THỊ VỚI R

1. BẢNG

- Lệnh **table** có sẵn trong R (đơn giản, ít tùy chọn, không linh hoạt)
- Lệnh **tabular** trong package **tables** (hỗ trợ xuất latex, pdf đẹp)

```
tabular(dòng + dòng + ... ~ cột + cột + ...)
tabular(dòng * dòng * ... ~ cột * cột * ...)
```

2. ĐỒ THỊ

- Lệnh **plot** có sẵn trong R (đơn giản, ít tùy chọn, không linh hoạt)
- Lệnh **ggplot** trong package **ggplot2** (nhiều tùy chọn, thông dụng)
- Lệnh **ggplotly** trong package **plotly** (đồ thị tương tác)
- Package **gganimate** (đồ thị động)

BÀI TẬP VẬN DỤNG

Bài 1: Thực hành với dữ liệu **diamonds** có sẵn trong ggplot2

- Lập bảng tần số và tần suất đối với chất lượng cắt (**cut**), sắp xếp theo thứ tự giảm dần về tần số và lưu data frame vào file excel (sử dụng table và tabular).
- Lập bảng chéo phân tích mối liên hệ giữa chất lượng cắt (**cut**) và màu sắc (**color**). Bổ sung dòng/cột **tổng** cho bảng này.
- Xóa 53000 quan sát đầu trong dữ liệu. Lập bảng chéo phân tích mối liên hệ giữa chất lượng cắt (**cut**) và biến **table**.
- Vẽ đồ thị cột biểu diễn tần số của các loại chất lượng cắt (**cut**).

ÔN TẬP

BÀI TẬP TỔNG HỢP

Bài 2: Thực hành với dữ liệu **midwest** trong gói **ggplot2.**

1. Tạo dataframe mới c1 chỉ gồm dữ liệu của các hạt (**county**) thuộc *bang **(state)** Indiana **(IN)***
2. Tạo dataframe mới c2 chỉ gồm các dữ liệu về dân số da trắng (**popwhite**) từ 40-85 nghìn người ở các hạt (**county**)của bang ***Ohio (OH)***
3. Tạo dữ liệu c3 gồm các biến **state, county, poptotal, popamerindian, percamerindan** của ***bang Ohio***. Sắp xếp dữ liệu biến **popamerindian** (thổ dân Mỹ) theo thứ tự tăng dần. Hạt nào của bang này có nhiều người thổ dân nhất?
4. Tạo dữ liệu c4 gồm các hạt của bang Michigan (MI) có dân số nghèo (**poppovertyknown)** lớn hơn 10 nghìn người và tỷ lệ dân số có trình độ chuyên môn (**percprof)** lớn hơn 12%. Dữ liệu mới này chỉ gồm những cột đã đề cập trong câu hỏi này.

BÀI TẬP TỔNG HỢP

Bài 2 *(tiếp)*: Thực hành với dữ liệu **midwest** trong gói **ggplot2.**

5. Tính dân số nghèo ***(poppovertyknown)*** trung bình của từng bang. Sắp xếp các bang theo thứ tự giảm dần về dân số nghèo trung bình.

6. Chọn ngẫu nhiên 10% quan sát theo phương pháp chọn không hoàn lại, gán vào dataframe **c6**. Có bao nhiêu quan sát được chọn? Nối dataframe **c6** với **midwest** và lưu vào dataframe **combine**.

7. Xóa các quan sát có giá trị trùng nhau trong dataframe **combine** và lưu vào dataframe **c72**.

8. Đổi tên cột **PID** thành **2**, lưu vào dataframe **c82**. Sau đó, đổi lại tên cột **2** thành **PID**.

BÀI TẬP TỔNG HỢP

Bài 2 *(tiếp)*: Thực hành với dữ liệu **midwest** trong gói **ggplot2.**

9. Lập bảng chứa đồng thời tần số và tần suất về số lượng các quan sát trong từng bang (**state**). Vẽ đồ thị tần số.

10. Lập bảng tần số và tần suất mô tả số lượng và tỷ trọng quan sát của từng bang ***(*state*)*** trong mẫu nghiên cứu.

11. Vẽ biểu đồ phân tán thể hiện mối liên hệ giữa tổng số dân (**poptotal**) và mật độ dân số (**popdensity**)

12. Vẽ biểu đồ hộp ria mèo thể hiện phân phối của biến tỷ lệ phần trăm người già sống dưới mức nghèo khổ***(*percelderlypoverty*)*** chia theo bang (**state**).

BÀI TẬP TỔNG HỢP

Bài 2 *(tiếp)*: Thực hành với dữ liệu **midwest** trong gói **ggplot2.**

13. Dữ liệu có giá trị trống không?
14. Dựa vào cột **state**, có bao nhiêu quan sát ở mỗi bang?
15. Dựa vào biến tỷ lệ % người sống dưới mức nghèo khổ (**percbelowpoverty)**, tạo biến mới là: level_poverty với các biểu hiện: low (dưới 15%), medium (từ 15% đến 50%), và high (trên 50%); chỉ giữ lại cột county, state, percamerindan và level_poverty. Có bao nhiêu quan sát trong mỗi nhóm?
16. Tính trung bình và trung vị về số người gốc Á **(popasian)** theo từng bang